

DISCOURS DE SOUTENANCE

Conception et mise en œuvre d'une solution décisionnelle pour l'analyse et l'optimisation du transport urbain de Dakar

Ibtihel Abdellaoui — Projet de Fin d'Études — CETUD

Durée indicative : 15 à 18 minutes • 31 supports projetés

0. Ouverture

| *Sourire, voix posée, contact visuel avec le jury avant de commencer.*

Madame, Monsieur les membres du jury, Madame, Monsieur les encadrants, bonjour, et merci pour votre présence et votre attention.

Je m'appelle Ibtihel Abdellaoui, et je vais vous présenter mon Projet de Fin d'Études, réalisé pour le compte du CETUD, le Conseil Exécutif des Transports Urbains de Dakar. Ce projet porte sur la conception et la mise en œuvre d'une solution décisionnelle pour l'analyse et l'optimisation du transport urbain de Dakar, combinant Business Intelligence et Machine Learning au service de la mobilité urbaine.

Avant d'entrer dans le détail, laissez-moi vous présenter le plan de mon intervention : je commencerai par le contexte et la problématique du projet, puis je détaillerai la phase d'analyse et de conception, la mise en œuvre technique, les modèles d'intelligence artificielle développés, et enfin la restitution et la démonstration de la solution, avant de conclure sur les limites et les perspectives.

1. Contexte du projet

| *Slides 3 à 8 — ≈ 3 minutes. Ton posé, on installe la légitimité du sujet.*

Le CETUD et la problématique

Le CETUD est l'autorité organisatrice de la mobilité urbaine dans l'agglomération dakaroise. Sa mission est de planifier, réguler et améliorer l'offre de transport — bus, cars rapides, TER, BRT — au service des citoyens.

Le CETUD dispose de données riches : une enquête ménages-déplacements, des comptages de trafic sur le terrain. Mais ces données sont dispersées, peu structurées, et restent largement sous-exploitées. La problématique qui a guidé ce projet est la suivante : comment transformer ces

données brutes en informations décisionnelles fiables, et comment aller au-delà du simple reporting grâce au Machine Learning ?

J'ai répondu à cette problématique par une double approche : la mise en place d'un système décisionnel classique, de type Business Intelligence, complété par des modèles prédictifs de Machine Learning.

Objectifs du projet

Pour répondre à cette problématique, je me suis fixé six objectifs : analyser les besoins des décideurs du CETUD, modéliser un entrepôt de données en constellation, construire la chaîne ETL avec Talend, restituer les indicateurs clés dans un cockpit Knowage, aller au-delà du reporting grâce à des modèles de segmentation, de recommandation et de détection d'anomalies, et enfin livrer une application complète, accessible aux citoyens comme aux décideurs.

Méthodologie : GIMSI et Scrum

Sur le plan méthodologique, j'ai structuré la démarche décisionnelle selon la méthode GIMSI, en quatre grandes étapes : l'identification des décideurs, des besoins et des données disponibles ; la conception du modèle décisionnel ; la mise en œuvre technique de l'ETL, de l'entrepôt et du cockpit ; et enfin une phase d'amélioration permanente, avec les modèles de Machine Learning et l'application web.

En complément, le pilotage opérationnel du projet a suivi une approche agile Scrum, organisée en sprints itératifs : un backlog de produit priorisé, des sprints courts dédiés chacun à un lot de fonctionnalités, des revues de sprint pour démontrer les livrables et recueillir des retours, et une amélioration continue du backlog. Un exemple concret de cette agilité : la table de faits Fait_Accessibilité, avec ses trois dimensions associées, a été ajoutée en cours de projet, suite à un besoin identifié lors d'une revue de sprint.

2. Analyse & conception

| Slides 9 à 14 — ≈ 3 minutes. On montre la rigueur de la démarche d'analyse.

Décideurs cibles et données sources

J'ai identifié deux profils de décideurs prioritaires au sein du CETUD. Le directeur de planification, dont l'objectif est de planifier l'offre et de comprendre la demande, avec comme indicateur associé

les volumes de déplacements par jour et par zone. Et le responsable d'exploitation, qui doit ajuster les horaires et les fréquences, en s'appuyant sur les heures de pointe et la charge par créneau.

Pour répondre à leurs besoins, j'ai mobilisé deux sources de données réelles fournies par le CETUD : l'enquête ménages-déplacements, qui couvre 13 415 individus et 3 176 ménages enquêtés, et les données de comptage de trafic, avec 49 sites de comptage et plus de 37 000 observations. Ces données couvrent la géographie du domicile, les caractéristiques du ménage, les déplacements individuels — motif, mode, durée, coût — ainsi que l'accessibilité aux services et les problèmes de quartier rencontrés.

Exploration des données et dictionnaire de données

Avant toute modélisation, j'ai mené une phase d'exploration des données dans un notebook Jupyter dédié : vérification de la volumétrie et de la structure des quatre tables sources, détection des valeurs manquantes — par exemple 104 colonnes sur 231 pour la table Ménage — détection des valeurs aberrantes par la règle de l'écart interquartile, et vérification de l'absence de doublons stricts.

L'ensemble de ce travail est documenté dans un dossier que j'ai appelé « CETUD DATA », qui regroupe les fichiers sources bruts, un dictionnaire de données complet faisant le lien entre chaque colonne, sa description métier et son mapping vers le modèle décisionnel, ainsi que le notebook d'exploration et des captures de la structure des tables sous pgAdmin.

KPIs et modèle décisionnel en constellation

J'ai ensuite spécifié les indicateurs clés à restituer, dont un score d'accessibilité composite, construit sur 0 à 100 points à partir de plusieurs facteurs : la durée de marche jusqu'à l'arrêt de transport en commun, la diversité des modes disponibles, le risque d'inondation de la zone, ou encore la tarification abusive en période de pluie. Ce score permet de classer chaque zone en quatre niveaux : bien desservie, moyenne, sous-desservie, ou critique.

Sur cette base, j'ai conçu un modèle décisionnel en constellation, composé de quatre tables de faits — Fait_Comptage, Fait_Déplacement, Fait_IndividuMénage et Fait_Accessibilité — articulées autour de dix dimensions partagées. Comme je l'ai mentionné, la table Fait_Accessibilité et ses trois dimensions ont été ajoutées en cours de projet, pour répondre spécifiquement au besoin d'analyse de l'accessibilité aux services.

3. Mise en œuvre technique

Slides 15 à 18 — ≈ 2 minutes. Rythme plus technique mais concret, citer les noms des composants.

Environnement et chaîne ETL

Sur le plan technique, j'ai mis en place une chaîne outillée de bout en bout : Python et Google Colab pour la préparation des données, Talend pour l'ETL, PostgreSQL pour l'entrepôt de données, Knowage pour le cockpit décisionnel, FastAPI pour exposer les modèles de Machine Learning, et React.js pour l'application web.

L'ETL sous Talend repose sur une architecture en deux niveaux : une zone de staging, qui charge les données brutes filtrées depuis les fichiers individu, ménage et déplacement, puis une zone de chargement, où le composant tMap réalise les jointures, les transformations et les calculs nécessaires pour peupler les tables de faits et de dimensions. Les composants clés utilisés sont tFileInputExcel, tFilterColumns, tMap, tDBInput et tDBOutput.

Entrepôt PostgreSQL

L'entrepôt a été implémenté sous PostgreSQL, dans un schéma dédié, en respectant les conventions de nommage Dim_ et Fait_, avec des clés primaires et étrangères cohérentes, et un contrôle systématique des volumes après chaque chargement — j'ai notamment vérifié, via pgAdmin, le contenu de la table Fait_Comptage croisée avec les 507 zones géographiques de la dimension Dim_Geographie. Une attention particulière a été portée à la qualité des données, avec la détection des valeurs manquantes ou aberrantes, et une table dédiée à l'accessibilité.

4. Intelligence artificielle

Slides 19 à 24 — ≈ 4 minutes. C'est le cœur scientifique : énoncer clairement métrique + chiffre pour chaque modèle.

Segmentation des usagers — K-Means

Le premier modèle développé est un algorithme de segmentation non supervisée, K-Means, appliqué aux variables sociodémographiques et de mobilité issues de l'enquête. Après normalisation et imputation des valeurs manquantes par la médiane, j'ai retenu cinq segments, choisis par la méthode du coude combinée à un coefficient de silhouette de 0,31. Ces cinq profils sont les actifs réguliers en transport en commun, les actifs motorisés, les étudiants en mobilité douce, les piétons de proximité, et les travailleurs informels.

Recommandation de mode de transport — Random Forest

Le deuxième modèle est un classifieur Random Forest, entraîné pour recommander un mode de transport parmi cinq catégories : transport en commun, voiture, taxi ou clando, marche, et moto. Le modèle utilise 200 arbres, une profondeur maximale de 10, une pondération équilibrée des classes, et a été validé par validation croisée stratifiée en 5 plis. Il atteint une accuracy de 90,6 % et un F1-score macro de 0,88. En production, le modèle retourne un top 3 des modes les plus probables, enrichi d'estimations de durée et de coût.

Détection d'anomalies de trafic

Le troisième axe porte sur la détection d'anomalies dans les données de trafic, à travers un consensus pondéré de trois algorithmes complémentaires : le Z-Score, pour les valeurs extrêmes univariées, pondéré à 0,25 ; l'Isolation Forest, pour la détection multivariée par isolement, pondéré à 0,40 ; et le Local Outlier Factor, pour la détection par densité locale, pondéré à 0,35. Un seuil de consensus supérieur ou égal à 0,6 permet de réduire significativement les faux positifs par rapport à un algorithme unique. Un clustering spatial DBSCAN vient ensuite distinguer les zones d'anomalies structurelles des incidents isolés.

Prédiction du risque d'inaccessibilité

Le quatrième modèle est un Gradient Boosting Classifier, qui prédit un risque d'inaccessibilité à partir d'un score composite construit sur sept indicateurs de terrain — distance au transport en commun, risque d'inondation, enclavement, accès à la santé, entre autres — avec un seuil fixé au 65^e percentile. Le pipeline complet comprend l'imputation, l'encodage, la normalisation, un sur-échantillonnage SMOTE pour corriger le déséquilibre des classes, puis une validation croisée stratifiée comparant quatre algorithmes. Le modèle retenu atteint un ROC AUC de 0,921, un F1-score de 88,3 % et une accuracy de 90,6 %. Les variables les plus déterminantes sont la distance à pied jusqu'à l'arrêt de transport en commun et la durée d'accès aux soins de santé.

L'ensemble de ces quatre modèles est sérialisé avec joblib et exposé via l'API FastAPI, qui les rend directement consommables par l'application web.

5. Restitution & démonstration

| Slides 25 à 30 — ≈ 3 minutes. Ici on peut basculer vers la démo live si prévue.

Cockpit décisionnel Knowage

La restitution des résultats repose sur un cockpit Knowage organisé en cinq feuillets thématiques : Accueil, Trafic, Déplacements, Démographie et Accessibilité. Ces feuillets sont directement connectés à l'entrepôt PostgreSQL, ce qui permet une restitution quasi temps réel des indicateurs — trafic horaire, flux par zones, accessibilité aux services, et démographie des usagers.

Au total, le cockpit restitue les chiffres clés du projet : 13 415 individus et 3 176 ménages enquêtés, 49 sites de comptage et 37 248 observations de trafic, 507 zones géographiques cartographiées, dont 41 zones identifiées comme à risque par le modèle de prédiction.

Application web

En complément du cockpit, j'ai développé une application web complète, articulée autour d'un backend FastAPI exposant neuf endpoints REST avec validation Pydantic, et d'un frontend React.js gérant les rôles d'accès entre l'espace citoyen et l'espace décideurs. Les principaux endpoints permettent de recommander un mode de transport, de récupérer les zones à risque, de consulter la synthèse des anomalies, les profils de segmentation, ou encore de prédire un risque d'inaccessibilité.

Côté citoyen, le parcours commence par une page d'accueil, puis un formulaire de profil de mobilité avec un contrôle contextuel selon l'âge, pour aboutir à une recommandation personnalisée avec le top 3 des modes de transport et leurs estimations de durée et de coût. Côté décideurs, l'espace propose une vue générale de synthèse, une cartographie des 41 zones à risque, un tableau de bord des anomalies par site de comptage, une page de segmentation avancée et un simulateur de risque, ainsi qu'un module de transparence sur les modèles de Machine Learning, pour en assurer l'auditabilité.

6. Limites, perspectives et conclusion

Slides 29 à 31 — ≈ 2 minutes. Ton honnête sur les limites, puis remontée en confiance pour la conclusion.

Limites assumées et perspectives

Ce projet comporte naturellement certaines limites, que j'assume pleinement. L'enquête ménages-déplacements utilisée date de 2019, la plus récente disponible publiquement. Le système ne s'appuie pas encore sur des données temps réel issues de capteurs ou de GPS. L'authentification

reste simplifiée, dans la mesure où il s'agit d'un projet à visée démonstrative. Et la validation a été réalisée manuellement, sans suite de tests automatisés.

Ces limites ouvrent naturellement des perspectives d'évolution : l'intégration de données temps réel auprès des opérateurs de transport, la conteneurisation de la solution avec Docker et la mise en place d'une chaîne CI/CD, une authentification renforcée par JWT et bcrypt, et l'exploration de modèles de Deep Learning plus avancés, comme des réseaux LSTM pour la prévision de trafic ou des réseaux de neurones sur graphes pour modéliser le réseau de transport.

Conclusion

Pour conclure, ce projet répond à la problématique initiale en assumant une double dimension, décisionnelle et prédictive. D'un côté, une dimension Business Intelligence classique, avec un modèle en constellation, une chaîne ETL sous Talend, un entrepôt PostgreSQL et un cockpit Knowage. De l'autre, une dimension Machine Learning, avec la segmentation des usagers, la recommandation de mode de transport, la détection d'anomalies et la prédiction de risque. Ces deux dimensions sont réunies dans une application complète, associant une API FastAPI et une interface React, à destination à la fois des citoyens et des décideurs du CETUD.

Je crois que ce travail constitue une base solide pour accompagner le CETUD vers une mobilité urbaine plus efficace et plus inclusive à Dakar.

Je vous remercie de votre attention, et je reste à votre disposition pour répondre à vos questions.

Notes de présentation

- Débit recommandé : environ 130 mots/minute — marquer une pause après chaque chiffre clé (90,6 %, 0,921, 13 415...).
- Garder le contact visuel avec le jury pendant les transitions entre sections, pas seulement en lisant l'écran.
- Prévoir une réponse courte et assumée sur la limite « données 2019 » : elle revient presque toujours en question.
- Si démonstration live prévue : l'annoncer explicitement avant de basculer (« Je vous propose à présent une courte démonstration... »).