

Rapport de Projet de Fin d'Etudes

En vue de l'obtention du Diplome National d'Ingenieur / Licence
Appliquee

Conception et mise en oeuvre d'une solution decisionnelle pour l'analyse et l'optimisation du transport urbain de Dakar

Cas du CETUD – Conseil Executif des Transports Urbains de Dakar

Realise par :
Ibtihel Abdellaoui

Encadre par :
[Nom de l'encadrant academique]
[Nom de l'encadrant professionnel –
CETUD]



Remerciements

Au terme de ce travail, je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce projet de fin d'études.

Je remercie en premier lieu mon encadrant académique pour son suivi rigoureux, ses conseils avisés et sa disponibilité tout au long de ce projet.

Mes remerciements vont également à mon encadrant professionnel au sein du CETUD (Conseil Exécutif des Transports Urbains de Dakar) pour la confiance qu'il m'a accordée, pour l'accès aux données du projet et pour son accompagnement durant toute la durée du stage.

Je remercie aussi l'ensemble du corps enseignant qui a contribué à ma formation tout au long de mon parcours universitaire, ainsi que les membres du jury qui me font l'honneur d'évaluer ce travail.

Enfin, je remercie ma famille et mes proches pour leur soutien constant et leurs encouragements.

Résumé

Le présent rapport décrit la conception et la mise en œuvre d’une solution décisionnelle (Business Intelligence) destinée à l’analyse et à l’optimisation du transport urbain de la ville de Dakar, réalisée pour le compte du CETUD (Conseil Exécutif des Transports Urbains de Dakar). Le projet s’appuie sur les données de l’Enquête Ménages-Déplacements (EMD) ainsi que sur des données de comptage de trafic, et couvre l’ensemble de la chaîne décisionnelle : compréhension métier, modélisation multidimensionnelle des données en schéma en constellation (4 faits, 10 dimensions), mise en œuvre d’un processus d’extraction-transformation-chargement (ETL) avec Talend, implémentation d’un entrepôt de données sous PostgreSQL, restitution à travers des tableaux de bord interactifs développés avec Knowage BI, et enrichissement de la solution par des modèles de Machine Learning (segmentation des usagers, système de recommandation, détection d’anomalies de trafic et prédiction des zones à risque d’inaccessibilité). L’ensemble de la solution est exposé à travers une application web (React / FastAPI) destinée à la fois aux usagers du réseau et aux décideurs du CETUD. Ce travail répond à la problématique de la valorisation d’un grand volume de données hétérogènes afin de fournir une vision globale, fiable et exploitable des flux de transport, en vue d’améliorer la prise de décision et l’optimisation du réseau de transport urbain.

Mots-clés : Business Intelligence, Data Warehouse, ETL, Talend, PostgreSQL, Knowage, schéma en constellation, Machine Learning, transport urbain, CETUD, Dakar.

Abstract

This report presents the design and implementation of a Business Intelligence solution for the analysis and optimization of urban transport in Dakar, carried out on behalf of CETUD (Executive Council of Urban Transport of Dakar). The project relies on Household Travel Survey (EMD) data as well as traffic count data, and covers the full decision-support chain: business understanding, multidimensional data modeling using a constellation schema (4 fact tables, 10 dimensions), an ETL process implemented with Talend, a PostgreSQL data warehouse, interactive dashboards built with Knowage BI, and Machine Learning models for user segmentation, recommendation, traffic anomaly detection and accessibility-risk prediction. The whole solution is exposed through a web application (React / FastAPI) for both end users and CETUD decision-makers.

Keywords: Business Intelligence, Data Warehouse, ETL, Talend, PostgreSQL, Knowage, constellation schema, Machine Learning, urban transport, CETUD, Dakar.

Contents

Remerciements	i
Résumé	ii
Introduction générale	1
1 Contexte général du projet	3
1.1 Introduction	3
1.2 Organisme d'accueil	3
1.3 Problématique	3
1.4 Objectifs du projet	4
1.5 Méthodologie de conduite de projet	4
1.6 Planification du projet	5
1.7 Conclusion	6
2 Environnement de travail	7
2.1 Introduction	7
2.2 Vue d'ensemble de la chaîne technique	7
2.3 Environnement de prétraitement des données	8
2.3.1 Python	8
2.3.2 Google Colab	8
2.4 Outil ETL : Talend	8
2.5 Système de gestion de base de données : PostgreSQL	8
2.6 Plateforme de restitution décisionnelle : Knowage	9
2.7 Développement de l'application web	9
2.7.1 FastAPI	9
2.7.2 React	10
2.8 Méthodologie de gestion de projet : Scrum	10
2.9 Synthèse	11
3 Analyse métier et spécification des besoins	12
3.1 Introduction	12
3.2 Les données sources	12

3.3	Identification des décideurs et de leurs besoins	13
3.3.1	Le directeur de planification	13
3.3.2	Le responsable d'exploitation	13
3.4	Spécification des indicateurs clés (KPIs)	14
3.5	Priorisation des données à intégrer	14
3.6	Conclusion	15
4	Conception du modèle décisionnel	16
4.1	Introduction	16
4.2	Choix du schéma en constellation	16
4.3	Description des tables de faits	17
4.3.1	Fait_Comptage	17
4.3.2	Fait_IndividuMenage	17
4.3.3	Fait_Deplacement	17
4.3.4	Fait_Accessibilite	18
4.4	Description des dimensions	19
4.5	Indicateurs calculés	19
4.6	Conclusion	20
5	Mise en œuvre de l'ETL avec Talend	21
5.1	Introduction	21
5.2	Architecture générale de l'ETL	21
5.3	Zone de préparation (Staging Area)	21
5.4	Configuration des dimensions	22
5.5	Construction des tables de faits	22
5.5.1	Fait_Deplacement	22
5.5.2	Fait_Comptage	23
5.5.3	Fait_Accessibilité et Fait_IndividuMenage	24
5.6	Composants Talend mobilisés	24
5.7	Conclusion	24
6	Implémentation de l'entrepôt de données	26
6.1	Introduction	26
6.2	Choix d'implémentation	26
6.3	Structure physique des tables de faits	26
6.4	Structure physique des dimensions	28
6.5	Table de faits dédiée à l'accessibilité	29
6.6	Administration et contrôle qualité	30
6.7	Conclusion	30

7	Modèles de Machine Learning	31
7.1	Introduction	31
7.2	Segmentation des usagers (K-Means)	31
7.2.1	Objectif et données	31
7.2.2	Choix du nombre de clusters	32
7.2.3	Profils obtenus	32
7.3	Recommandation de mode de transport (Random Forest)	33
7.4	Détection d'anomalies de trafic	34
7.4.1	Démarche	34
7.4.2	Clustering spatial des anomalies	35
7.5	Prédiction du risque d'inaccessibilité	35
7.5.1	Construction de la variable cible	35
7.5.2	Pipeline d'entraînement	35
7.6	Synthèse	36
8	Cockpit décisionnel Knowage BI	37
8.1	Introduction	37
8.2	Organisation du cockpit	37
8.2.1	Indicateurs de trafic	37
8.2.2	Indicateurs de déplacement	39
8.2.3	Indicateurs démographiques	40
8.2.4	Indicateurs d'accessibilité	41
8.3	Synthèse des KPIs produits	41
8.4	Apport du cockpit pour les décideurs	42
8.5	Conclusion	42
9	Application web et démonstration de la solution	43
9.1	Introduction	43
9.2	Architecture technique	43
9.3	Parcours citoyen	44
9.3.1	Page d'accueil	44
9.3.2	Formulaire et recommandation	44
9.4	Espace décideurs	44
9.4.1	Authentification et contrôle d'accès	45
9.4.2	Vue générale	45
9.4.3	Zones à risque d'inaccessibilité	45
9.4.4	Tableau de bord des anomalies	45
9.4.5	Segmentation des usagers	45
9.4.6	Simulateur de risque	45
9.4.7	Transparence des modèles (MlInsights)	45

9.4.8	Évolution temporelle	46
9.5	Synthèse de la démonstration	46
9.6	Conclusion	46
Conclusion générale		47
A Annexes		50
A.1	Exploration des données (data discovery) et dictionnaire de données	50
A.2	Dictionnaire des codes de variables EMD utilisés	51
A.3	Glossaire	51
A.4	Liste des technologies utilisées	52
A.5	Liste des points d'accès API	52

List of Figures

1.1	Méthodologie GIMSI appliquée à la construction du système décisionnel . .	5
1.2	Diagramme de Gantt du projet	6
2.1	Architecture globale de la chaîne décisionnelle	7
2.2	Python et Google Colab	8
2.3	Talend Open Studio	8
2.4	PostgreSQL	9
2.5	Knowage BI	9
2.6	FastAPI	9
2.7	React	10
2.8	Méthodologie agile Scrum	11
4.1	Schéma en constellation du modèle décisionnel (4 faits, 10 dimensions) . .	17
5.1	Job Talend de chargement de la Staging Area – déplacements	22
5.2	Jobs de construction des dimensions de référence	22
5.3	Composant tMap du job de construction de Fact_deplacement	23
5.4	Job Talend de construction de Fact_Comptage	24
6.1	Structure de la table Fact_Comptage (pgAdmin)	27
6.2	Structures des tables Fact_deplacement et Fact_indivMen	28
6.3	Extrait de la table Dim_Geographie (507 zones)	28
6.4	Vérification des dimensions Dim_Menage , Dim_Individu et Dim_Site	29

6.5	Structure de la table <code>fact_access</code>	29
7.1	Exploration des données individus avant segmentation	32
7.2	Détermination du nombre optimal de clusters (méthode du coude + silhouette)	32
7.3	Caractérisation des segments par variable (heatmap)	33
8.1	Évolution horaire du trafic	38
8.2	Volume de trafic par site et par sens de circulation	38
8.3	Identification des heures de pointe	39
8.4	Temps de parcours par motif et coût moyen des déplacements	39
8.5	Flux de déplacements entre zones géographiques	40
8.6	Répartition par sexe et statut matrimonial	40
8.7	Niveau d'instruction et statut d'activité	40
8.8	Accès aux services et manque de transport déclaré	41
8.9	Difficultés d'accès déclarées et exposition aux inondations	41

List of Tables

2.1	Synthèse de l'environnement de travail	11
3.1	Synthèse des décideurs et de leurs usages des données	13
4.1	Dictionnaire des dimensions du modèle décisionnel	19
5.1	Composants Talend utilisés	24
7.1	Segments d'utilisateurs identifiés par K-Means	33
7.2	Algorithmes de détection d'anomalies et pondération du consensus	34
7.3	Performances du modèle de prédiction d'inaccessibilité (Gradient Boosting)	35
7.4	Synthèse des modèles de Machine Learning développés	36
8.1	Synthèse des indicateurs clés restitués (cockpit Knowage)	41
9.1	Principaux points d'accès (endpoints) de l'API	44
9.2	Synthèse des écrans de l'application web	46
A.1	Principaux codes de variables EMD exploités	51
A.2	Stack technique du projet	52

A.3	Liste complète des endpoints REST exposés par l'API	52
-----	---	----

Introduction générale

La ville de Dakar connaît, comme la plupart des grandes agglomérations africaines, une croissance urbaine rapide accompagnée d'une demande de mobilité de plus en plus forte. Le réseau de transport urbain, structuré autour de multiples modes (bus, cars rapides, Ndiaga Ndiaye, TATA, taxis, transport informel), génère un volume important de données issues des enquêtes ménages-déplacements et des dispositifs de comptage de trafic. Ces données, bien que riches, restent aujourd'hui largement sous-exploitées par manque d'outils permettant de les centraliser, de les croiser et de les restituer sous une forme directement utilisable par les décideurs.

C'est dans ce contexte que le CETUD (Conseil Exécutif des Transports Urbains de Dakar), autorité organisatrice des transports urbains de la région de Dakar, a souhaité disposer d'une solution décisionnelle complète permettant de transformer ces données brutes en informations stratégiques. L'enjeu n'est pas uniquement technique : il s'agit de fournir aux directeurs de planification et aux responsables d'exploitation du CETUD une vision fiable, actualisée et exploitable des flux de transport, afin d'orienter les décisions d'investissement, d'adaptation de l'offre et d'amélioration de l'accessibilité.

Le présent projet de fin d'études a consisté à concevoir et développer une chaîne décisionnelle complète, allant de la collecte et du nettoyage des données brutes jusqu'à leur restitution sous forme de tableaux de bord interactifs, en passant par la modélisation multidimensionnelle, l'industrialisation du processus ETL et l'intégration de modèles de Machine Learning pour enrichir l'analyse. La solution a par ailleurs été intégrée dans une application web complète, offrant à la fois un espace public pour les usagers du réseau et un espace sécurisé pour les décideurs du CETUD.

Ce rapport est organisé en neuf chapitres. Le premier chapitre présente le contexte général du projet, la problématique traitée, les objectifs visés ainsi que la méthodologie de conduite de projet adoptée. Le deuxième chapitre décrit l'environnement de travail, c'est-à-dire l'ensemble des outils, langages et technologies mobilisés. Le troisième chapitre est consacré à l'analyse métier : identification des décideurs cibles, de leurs besoins et des indicateurs clés à produire. Le quatrième chapitre détaille la conception du modèle décisionnel, structuré en schéma en constellation. Les chapitres cinq et six couvrent respectivement la mise en œuvre du processus ETL avec Talend et l'implémentation physique de l'entrepôt de données sous PostgreSQL. Le septième chapitre présente les modèles de Machine Learning développés. Le huitième chapitre décrit le cockpit décisionnel réalisé avec Knowage BI et les indicateurs qui y sont restitués. Enfin, le neuvième chapitre présente l'application web développée et propose une démonstration complète de la solution, avant

de conclure sur les apports du projet et ses perspectives d'évolution.

Chapter 1

Contexte général du projet

1.1 Introduction

Ce chapitre situe le projet dans son contexte organisationnel et technique. Il présente l'organisme d'accueil, la problématique à l'origine du projet, les objectifs poursuivis, la méthodologie de conduite de projet retenue ainsi que la planification adoptée.

1.2 Organisme d'accueil

Le CETUD (Conseil Exécutif des Transports Urbains de Dakar) est l'autorité organisatrice des transports urbains pour la région de Dakar. Sa mission consiste à planifier, organiser et réguler l'offre de transport public sur le territoire de l'agglomération dakaroise, en coordonnant les différents opérateurs (bus, cars rapides, transport informel) et en veillant à l'amélioration continue de l'accessibilité et de la qualité de service offerte aux usagers.

Dans le cadre de ses missions de planification, le CETUD réalise et exploite des enquêtes de grande ampleur, notamment l'Enquête Ménages-Déplacements (EMD), ainsi que des campagnes de comptage de trafic sur les principaux axes et points névralgiques du réseau. Ces données constituent un patrimoine informationnel considérable, mais dont l'exploitation reste aujourd'hui largement manuelle et ponctuelle.

1.3 Problématique

La problématique générale ayant motivé ce projet peut être formulée ainsi :

Comment exploiter efficacement un grand volume de données hétérogènes issues du système de transport urbain afin de fournir une vision globale, pertinente et en temps réel des flux de transport, et ainsi améliorer la prise de décision et l'optimisation du réseau de transport urbain ?

Cette problématique se décline en plusieurs questions opérationnelles :

- Comment garantir la qualité, la fiabilité et la cohérence de données collectées depuis des sources multiples et hétérogènes (enquêtes terrain, comptages automatiques) ?

- Comment structurer ces données pour qu'elles soient directement exploitables dans des indicateurs décisionnels ?
- Comment restituer ces indicateurs de façon claire et actionnable aux différents profils de décideurs du CETUD ?
- Comment aller au-delà du simple reporting descriptif, en exploitant les données pour anticiper (segmentation des usagers, détection d'anomalies, prédiction des zones à risque) ?

1.4 Objectifs du projet

Pour répondre à cette problématique, le projet poursuit les objectifs suivants :

1. **Compréhension métier et données** : analyser les sources de données disponibles (EMD, comptages de trafic) et identifier les besoins des différents profils de décideurs du CETUD.
2. **Modélisation décisionnelle** : concevoir un modèle multidimensionnel (schéma en constellation) capable de répondre aux besoins analytiques identifiés.
3. **Mise en œuvre de l'ETL** : industrialiser la collecte, le nettoyage et le chargement des données dans l'entrepôt de données à l'aide de Talend.
4. **Implémentation de l'entrepôt de données** : déployer un entrepôt de données sous PostgreSQL conforme au modèle décisionnel conçu.
5. **Visualisation et restitution** : développer des tableaux de bord interactifs avec Knowage BI permettant le suivi des indicateurs clés.
6. **Enrichissement par le Machine Learning** : développer des modèles prédictifs et de segmentation pour aller au-delà du reporting descriptif.
7. **Intégration applicative** : exposer l'ensemble de la solution à travers une application web destinée aux usagers et aux décideurs.

1.5 Méthodologie de conduite de projet

La conduite du projet s'est appuyée sur la méthodologie GIMSI (Generalized Indicator for Management of Strategic Information), une démarche structurée en quatre étapes destinée à la construction de systèmes de tableaux de bord : identification, conception, mise en œuvre et amélioration permanente. Cette méthodologie a guidé en particulier la

démarche de définition des indicateurs en partant de l'identification des décideurs et de leurs objectifs métier, plutôt que de partir directement des données disponibles.




Figure 1.1: Méthodologie GIMSI appliquée à la construction du système décisionnel

Sur le plan du développement logiciel, une approche itérative inspirée de Scrum a été adoptée : le projet a été découpé en cycles courts correspondant chacun à une brique de la chaîne décisionnelle (analyse, modélisation, ETL, entrepôt, restitution, Machine Learning, application web), avec des points d'avancement réguliers avec l'encadrant professionnel du CETUD.

1.6 Planification du projet

Le projet s'est déroulé sur une période de six mois, structurée selon le planning prévisionnel suivant :




Figure 1.2: Diagramme de Gantt du projet

Cette planification distingue huit grandes phases : l'analyse métier et données, la définition des décideurs et des KPIs, la conception de l'architecture Big Data / BI, la modélisation des données, l'implémentation de l'ETL, la visualisation et l'analyse BI, les corrections et la validation finale, et enfin la clôture du projet.

1.7 Conclusion

Ce chapitre a permis de poser le cadre général du projet : l'organisme d'accueil, la problématique traitée, les objectifs visés et la démarche méthodologique suivie. Le chapitre suivant présente en détail l'environnement de travail technique mobilisé pour la réalisation de ce projet.

Chapter 2

Environnement de travail

2.1 Introduction

Ce chapitre présente l'ensemble des outils, langages et technologies utilisés pour la réalisation de ce projet, depuis le prétraitement des données brutes jusqu'au déploiement de l'application web finale. Le choix de ces outils répond à des contraintes de robustesse (sources de données volumineuses et hétérogènes), d'interopérabilité (chaîne ETL → entrepôt → restitution) et de coût (solutions open source).

2.2 Vue d'ensemble de la chaîne technique

La figure 2.1 résume l'architecture globale de la solution, qui s'organise en cinq niveaux successifs : la source de données, le prétraitement, l'ETL, l'entrepôt de données et la restitution décisionnelle.



Figure 2.1: Architecture globale de la chaîne décisionnelle

2.3 Environnement de prétraitement des données

2.3.1 Python

Python a été utilisé pour l'ensemble des traitements de préparation, de nettoyage et d'exploration des données (librairies `pandas`, `numpy`), ainsi que pour le développement des modèles de Machine Learning (`scikit-learn`). Son écosystème riche et sa simplicité d'utilisation en font un outil de référence pour la science des données.

2.3.2 Google Colab

Google Colab a été utilisé comme environnement de notebooks en ligne pour le développement et l'exécution des scripts Python de prétraitement et de modélisation, sans nécessiter de configuration locale et en profitant d'un accès simplifié au stockage cloud.



Figure 2.2: Python et Google Colab

2.4 Outil ETL : Talend

Talend Open Studio a été retenu pour l'industrialisation du processus d'extraction, de transformation et de chargement (ETL) des données vers l'entrepôt. Cet outil graphique permet de concevoir des *jobs* sous forme de flux de composants (lecture de fichiers, transformations `tMap`, chargement en base), facilitant la traçabilité et la maintenance du pipeline de données. Le détail des jobs développés est présenté au chapitre 5.



Figure 2.3: Talend Open Studio

2.5 Système de gestion de base de données : PostgreSQL

PostgreSQL a été choisi comme système de gestion de base de données relationnelle pour l'implémentation physique de l'entrepôt de données. Système open source robuste, il offre

un bon compromis entre performance, richesse fonctionnelle (typage avancé, fonctions analytiques) et facilité d'administration via l'outil pgAdmin, qui a été utilisé pour la création et la vérification des tables de dimensions et de faits (voir chapitre 6).



Figure 2.4: PostgreSQL

2.6 Plateforme de restitution décisionnelle : Knowage

Knowage est une suite open source de Business Intelligence permettant de construire des tableaux de bord interactifs (*cockpits*), des requêtes ad hoc et des analyses multidimensionnelles directement connectées à l'entrepôt de données. Cette plateforme a été utilisée pour concevoir l'ensemble des cockpits décisionnels du projet (Accueil, Trafic, Déplacements, Démographie, Accessibilité, Intelligence Artificielle), détaillés au chapitre 8.



Figure 2.5: Knowage BI

2.7 Développement de l'application web

2.7.1 FastAPI

FastAPI est un framework Python moderne et performant pour la conception d'API REST. Il a été utilisé pour exposer côté serveur les données de l'entrepôt, les résultats des modèles de Machine Learning (segmentation, détection d'anomalies, prédiction d'inaccessibilité) ainsi que les fonctionnalités de planification d'itinéraires, consommées par l'application web.



Figure 2.6: FastAPI

2.7.2 React

React, bibliothèque JavaScript pour le développement d'interfaces utilisateurs, a été utilisé pour la réalisation du frontend de l'application : espace public usager (réseau de bus, itinéraires, planning, cellule d'écoute) et espace décideurs sécurisé (cockpit intégré, zones à risque, rapports PDF). L'animation des interfaces a été enrichie grâce à la librairie `framer-motion` et les icônes via `lucide-react`.




Figure 2.7: React

2.8 Méthodologie de gestion de projet : Scrum

Si la méthodologie GIMSI a structuré la démarche *décisionnelle* du projet (de l'identification des besoins à la restitution), la conduite *opérationnelle* du développement s'est quant à elle appuyée sur des principes inspirés du cadre agile **Scrum**, adaptés au contexte d'un projet de fin d'études mené en autonomie.

- **Sprints** : le projet a été découpé en itérations courtes (1 à 2 semaines), chacune centrée sur une brique fonctionnelle de la chaîne décisionnelle (analyse des besoins, modélisation, ETL, entrepôt, Machine Learning, cockpit Knowage, application web), plutôt que sur un développement séquentiel monolithique.
- **Backlog de produit** : les besoins exprimés par les décideurs (chapitre 3) ainsi que les retours obtenus en cours de projet ont été traduits en un backlog de tâches priorisées, réévalué à chaque itération – c'est notamment ce backlog qui a conduit à l'ajout, en cours de projet, de la quatrième table de faits **Fait_Accessibilite** (cf. chapitre 4).
- **Revues de sprint** : l'encadrant professionnel du CETUD a tenu le rôle assimilable à celui de *Product Owner*, validant à intervalles réguliers les livrables intermédiaires (maquettes de tableaux de bord, premières versions du modèle décisionnel, prototypes de l'application web) et orientant les itérations suivantes.
- **Amélioration continue** : chaque itération s'est conclue par une forme de rétrospective informelle, donnant lieu à des actions correctives concrètes – harmonisation

des couleurs et de la navigation des widgets Knowage, redesign successif des feuillets du cockpit, ou encore corrections de cohérence des données identifiées au fil du projet (volumétrie EMD, nombre de tables de faits).

Cette approche itérative et incrémentale, bien qu'adaptée à un contexte de travail individuel, a permis de livrer des versions fonctionnelles à chaque étape et d'intégrer les retours au plus tôt, plutôt que de découvrir des écarts uniquement en fin de projet.



Figure 2.8: Méthodologie agile Scrum

2.9 Synthèse

Le tableau 2.1 récapitule les outils utilisés par étape de la chaîne décisionnelle.

Table 2.1: Synthèse de l'environnement de travail

Étape	Outil(s)
Source de données	Fichiers Excel / CSV (Enquête EMD, comptages)
Prétraitement & Machine Learning	Python, Google Colab, scikit-learn, pandas
ETL	Talend Open Studio
Entrepôt de données	PostgreSQL, pgAdmin
Restitution décisionnelle	Knowage BI
Backend applicatif	FastAPI
Frontend applicatif	React, framer-motion
Gestion de projet	Scrum (itératif), méthodologie GIMSI

Chapter 3

Analyse métier et spécification des besoins

3.1 Introduction

Conformément à la première étape de la méthodologie GIMSI (identification), ce chapitre présente l'analyse métier menée en amont de toute modélisation technique : identification des décideurs cibles, de leurs besoins respectifs, et des données sources disponibles pour y répondre.

3.2 Les données sources

La principale source de données exploitée est l'**Enquête Ménages-Déplacements (EMD)** de Dakar, complétée par des données de **comptage de trafic** issues de capteurs et de relevés sur les principaux sites de comptage du réseau. L'EMD est structurée en plusieurs blocs de variables, identifiées par des codes (I2, I4, I9, M21, M26, M66 à M91, etc.), couvrant :

- les caractéristiques géographiques du domicile (quartier, strate, district de recensement) ;
- les caractéristiques du ménage (taille, type de logement, équipement) ;
- les déplacements individuels (motif, mode, durée, coût) ;
- l'accessibilité aux transports en commun et aux services (école, daara) ;
- les problèmes et manquements perçus dans le quartier (manque de transport, inondations, enclavement, insécurité).

Il s'agit de **données réelles, fournies par le CETUD** (Conseil Exécutif des Transports Urbains de Dakar, Sénégal), et non de données simulées ou synthétiques. Elles sont livrées sous deux formats : des fichiers **Excel (.xls/.xlsx)** pour les exports bruts de l'enquête (*CETUD_BD_EMD_MENAGE_COMPILE*, *CETUD_BD_EMD_INDIVIDU_COMPILE*, *CETUD_BD_EMD_DEPLACEMENT_COMPILE*), et des fichiers **CSV** pour les extractions et versions renommées/transformées utilisées en entrée du processus ETL (*Menage.csv*,

Individu.csv, *Deplacement.csv*, *Trafic.csv*). Ces fichiers sources comportent une volumétrie réelle conséquente : 3 176 ménages, 13 415 individus, 45 599 déplacements déclarés et 37 248 relevés de comptage de trafic sur 49 sites, avec plusieurs centaines de variables brutes par table (jusqu'à 231 colonnes pour le fichier Ménage). Un travail préalable de découverte des données (data discovery), incluant la détection des valeurs manquantes et des valeurs aberrantes, a été mené sur ces fichiers sources avant toute modélisation ; il est détaillé dans le notebook d'exploration fourni en annexe (section A.1) ainsi que dans le dictionnaire de données du dossier *CETUD DATA*.

3.3 Identification des décideurs et de leurs besoins

Deux profils de décideurs principaux ont été identifiés au sein du CETUD, chacun ayant des besoins analytiques distincts vis-à-vis des mêmes données sources.

3.3.1 Le directeur de planification

C'est l'utilisateur principal des données décisionnelles. Il doit planifier les lignes de transport, adapter l'offre à la demande et comprendre les habitudes de mobilité des citoyens. Il s'appuie en particulier sur les volumes de déplacements par jour, le type d'habitation et les indicateurs d'équipement et d'accès des ménages.

- **Objectifs** : identifier les zones à forte densité de déplacements, les jours les plus chargés, et les types de zones les plus mobiles.
- **KPIs associés** : nombre moyen de déplacements par jour, mobilité par type d'habitation.

3.3.2 Le responsable d'exploitation

Ce décideur gère les aspects opérationnels du réseau : lignes de bus, fréquences, horaires. Il exploite les volumes de déplacements et leur répartition journalière pour ajuster l'offre.

- **Objectifs** : ajuster les horaires et la fréquence des bus, gérer les heures de pointe.
- **KPIs associés** : pic de déplacements par jour, charge moyenne par créneau horaire.

Table 3.1: Synthèse des décideurs et de leurs usages des données

Décideur	Usage	Objectif
Directeur de planification	Stratégique	Planifier l'offre, comprendre la demande
Responsable d'exploitation	Opérationnel	Ajuster horaires et fréquences

Au-delà de ces deux profils, des besoins analytiques plus avancés ont également été identifiés : segmentation des ménages selon leur profil de mobilité et prédiction des zones à risque d'inaccessibilité. Ces besoins ne correspondent pas à un profil de décideur distinct mais à une couche d'analyse transversale, enrichissant les tableaux de bord mis à disposition du directeur de planification et du responsable d'exploitation ; ils ont été couverts par les modèles de Machine Learning présentés au chapitre 7.

3.4 Spécification des indicateurs clés (KPIs)

À partir de cette analyse, un score d'accessibilité composite a été défini afin de quantifier, pour chaque ménage ou zone, la qualité de la desserte en transport en commun. Ce score (noté de 0 à 100) intègre :

- une pénalité liée à la durée de marche jusqu'à l'arrêt de transport en commun le plus proche (jusqu'à -40 points) ;
- un bonus lié à la diversité des modes de transport en commun disponibles (jusqu'à $+20$ points) ;
- une pénalité en cas de zone inondable (-25 points), aggravée si aucun mode de transport ne reste disponible en cas de pluie (-20 points supplémentaires) ;
- une pénalité en cas de tarification abusive en période de pluie (-15 points).

Ce score permet de classer chaque zone selon une typologie à quatre niveaux : *Bien desservie* (≥ 75), *Moyenne* (≥ 50), *Sous-desservie* (≥ 25) et *Critique* (< 25). Un indicateur complémentaire de **vulnérabilité climatique** a également été défini, combinant l'exposition aux inondations, l'absence de transport en cas de pluie et la pratique de tarifs abusifs.

Par ailleurs, un indicateur d'**impact sur l'éducation** a été spécifié à partir des difficultés d'accès déclarées aux structures scolaires (école primaire, daara), permettant de mesurer le lien entre accessibilité aux transports et accès aux services essentiels.

3.5 Priorisation des données à intégrer

Afin de structurer le développement de l'ETL de façon incrémentale, une priorisation en trois phases des colonnes sources a été retenue :

1. **Phase 1 – MVP** : colonnes géographiques (I2, I4, I9), accessibilité de base (M66 à M70), problèmes majeurs (M73, M87) et taille du ménage (M21) ;

2. **Phase 2 – Extension services** : variables d'accès aux écoles et daaras (M90, M91) ;
3. **Phase 3 – Détails avancés** : variables de résilience en cas de pluie (M69), modes de transport vers les services, et autres problèmes de quartier (bruit, insécurité, accidents).

Cette priorisation a directement guidé la conception du modèle décisionnel et la construction progressive des jobs Talend, présentées dans les chapitres suivants.

3.6 Conclusion

L'analyse métier a permis d'identifier précisément les décideurs cibles, leurs besoins et les indicateurs à produire, ainsi qu'une stratégie de priorisation des données à intégrer. Ces éléments constituent le cahier des charges fonctionnel à partir duquel le modèle décisionnel, présenté au chapitre suivant, a été conçu.

Chapter 4

Conception du modèle décisionnel

4.1 Introduction

Conformément à la deuxième étape de la méthodologie GIMSI (conception), ce chapitre présente la modélisation multidimensionnelle retenue pour l'entrepôt de données. Le choix s'est porté sur un **schéma en constellation**, c'est-à-dire un modèle comportant plusieurs tables de faits partageant un ensemble commun de dimensions, ce qui correspond naturellement aux quatre processus métier identifiés : le comptage de trafic, les déplacements individuels, les caractéristiques des ménages et l'accessibilité aux transports et services.

4.2 Choix du schéma en constellation

Contrairement à un schéma en étoile classique (une seule table de faits), le schéma en constellation permet de modéliser plusieurs processus métier distincts tout en mutualisant les dimensions communes (temps, géographie). Ce choix est justifié par la nature du projet : les données de comptage de trafic (issues de capteurs), les données d'enquête ménages-déplacements et les données d'accessibilité ont des granularités et des cycles de mise à jour différents, mais partagent des axes d'analyse communs (site, zone géographique, ménage).

Le modèle retenu comporte :

- **4 tables de faits** : `Fait_Comptage`, `Fait_Deplacement`, `Fait_IndividuMenage`, `Fait_Accessibilite` ;
- **10 dimensions** : `Dim_Site`, `Dim_Temps`, `Dim_Motif`, `Dim_Individu`, `Dim_Mode`, `Dim_Menage`, `Dim_Geographie`, `Dim_Service`, `Dim_Difficulte`, `Dim_Transport`.

La quatrième table de faits, `Fait_Accessibilite`, a été ajoutée après une première itération du modèle, lorsque l'analyse des besoins des décideurs a mis en évidence un besoin spécifique de restitution autour de l'accessibilité aux services (éducation, santé, commerce, administration) et des difficultés rencontrées par les ménages ; trois nouvelles dimensions (`Dim_Service`, `Dim_Difficulte`, `Dim_Transport`) ont été créées pour la qualifier. Cette évolution illustre concrètement la quatrième étape de la méthodologie GIMSI (amélioration permanente) : le modèle décisionnel n'a pas été figé dès la conception initiale mais a été enrichi en cours de projet pour mieux répondre aux besoins identifiés.




Figure 4.1: Schéma en constellation du modèle décisionnel (4 faits, 10 dimensions)

4.3 Description des tables de faits

4.3.1 Fait_Comptage

Cette table enregistre les mesures issues des dispositifs de comptage automatique de trafic, à la granularité du site et de l'heure.

- **Clés étrangères** : FK_id_Site, FK_id_temps
- **Mesures** : nb_vehicules, volume horaire (matin / soir), flux entrant, flux sortant, désagrégation directionnelle, volume par sens

4.3.2 Fait_IndividuMenage

Cette table croise les informations individuelles et celles du ménage, à la granularité de l'individu enquêté.

- **Clés étrangères** : FK_id_individu, FK_id_menage, FK_id_zone_residence
- **Mesures** : nombre de déplacements journaliers, taux d'équipement en voiture, nombre de voitures, taux de motorisation, mobilité des seniors, mobilité par zone

4.3.3 Fait_Deplacement

Cette table décrit chaque déplacement individuel déclaré, à la granularité du déplacement.

- **Clés étrangères** : FK_id_Dep, FK_id_motif, FK_id_mode, FK_id_zone_residence
- **Mesures** : durée du trajet, heure de départ, heure d'arrivée, coût total, temps de parcours par motif, corrélation temps / coût

4.3.4 Fait__Accessibilite

Cette table porte les mesures relatives à l'accessibilité aux transports en commun et aux services de proximité, à la granularité du ménage.

- **Clés étrangères** : FK_id_menage, FK_id_transport, FK_id_zone_residence, FK_id_difficulte, FK_id_service
- **Mesures** : fréquence d'inondation, manque de transport déclaré, variation du tarif en saison des pluies, nombre de pièces du logement, durée d'accès à l'eau, dépenses du ménage, ancienneté du logement, durée d'accès au transport en commun

4.4 Description des dimensions

Table 4.1: Dictionnaire des dimensions du modèle décisionnel

Dimension	Attributs principaux	Granularité
Dim_Site	id_Site, code_site, Ouvl_Soc, catégorie_unité, DESC_Site, Sens	Site de comptage
Dim_Temps	id_temps, année, MOIS, jour, heure, heure début/fin déplacement	Heure / jour
Dim_Motif	id_motif, code_motif, motif_origine	Motif de déplacement
Dim_Individu	id_individu, num_individu, sexe, statut matrimonial, profession, possession permis	Individu
Dim_Mode	id_mode, code_mode, libellé, catégorie_mode	Mode de transport
Dim_Menage	id_menage, num_menage, statut occupation, type logement, a_eau, a_electricité, a_internet	Ménage
Dim_Geographique	id_zone_residence, code_zone, quartier, strate, département, difficultés	Zone géographique
Dim_Service	pk_id_service, code_service, libellé court/long, catégorie (Éducation, Santé, Commerce, Administration), actif	Type de service de proximité
Dim_Difficulte	pk_id_difficulte, code_difficulte, libellé court/long, catégorie (Accessibilité, Transport, Économique, Qualité), lié au transport	Type de difficulté déclarée
Dim_Transport	pk_id_transport, code_transport (19 modalités : à pied, car rapide, Ndiaga Ndiaye, taxi, TATA, etc.)	Mode de transport utilisé

4.5 Indicateurs calculés

Au-delà des mesures directement issues des sources, plusieurs indicateurs calculés ont été intégrés au modèle ou dérivés lors du chargement : le *score d'accessibilité* (0 à 100), la *vulnérabilité climatique* (0 à 5), l'*impact sur l'éducation*, le *taux de motorisation des ménages* et la *mobilité des seniors*. Ces deux derniers indicateurs n'ont pu être renseignés que partiellement, la donnée source correspondante étant absente ou incomplète dans l'EMD exploitée.

4.6 Conclusion

Le modèle décisionnel en constellation conçu dans ce chapitre constitue le socle structurel de l'entrepôt de données. Il répond directement aux besoins analytiques identifiés au chapitre précédent tout en assurant la cohérence entre les quatre processus métier modélisés. Le chapitre suivant détaille la mise en œuvre du processus ETL permettant d'alimenter ce modèle à partir des sources de données brutes.

Chapter 5

Mise en œuvre de l'ETL avec Talend

5.1 Introduction

Ce chapitre détaille la mise en œuvre du processus ETL (Extract-Transform-Load) permettant d'alimenter l'entrepôt de données à partir des sources brutes (fichiers Excel/CSV issus de l'EMD et des comptages de trafic, préalablement nettoyés sous Python/Colab). L'outil Talend Open Studio a été utilisé pour concevoir cette chaîne sous forme de *jobs* graphiques.

5.2 Architecture générale de l'ETL

La chaîne ETL est organisée en deux niveaux successifs :

1. une **zone de préparation (Staging Area, SA)** : jobs chargeant les données brutes nettoyées dans des tables intermédiaires, sans transformation lourde ;
2. une **zone de chargement final** : jobs lisant les tables de la Staging Area, appliquant les transformations, jointures et calculs nécessaires (via le composant `tMap`), puis chargeant les dimensions et les faits dans l'entrepôt de données (DW).

5.3 Zone de préparation (Staging Area)

Trois jobs principaux assurent l'alimentation de la zone de préparation : `SA_individu`, `SA_menage` et `SA_deplacement`, correspondant aux trois grandes entités sources de l'EMD (individus, ménages, déplacements). Chaque job suit un schéma simple : lecture du fichier source, filtrage des colonnes utiles via `tFilterColumns`, puis chargement dans la base via `tDBOutput`.





Figure 5.1: Job Talend de chargement de la Staging Area – déplacements

5.4 Configuration des dimensions

La configuration des dimensions géographiques et de site illustre la logique de mapping utilisée pour la construction des tables de référence de l'entrepôt.



(a) Configuration de Dim_Site

(b) Chargement de Dim_Geographie

Figure 5.2: Jobs de construction des dimensions de référence

De même, les dimensions `Dim_Individu` et `Dim_Menage` sont alimentées par des jobs dédiés, reprenant les données nettoyées issues de la Staging Area correspondante.

5.5 Construction des tables de faits

5.5.1 Fait_Deplacement

Le job `Job_deplacement` illustre la logique de transformation appliquée pour construire la table de faits `Fact_deplacement`. Le composant `tMap` central réalise les opérations suivantes (figure 5.3) :

- récupération du flux principal (**row1**) contenant les attributs du déplacement (numéro de ménage, numéro d'individu, lieux et heures de départ/arrivée, durée, motif, fréquence de transport en commun, mode, coût total) ;
- trois jointures (*lookup*) sur les dimensions Dim_Motif (par motif), Dim_Individu (par clé composite num_individu + num_menage) et Dim_Mode (par mode) afin de résoudre les clés étrangères ;
- construction du flux de sortie **fact_deplacement** combinant les clés étrangères résolues (fk_id_motif, fk_id_individu, fk_id_transport) et les mesures (durée du trajet, lieux, coût total, heures de départ/arrivée, fréquence de transport en commun).




Figure 5.3: Composant tMap du job de construction de **Fact_deplacement**

5.5.2 Fait__Comptage

Le job de construction de **Fact_Comptage** suit une logique similaire : une entrée principale (tDBInput_1) portant les mesures de comptage est enrichie par deux jointures de référence (tDBInput_2, tDBInput_3) via un composant tMap_1, avant chargement final dans la table **fact_comptage** de l'entrepôt.




Figure 5.4: Job Talend de construction de Fact_Comptage

5.5.3 Fait_Accessibilité et Fait_IndividuMenage

Les jobs `fact_accessibilite` et `fact_indivmen` suivent le même schéma général, en exploitant respectivement les variables d'accessibilité (durée de marche, modes de transport disponibles, exposition aux inondations) et les variables croisées individu/ménage (taille du ménage, équipement, motorisation).

5.6 Composants Talend mobilisés

Le tableau 5.1 récapitule les principaux composants Talend utilisés dans les différents jobs.

Table 5.1: Composants Talend utilisés

Composant	Rôle
tFileInputExcel / tFileInputDelimited	Lecture des fichiers sources (EMD, comptages)
tFilterColumns	Sélection des colonnes utiles (priorisation MVP)
tMap	Jointures, transformations et calculs de mesures
tDBInput	Lecture de tables intermédiaires / dimensions
tDBOutput	Chargement dans la Staging Area ou l'entrepôt

5.7 Conclusion

Le processus ETL conçu avec Talend assure une alimentation fiable et traçable de l'entrepôt de données, en respectant la priorisation des données définie au chapitre 3 et le modèle décisionnel conçu au chapitre 4. Le chapitre suivant présente l'implémentation physique de cet entrepôt sous PostgreSQL.

Chapter 6

Implémentation de l'entrepôt de données

6.1 Introduction


Ce chapitre présente l'implémentation physique de l'entrepôt de données sous PostgreSQL, ainsi que la vérification de sa structure à l'aide de l'outil pgAdmin, conformément au modèle décisionnel conçu au chapitre 4.

6.2 Choix d'implémentation

L'entrepôt de données a été déployé dans un schéma dédié (DW) au sein d'une base PostgreSQL. Chaque table de dimension est préfixée `Dim_` et chaque table de faits `Fact_`, conformément aux conventions de nommage usuelles en modélisation décisionnelle. Les clés primaires des dimensions sont des entiers auto-incrémentés (`PK_id_...`), repris en clé étrangère dans les tables de faits (`FK_id_...`).

6.3 Structure physique des tables de faits

La table `Fact_Comptage` a été vérifiée directement via une requête sur le catalogue système `information_schema.columns`, confirmant la structure suivante :



```
1 SELECT column_name, data_type
2 FROM information_schema.columns
3 WHERE table_name = 'Fact_comptage';
```

	column_name name	data_type character varying
1	PK_id_Comptage	integer
2	FK_id_site	integer
3	FK_id_temps	integer
4	GPS_X	double precision
5	GPS_Y	real
6	Amplitude	integer
7	VOLUME_SECT	integer

Figure 6.1: Structure de la table **Fact_Comptage** (pgAdmin)

Cette table comporte les clés étrangères **FK_id_site** et **FK_id_temps**, ainsi que les mesures **GPS_X**, **GPS_Y**, **Amplitude** et **Volume_Sect**, confirmant la granularité site/heure retenue dans la conception.

De même, les tables **Fact_deplacement** et **Fact_indivMen** ont été contrôlées afin de s'assurer de la cohérence entre le modèle conceptuel et son implémentation physique, et corrigées si nécessaire (ajout de colonnes manquantes, correction de types).

Query Query History

```
1 SELECT column_name, data_type
2 FROM information_schema.columns
3 WHERE table_name = 'Fact_Deplacement';
```

Data Output Messages Notifications

	column_name	data_type
1	PK_id_Dep	integer
2	fk_id_motif	integer
3	fk_id_individu	integer
4	num_individu	character varying
5	duree_trajet	character varying
6	Nom_depart	character varying
7	Nom_arrivee	character varying
8	freq_tc	character varying
9	heure_depart	character varying
10	heure_arrivee	character varying
11	fk_id_transport	integer
12	cout_total	character varying
13	num_menage	character varying

Query Query History

```
1 SELECT column_name, data_type
2 FROM information_schema.columns
3 WHERE table_name = 'Fact_individuMenage';
```

Data Output Messages Notifications

	column_name	data_type
1	PK_id_IndivMen	integer
2	FK_id_individu	integer
3	age	character varying
4	num_menage	character varying
5	nb_deplacements	integer
6	abonnement_tc	character varying
7	type_vehicule	character varying

Figure 6.2: Structures des tables Fact_deplacement et Fact_indivMen

6.4 Structure physique des dimensions

La dimension géographique (Dim_Geographie) illustre la richesse du référentiel mis en place : elle recense 507 zones de résidence, chacune associée à une strate et un quartier de domicile, permettant l'agrégation de tous les indicateurs à différents niveaux géographiques.

Query Query History

```
1 SELECT * FROM 'DW'. 'Dim_Geographie'
2 ORDER BY pk_id_zone_residence ASC
```

Data Output Messages Notifications

	Strate	Quartier_du_domicile	pk_id_zone_residence
1	MALIKA/YEUMBEUL NORD	262	1
2	PLATEAU	58	2
3	MEDINA/GOUNASS	119	3
4	MALIKA/YEUMBEUL NORD	260	4
5	CAMBERENE	5	5
6	DJIDAH/THIAROYE/KAQ/YEUMB SUD	230	6
7	GUINAW RAIL N - S/PIKINE OUEST	256	7
8	SAM NOTAIRES	122	8
9	OIAKAM	44	9
10	DALIFORD	208	10
11	FANN/POINT E/AMITIE	14	11
12	RUFISQUE EST	328	12
13	JAXAAY PARCELLE NIAKOUL RAP TIVAOUANE PEULH-NIAGHA	311	13
14	MEDINA	35	14
15	MEDINA/GOUNASS	116	15
16	GRAND YOFF	7	16
17	PATTE D'OIE	54	17
18	HANN/BEL AIR	63	18

Total rows: 507 Query complete 00:00:00.330

Figure 6.3: Extrait de la table Dim_Geographie (507 zones)

Les autres dimensions (Dim_Individu, Dim_Menage, Dim_Site, Dim_Motif, Dim_Temps) ainsi que deux dimensions complémentaires créées pour les besoins de l'analyse d'accessibilité (Dim_Service et Dim_Difficulte, Dim_Transport) ont été vérifiées de la même façon.

Figure 6.4: Vérification des dimensions Dim_Menage, Dim_Individu et Dim_Site

6.5 Table de faits dédiée à l'accessibilité

Une table `fact_access` a été ajoutée au modèle initial afin de porter spécifiquement les mesures liées à l'accessibilité aux transports en commun et aux services (score d'accessibilité, durée de marche, nombre de modes disponibles, indicateur de zone inondable), en lien avec les dimensions Dim_Difficulte, Dim_Service et Dim_Transport.

Query Query History

```
1 SELECT column_name, data_type
2 FROM information_schema.columns
3 WHERE table_name = 'Fact_accessibilite';
```

Data Output Messages Notifications

	column_name	data_type
	name	character varying
1	PK_id_accessibilite	integer
2	fk_id_menage	integer
3	fk_id_transport	integer
4	fk_id_zone_reside...	integer
5	fk_id_difficulte	integer
6	fk_id_service	integer
7	freq_inondation	character varying
8	manque_transport	character varying
9	variation_tarif_pluie	character varying
10	nb_pieces	character varying
11	duree_acces_eau	character varying
12	depenses_menage	character varying
13	anciennete_loge...	character varying
14	duree_tc	character varying

Figure 6.5: Structure de la table `fact_access`

6.6 Administration et contrôle qualité

L'outil pgAdmin a été utilisé tout au long du projet pour : vérifier la structure des tables après chaque chargement Talend, contrôler les volumes chargés, détecter les valeurs manquantes ou aberrantes, et exécuter des requêtes SQL de contrôle qualité (cohérence des clés étrangères, doublons, valeurs hors plage). Ce contrôle a notamment permis d'identifier l'absence de données fiables pour le taux de motorisation des ménages et la mobilité des seniors, indicateurs qui n'ont donc pu être que partiellement renseignés.

6.7 Conclusion

L'entrepôt de données PostgreSQL constitue le socle physique fiable sur lequel s'appuient l'ensemble des restitutions décisionnelles et des modèles de Machine Learning présentés dans les chapitres suivants. Le chapitre suivant détaille les modèles de Machine Learning développés pour enrichir l'analyse au-delà du reporting descriptif.

Chapter 7

Modèles de Machine Learning

7.1 Introduction

Au-delà du reporting descriptif assuré par l'entrepôt de données et le cockpit Knowage, le projet intègre quatre familles de modèles de Machine Learning afin de répondre à des besoins analytiques plus avancés : segmenter les usagers, recommander un mode de transport personnalisé, détecter les anomalies de trafic et prédire les zones à risque d'inaccessibilité. Ce chapitre présente la démarche, les algorithmes retenus et les performances obtenues pour chacun de ces quatre modèles.

Contrairement aux indicateurs de reporting, qui sont calculés à partir de l'entrepôt de données, les modèles de Machine Learning sont entraînés directement à partir des extraits sources de l'EMD (fichiers Excel/CSV bruts, après nettoyage). Ce choix est délibéré : l'entrepôt de données a été modélisé pour répondre aux besoins de restitution décisionnelle (schéma en constellation, mesures agrégées par dimension), tandis que les modèles ML nécessitent l'ensemble des variables individuelles brutes de l'enquête (plus de 200 variables par individu/ménage) pour la sélection et la construction de features, variables qui n'ont pas vocation à être intégrées telles quelles dans un schéma dimensionnel. Ce découplage permet en outre de faire évoluer les modèles (sélection de variables, ré-entraînement) sans dépendre du schéma figé de l'entrepôt ni modifier le pipeline ETL à chaque expérimentation. Les résultats produits par ces modèles (scores d'accessibilité, segments, anomalies) sont en revanche réinjectés dans l'entrepôt – notamment via la table `fact_access` présentée au chapitre 6 – afin d'être restitués aux décideurs dans le cockpit Knowage et l'application web.

7.2 Segmentation des usagers (K-Means)

7.2.1 Objectif et données

L'objectif est de regrouper les individus enquêtés (données EMD) en profils de mobilité homogènes, afin de permettre des analyses et des recommandations différenciées par segment. Les données utilisées sont les variables sociodémographiques et de mobilité de l'enquête individus (âge, sexe, statut d'activité, niveau d'instruction, possession du permis, fréquence d'utilisation des transports en commun, nombre de déplacements, nombre

de véhicules, revenu).




Figure 7.1: Exploration des données individus avant segmentation

7.2.2 Choix du nombre de clusters

Le nombre optimal de clusters a été déterminé en combinant la méthode du coude (*elbow method*), qui trace l'inertie intra-cluster en fonction de k , et le coefficient de silhouette, qui mesure la qualité de séparation entre clusters. Cette double vérification a permis de retenir $k = 5$, valeur pour laquelle le coefficient de silhouette est maximal ($\approx 0,31$) tout en correspondant au coude visible sur la courbe d'inertie.




Figure 7.2: Détermination du nombre optimal de clusters (méthode du coude + silhouette)

7.2.3 Profils obtenus

Le tableau 7.1 présente les cinq segments d'utilisateurs identifiés.

Table 7.1: Segments d'utilisateurs identifiés par K-Means

Segment	Profil type	Mode dominant
Actifs TC réguliers	~35 ans, actif, sans permis, usage quotidien des TC	Transport commun
Actifs motorisés	~40 ans, actif, permis, revenu élevé	Voiture / Taxi
Étudiants mobilité douce	~20 ans, étudiant, budget faible	Marche / TC
Piétons de proximité	~45 ans, peu mobile, quartier dense	Marche
Travailleurs informels	~30 ans, actif informel, mobilité mixte	TC / Moto




Figure 7.3: Caractérisation des segments par variable (heatmap)

Avant l'application de K-Means, les variables ont été normalisées avec un `StandardScaler` afin d'éviter qu'une variable à forte variance (par exemple le revenu) ne domine artificiellement le calcul de distance euclidienne. Les valeurs manquantes ont été traitées par imputation à la médiane (robuste aux valeurs extrêmes).

7.3 Recommandation de mode de transport (Random Forest)

Le second modèle vise à recommander, pour un profil d'utilisateur donné, le mode de transport le plus adapté parmi l'ensemble des modes disponibles (transport en commun, voiture, taxi/clando, marche, moto). Il s'agit d'une tâche de classification supervisée multi-classes, entraînée à partir des modes effectivement déclarés dans l'EMD.

- **Algorithme** : `RandomForestClassifier` (scikit-learn), 200 arbres (`n_estimators=200`), profondeur maximale 10 (`max_depth=10`) pour limiter le surapprentissage, pondération des classes (`class_weight='balanced'`) pour compenser le déséquilibre entre modes.
- **Validation** : validation croisée stratifiée à 5 plis (`StratifiedKFold`).
- **Performance** : exactitude (*accuracy*) $\approx 90,6\%$, F1-macro $\approx 0,88$.

En production, le modèle retourne non pas une seule prédiction mais le *top 3* des modes les plus probables avec leurs probabilités, enrichi par des statistiques de durée et de coût (quartiles Q1/médiane/Q3) calculées par mode et par segment, ce qui permet de fournir à l'utilisateur une recommandation nuancée plutôt qu'une réponse binaire.

7.4 Détection d'anomalies de trafic

7.4.1 Démarche

Les données de comptage de trafic (issues des sites de comptage automatique) sont analysées afin de détecter des comportements anormaux : pics de volume inattendus, schémas horaires incohérents, sites présentant un comportement différent de leurs voisins géographiques. Trois algorithmes complémentaires sont appliqués en parallèle puis combinés par un vote pondéré (consensus) :

Table 7.2: Algorithmes de détection d'anomalies et pondération du consensus

Algorithme	Poids	Principe
Z-Score	0,25	Détection univariée des valeurs extrêmes par site
Isolation Forest	0,40	Détection multivariée par isolement aléatoire (arbres)
Local Outlier Factor (LOF)	0,35	Détection par densité locale (comparaison aux voisins)

Une observation est déclarée anormale lorsque le score pondéré combiné dépasse le seuil de 0,6. Cette approche par consensus permet de réduire significativement les faux positifs par rapport à l'utilisation d'un seul algorithme, chaque méthode ayant des forces complémentaires : le Z-Score est rapide et interprétable mais univarié, l'Isolation Forest est robuste sur des données multivariées sans hypothèse de distribution, et le LOF détecte les anomalies de densité locale invisibles aux deux autres méthodes.

7.4.2 Clustering spatial des anomalies

Un algorithme DBSCAN est ensuite appliqué sur les coordonnées GPS des sites détectés comme anormaux (rayon $\text{eps} \approx 500$ mètres, minimum 3 sites pour former un groupe), afin de distinguer les *hotspots* de congestion structurelle (axes durablement saturés) des incidents ponctuels et isolés.

7.5 Prédiction du risque d'inaccessibilité

7.5.1 Construction de la variable cible

Pour chaque ménage, un score composite d'inaccessibilité est construit en sommant sept indicateurs binaires dérivés des variables de l'EMD : distance à pied jusqu'à l'arrêt de transport en commun supérieure à 10 minutes, fréquence d'inondation élevée du quartier, enclavement déclaré, absence de routes carrossables, manque de transport en commun déclaré, inaccessibilité du transport en commun en cas de pluie, et durée d'accès au centre de santé supérieure à 30 minutes. Le seuil de classification (ménage à risque ou non) est fixé au 65^e percentile de ce score, valeur qui maximise l'équilibre entre précision et rappel tout en restant interprétable d'un point de vue métier.

7.5.2 Pipeline d'entraînement

Le pipeline complet comprend : l'imputation des valeurs manquantes (médiane pour les variables numériques, valeur la plus fréquente pour les variables catégorielles), l'encodage des variables catégorielles, la normalisation des variables numériques, puis un rééchantillonnage par sur-échantillonnage synthétique (SMOTE) afin de compenser le déséquilibre entre ménages à risque (minoritaires) et ménages non à risque.

Quatre algorithmes de classification ont été comparés par validation croisée stratifiée : régression logistique, Random Forest, Gradient Boosting et XGBoost. Le **Gradient Boosting** a été retenu comme modèle final, offrant les meilleures performances sur ce jeu de données déséquilibré.

Table 7.3: Performances du modèle de prédiction d'inaccessibilité (Gradient Boosting)

Métrique	Valeur
Exactitude (Accuracy)	90,6 %
ROC AUC	0,921
F1-score	0,883
Précision	$\approx 89\%$
Rappel	$\approx 88\%$

L'analyse de l'importance des variables (*feature importance*) confirme que la distance à pied jusqu'à l'arrêt de transport en commun et la durée d'accès aux soins de santé sont les déterminants principaux du risque d'inaccessibilité, en cohérence avec la littérature sur la mobilité urbaine en Afrique subsaharienne.

7.6 Synthèse

Table 7.4: Synthèse des modèles de Machine Learning développés

Modèle	Type	Objectif	Performance
K-Means ($k = 5$)	Non supervisé	Segmentation des usagers	Silhouette $\approx 0,31$
Random Forest	Supervisé	Recommandation de mode	Accuracy $\approx 90,6\%$
Z-Score + Isolation Forest + LOF	Détection d'anomalies	Anomalies de trafic	Consensus pondéré
Gradient Boosting	Supervisé	Prédiction d'inaccessibilité	ROC AUC = 0,921

L'ensemble de ces modèles a été sérialisé (`joblib`) et exposé via l'API FastAPI de l'application web, présentée au chapitre 9. Le chapitre suivant présente le cockpit décisionnel Knowage BI, dédié à la restitution des indicateurs descriptifs de l'entrepôt de données.

Chapter 8

Cockpit décisionnel Knowage BI

8.1 Introduction

Conformément à la dernière étape de la méthodologie GIMSI (mise en œuvre et amélioration permanente), ce chapitre présente le cockpit décisionnel développé avec la plateforme **Knowage**, outil de Business Intelligence open source connecté directement à l'entrepôt de données PostgreSQL. Ce cockpit restitue, sous forme de tableaux de bord interactifs, les indicateurs spécifiés au chapitre 3.

8.2 Organisation du cockpit

Le cockpit est structuré en plusieurs feuillets (*sheets*) thématiques, chacun ciblant un axe d'analyse : accueil et navigation, trafic, déplacements, démographie, et accessibilité.

8.2.1 Indicateurs de trafic

Cette section restitue les volumes de comptage agrégés par site et par tranche horaire, permettant d'identifier les heures de pointe et les sites les plus chargés du réseau.

DS_Trafic_Horaire

Detail Type Metadata Link Advanced

DataSet Type *

Query

Data Source *

CETUD_PFE

▼ Edit Query

```

1 SELECT
2   t."heure" AS heure,
3   SUM(f."VOLUME_SECT") AS volume_total
4 FROM "DW"."Fact_comptage" f
5 JOIN "DW"."Dim_Temps" t ON f."FK_id_temps" = t."pk_id_temps"
6 GROUP BY t."heure"
7 ORDER BY heure;

```

Figure 8.1: Évolution horaire du trafic

DS_Trafic_ParSite

Detail Type Metadata Link Advanced

DataSet Type *

Query

Data Source *

CETUD_PFE

▼ Edit Query

```

1 SELECT
2   s."desc_site" AS site,
3   s."sens" AS sens_circulation,
4   SUM(f."VOLUME_SECT") AS volume_total
5 FROM "DW"."Fact_comptage" f
6 JOIN "DW"."Dim_Site" s ON f."FK_id_site" = s."id_site"
7 GROUP BY s."desc_site", s."sens"
8 ORDER BY volume_total DESC;

```

▼ Edit Script

Script Language

1

DS_Trafic_ParSens

Detail Type Metadata Link Advanced

DataSet Type *

Query

Data Source *

CETUD_PFE

▼ Edit Query

```

1 SELECT
2   s."sens" AS sens_circulation,
3   SUM(f."VOLUME_SECT") AS volume_total
4 FROM "DW"."Fact_comptage" f
5 JOIN "DW"."Dim_Site" s ON f."FK_id_site" = s."id_site"
6 GROUP BY s."sens"
7 ORDER BY volume_total DESC;

```

Figure 8.2: Volume de trafic par site et par sens de circulation




Figure 8.3: Identification des heures de pointe

8.2.2 Indicateurs de déplacement

Cette section analyse les déplacements individuels déclarés : temps de parcours par motif, répartition des flux par zone et coût moyen des déplacements.





Figure 8.4: Temps de parcours par motif et coût moyen des déplacements




Figure 8.5: Flux de déplacements entre zones géographiques

8.2.3 Indicateurs démographiques

Cette section dresse le profil sociodémographique des individus enquêtés : sexe, statut matrimonial, niveau d'instruction, statut d'activité et possession du permis de conduire.




Figure 8.6: Répartition par sexe et statut matrimonial




Figure 8.7: Niveau d'instruction et statut d'activité

8.2.4 Indicateurs d'accessibilité

Cette dernière section restitue les indicateurs d'accessibilité aux services et aux transports en commun, directement issus du score d'accessibilité composite défini au chapitre 3.




Figure 8.8: Accès aux services et manque de transport déclaré




Figure 8.9: Difficultés d'accès déclarées et exposition aux inondations

8.3 Synthèse des KPIs produits

Le tableau 8.1 récapitule les principaux indicateurs clés de performance restitués dans le cockpit Knowage, calculés à partir des volumes réels de l'entrepôt de données.

Table 8.1: Synthèse des indicateurs clés restitués (cockpit Knowage)

Indicateur	Valeur
Individus enquêtés (EMD)	13 415
Ménages enquêtés (EMD)	3 176
Sites de comptage de trafic	49
Observations de trafic	37 248
Zones géographiques analysées	507

8.4 Apport du cockpit pour les décideurs

Le cockpit Knowage répond directement aux besoins des deux profils de décideurs identifiés au chapitre 3 : le directeur de planification y visualise la répartition géographique et temporelle des déplacements pour orienter ses choix stratégiques, et le responsable d'exploitation y identifie les heures de pointe pour ajuster les fréquences de desserte. Le cockpit restitue également les indicateurs d'accessibilité qui alimentent les modèles de Machine Learning présentés au chapitre 7, mis à disposition des deux décideurs pour enrichir leur analyse.

8.5 Conclusion

Le cockpit Knowage constitue le point de restitution central du système décisionnel, transformant les données brutes de l'entrepôt en informations directement exploitables par les décideurs du CETUD. Le chapitre suivant présente l'application web développée pour compléter ce dispositif, à destination à la fois des citoyens et des décideurs.

Chapter 9

Application web et démonstration de la solution

9.1 Introduction

En complément du cockpit décisionnel Knowage, une application web a été développée afin d'exposer les modèles de Machine Learning du chapitre 7 à deux publics distincts : les **citoyens**, qui consultent l'application pour obtenir une recommandation de mode de transport, et les **décideurs du CETUD**, qui disposent d'un espace dédié à l'analyse approfondie des zones à risque, des anomalies de trafic et des segments d'utilisateurs. Ce chapitre présente l'architecture technique de cette application et illustre son fonctionnement à travers ses principaux écrans.

9.2 Architecture technique

L'application repose sur une architecture client-serveur classique en trois couches :

- un **backend** développé avec **FastAPI** (Python), exposant neuf points d'accès REST, avec validation des entrées par schémas **Pydantic** et documentation interactive automatique (Swagger). Les modèles de Machine Learning, sérialisés avec **joblib**, sont chargés une seule fois au démarrage du serveur pour garantir des temps de réponse rapides ;
- un **frontend** développé avec **React.js**, organisé autour d'un routeur central (**App.js**) et d'un contexte de thème (**ThemeProvider**) gérant le mode clair/sombre ;
- une couche de **contrôle d'accès** (RBAC) distinguant les rôles *citoyen*, *directeur de planification* et *chef d'exploitation*, chacun disposant d'un périmètre fonctionnel différent.

Table 9.1: Principaux points d'accès (endpoints) de l'API

Endpoint	Fonction
POST /recommander	Recommandation de mode de transport (citoyen)
GET /zones-risque	Liste des zones à risque d'inaccessibilité
GET /zones-risque/resume	Statistiques agrégées sur les zones à risque
GET /api/anomalies/summary	Indicateurs de synthèse sur les anomalies de trafic
GET /api/anomalies/sites	Liste des sites de comptage avec score d'anomalie
GET /api/segmentation/profils	Profils des cinq segments d'utilisateurs
POST /predict-inaccessibility	Prédiction du score de risque pour un profil donné
GET /api/ml/metrics	Métriques de performance des modèles (accuracy, AUC, F1)
GET /api/ml/features-importance	Importance des variables du modèle de prédiction

9.3 Parcours citoyen

9.3.1 Page d'accueil

La page d'accueil (**WelcomePage**) présente l'application aux citoyens avec une identité visuelle dédiée (logo, palette de couleurs orange/bleu) et un point d'entrée vers le formulaire de recommandation.

9.3.2 Formulaire et recommandation

Le citoyen renseigne un court formulaire (**FormPage**) décrivant son profil de mobilité (zone de résidence, âge, statut, disponibilité d'un véhicule, fréquence des déplacements). Le formulaire applique un contrôle de saisie contextualisé : certains champs sont masqués ou adaptés en fonction de l'âge déclaré (par exemple, les champs liés au permis de conduire ne sont pas affichés pour les moins de 18 ans), afin de garantir la cohérence et la qualité des données saisies.

Ce profil est transmis à l'API (**POST /recommander**), qui retourne le *top 3* des modes de transport recommandés par le modèle Random Forest, accompagné des statistiques de durée et de coût estimées pour chaque mode.

9.4 Espace décideurs

9.4.1 Authentification et contrôle d'accès

L'accès à l'espace décideurs (**LoginDecideurs**) est protégé par une authentification distinguant deux rôles : le *directeur de planification*, qui dispose d'un accès complet incluant les pages d'analyse ML avancée, et le *chef d'exploitation*, dont l'accès est restreint aux tableaux de bord opérationnels (sans les pages de transparence des modèles).

9.4.2 Vue générale

La page **VueGenerale** constitue le tableau de bord d'entrée de l'espace décideurs, agrégeant les indicateurs clés (volumes de trafic, nombre de zones à risque, nombre d'anomalies détectées) sous forme de cartes de synthèse.

9.4.3 Zones à risque d'inaccessibilité

La page **ZonesRisquePage** restitue les résultats du modèle de prédiction d'inaccessibilité (chapitre 7) : cartographie interactive des 41 zones analysées, classées selon quatre niveaux de risque (Bien desservie, Moyenne, Sous-desservie, Critique), avec, pour chaque zone, le détail des facteurs contribuant au score.

9.4.4 Tableau de bord des anomalies

La page **AnomalyDashboard** présente les résultats du module de détection d'anomalies de trafic : liste des sites de comptage avec leur score de consensus, drill-down par site, et visualisation des *hotspots* identifiés par clustering spatial DBSCAN.

9.4.5 Segmentation des usagers

La page **SegmentationPage** restitue les cinq profils d'utilisateurs issus du modèle K-Means, avec leurs caractéristiques moyennes et leur poids relatif dans la population enquêtée.

9.4.6 Simulateur de risque

La page **SimulateurRisque** permet à un décideur de simuler le score de risque d'inaccessibilité d'une zone hypothétique en faisant varier les sept indicateurs composant le score, offrant ainsi un outil d'aide à la décision pour l'évaluation de projets d'infrastructure.

9.4.7 Transparence des modèles (MlInsights)

La page **MlInsights**, réservée au directeur de planification, expose les métriques de performance des modèles (exactitude, ROC AUC, F1-score) ainsi que l'importance des variables, dans un objectif de transparence et d'auditabilité des décisions automatisées.

9.4.8 Évolution temporelle

La page **EvolutionTemporelle** propose une analyse prospective de l'évolution de la mobilité à Dakar sur la période 2010–2023, à partir de données contextualisées, afin d'apporter un éclairage de tendance complémentaire à l'analyse instantanée des autres pages.

9.5 Synthèse de la démonstration

Le tableau 9.2 récapitule l'ensemble des écrans de l'application et leur public cible.

Table 9.2: Synthèse des écrans de l'application web

Écran	Fonction	Public
WelcomePage / FormPage	Accueil et recommandation	Citoyen
VueGenerale	Tableau de bord de synthèse	Décideurs
ZonesRisquePage	Zones à risque d'inaccessibilité	Décideurs
AnomalyDashboard	Anomalies de trafic	Décideurs
SegmentationPage	Segments d'utilisateurs	Décideurs
SimulateurRisque	Simulation de scénarios	Décideurs
MIInsights	Transparence des modèles	Directeur de planification
EvolutionTemporelle	Analyse prospective	Directeur de planification

9.6 Conclusion

L'application web développée concrétise, à travers une interface accessible, l'ensemble de la chaîne de traitement décrite dans les chapitres précédents : des modèles de Machine Learning entraînés sur les données EMD jusqu'à leur exposition via une API REST consommée par des écrans dédiés à chaque type d'utilisateur. Elle constitue, avec le cockpit Knowage, le second pilier de restitution du système décisionnel mis en place pour le CETUD.

Conclusion générale

Ce projet de fin d'études a porté sur la conception et la mise en œuvre d'une solution décisionnelle complète au service du CETUD, visant à exploiter l'Enquête Ménages-Déplacements et les données de comptage de trafic de Dakar pour éclairer la prise de décision en matière de mobilité urbaine.

La démarche suivie s'est appuyée sur la méthodologie GIMSI, qui a structuré le travail en quatre grandes étapes : l'identification des décideurs et de leurs besoins, la conception d'un modèle décisionnel en constellation, la mise en œuvre technique de la chaîne ETL avec Talend et de l'entrepôt de données sous PostgreSQL, puis la restitution des indicateurs à travers le cockpit Knowage BI.

Au-delà de ce volet purement décisionnel, le projet a été enrichi par le développement de quatre modèles de Machine Learning : la segmentation des usagers par K-Means, la recommandation de mode de transport par Random Forest, la détection d'anomalies de trafic par un consensus de trois algorithmes (Z-Score, Isolation Forest, Local Outlier Factor) complété par un clustering spatial DBSCAN, et la prédiction du risque d'inaccessibilité par Gradient Boosting. Ces modèles ont été exposés au sein d'une application web complète, combinant un backend FastAPI et un frontend React, à destination à la fois des citoyens et des décideurs du CETUD.

Sur le plan des compétences acquises, ce projet a permis une mise en pratique transversale couvrant l'ensemble de la chaîne de valeur de la donnée : de la modélisation décisionnelle classique (schéma en constellation, ETL, entrepôt de données) jusqu'aux techniques avancées de Machine Learning (apprentissage supervisé et non supervisé, détection d'anomalies), en passant par le développement d'une application web complète. Cette double dimension, décisionnelle et prédictive, constitue l'apport principal du projet par rapport à une solution de reporting classique.

Le système présente toutefois certaines limites, assumées au regard du cadre d'un projet de fin d'études : l'absence de données temps réel, l'utilisation de l'EMD 2019 (la plus récente disponible publiquement), une authentification simplifiée côté client, et l'absence de tests automatisés. Ces limites ouvrent autant de pistes d'amélioration pour une mise en production : intégration de données temps réel issues des opérateurs de transport, conteneurisation Docker, authentification renforcée (JWT, bcrypt), mise en place de tests automatisés et de pipelines d'intégration continue, et, à plus long terme, exploration de techniques de Deep Learning (réseaux de neurones récurrents pour la prédiction de trafic, réseaux de neurones sur graphes pour la modélisation du réseau de transport).

En définitive, ce projet démontre la faisabilité et l'intérêt d'une approche combinant

Business Intelligence traditionnelle et Machine Learning pour répondre aux enjeux de mobilité urbaine d'une métropole comme Dakar, et pose les bases d'un système qui pourra être consolidé et étendu dans le cadre d'une collaboration future avec le CETUD.

Bibliography

- [1] CETUD – Conseil Exécutif des Transports Urbains de Dakar, *Enquête Ménages-Déplacements de Dakar*.
- [2] Fernandez, A., *Les Nouveaux Tableaux de Bord des Managers : la méthode GIMSI*, Éditions Eyrolles.
- [3] Kimball, R., Ross, M., *The Data Warehouse Toolkit : The Definitive Guide to Dimensional Modeling*, Wiley.
- [4] Talend, *Talend Open Studio – Documentation officielle*, <https://www.talend.com/>.
- [5] PostgreSQL Global Development Group, *PostgreSQL Documentation*, <https://www.postgresql.org/docs/>.
- [6] Knowage Labs, *Knowage Documentation*, <https://www.knowage-suite.com/>.
- [7] Pedregosa, F. et al., *Scikit-learn : Machine Learning in Python*, Journal of Machine Learning Research, 2011.
- [8] Ramírez, S., *FastAPI Documentation*, <https://fastapi.tiangolo.com/>.
- [9] Meta Open Source, *React – Documentation officielle*, <https://react.dev/>.
- [10] Breiman, L., *Random Forests*, Machine Learning, vol. 45, 2001.
- [11] Liu, F. T., Ting, K. M., Zhou, Z.-H., *Isolation Forest*, IEEE International Conference on Data Mining, 2008.
- [12] Breunig, M. M., Kriegel, H.-P., Ng, R. T., Sander, J., *LOF : Identifying Density-Based Local Outliers*, ACM SIGMOD, 2000.
- [13] Ester, M., Kriegel, H.-P., Sander, J., Xu, X., *A Density-Based Algorithm for Discovering Clusters*, KDD, 1996.
- [14] Chawla, N. V. et al., *SMOTE : Synthetic Minority Over-sampling Technique*, Journal of Artificial Intelligence Research, 2002.

Appendix A

Annexes

A.1 Exploration des données (data discovery) et dictionnaire de données

Avant toute modélisation décisionnelle, un travail de découverte des données (*data discovery*) a été mené sur les quatre tables sources réelles fournies par le CETUD : **Menage** (3 176 lignes, 231 colonnes), **Individu** (13 415 lignes, 210 colonnes), **Deplacement** (45 599 lignes, 11 colonnes) et **Trafic** (37 248 lignes, 19 colonnes). Ce travail, mené sous Python (pandas), a couvert :

- la vérification de la volumétrie et de la structure de chaque table source ;
- la détection des valeurs manquantes (nulls), colonne par colonne, et l'identification des blocs de variables fortement affectés (104/231 colonnes pour **Menage**, 41/210 pour **Individu**, contre seulement 1/11 et 2/19 pour **Deplacement** et **Trafic** respectivement) ;
- la détection des valeurs aberrantes (outliers) sur les variables numériques, selon la règle de l'écart interquartile (IQR) ;
- la vérification de l'absence de doublons stricts dans les exports sources.

Ce travail est intégralement documenté dans un notebook Jupyter dédié (*EDA_CETUD_DataDiscovery*) exécuté sur les fichiers sources réels et fourni avec ses résultats dans le dossier **CETUD DATA** livré en complément de ce rapport. Ce dossier regroupe également : les fichiers sources bruts (Excel/CSV), un **dictionnaire de données** complet (fichier *Dictionnaire_Donnees_CETUD.xlsx*) recensant, pour chacune des quatre tables, le nom de chaque colonne source, sa description métier et son éventuel mapping vers une dimension ou une table de faits du modèle décisionnel, ainsi que des captures d'écran de la structure physique des tables de l'entrepôt de données sous pgAdmin.

A.2 Dictionnaire des codes de variables EMD utilisés

Table A.1: Principaux codes de variables EMD exploités

Code	Signification
I2, I4, I9	Caractéristiques géographiques du domicile (quartier, strate, district)
M21	Taille du ménage
M55	Manque de transport en commun déclaré
M66 – M70	Accessibilité de base (distance, durée de marche, modes disponibles)
M68	Exposition aux inondations
M69	Résilience d'accès en cas de pluie
M73, M87	Problèmes majeurs déclarés dans le quartier
M90, M91	Accès aux écoles et daaras

A.3 Glossaire

BI Business Intelligence – informatique décisionnelle.

CETUD Conseil Exécutif des Transports Urbains de Dakar.

EMD Enquête Ménages-Déplacements.

ETL Extract-Transform-Load – processus d'extraction, transformation et chargement des données.

GIMSI Méthodologie de conception de tableaux de bord décisionnels.

KPI Key Performance Indicator – indicateur clé de performance.

RBAC Role-Based Access Control – contrôle d'accès basé sur les rôles.

SMOTE Synthetic Minority Over-sampling Technique – technique de rééquilibrage de classes.

A.4 Liste des technologies utilisées

Table A.2: Stack technique du projet

Couche	Technologie
Préparation des données	Python, Pandas, Google Colab
ETL	Talend Open Studio
Entrepôt de données	PostgreSQL
Restitution décisionnelle	Knowage BI
Machine Learning	scikit-learn, joblib
Backend applicatif	FastAPI, Pydantic, uvicorn
Frontend applicatif	React.js, Recharts, Leaflet, Framer Motion
Gestion de projet	Scrum

A.5 Liste des points d'accès API

Table A.3: Liste complète des endpoints REST exposés par l'API

Méthode	Endpoint
POST	/recommander
GET	/zones-risque
GET	/zones-risque/resume
GET	/api/anomalies/summary
GET	/api/anomalies/sites
GET	/api/anomalies/sites/{id}
GET	/api/segmentation/profils
POST	/predict-inaccessibility
GET	/api/ml/metrics
GET	/api/ml/features-importance