

Je valide le dépôt du rapport PFE relatif à l'étudiant nommé ci-dessous / I validate the submission of the student's report:

- Nom & Prénom /Name & Surname : Ibtihel Abdellaoui

Encadrant Entreprise/ Business site Supervisor

- Nom & Prénom /Name & Surname : Mohamed Ben Hassine

Cachet & Signature / Stamp & Signature

Encadrant Académique/Academic Supervisor

- Nom & Prénom /Name & Surname : Zeineb Maatoug

Signature / Signature

Ce formulaire doit être rempli, signé et **scanné**/This form must be completed, signed and **scanned**.

Ce formulaire doit être introduit après la page de garde/ This form must be inserted after the cover page.



ECOLE SUPÉRIEURE PRIVÉE D'INGÉNIERIE ET DE TECHNOLOGIES

www.esprit.tn - E-mail : contact@esprit.tn

Siège Social : 18 rue de l'Usine - Charguia II - 2035 - Tél. : +216 71 941 541 - Fax. : +216 71 941 889

Annexe : Z.I. Chotrana II - B.P. 160 - 2083 - Pôle Technologique - El Ghazala - Tél. : +216 70 685 685 - Fax. : +216 70 685 454

2025 - 2026
PROJET DE FIN D'ÉTUDES

DIPLÔME NATIONAL D'INGÉNIEUR

SPÉCIALITÉ : INFORMATIQUE

**Conception d'une solution décisionnelle
pour l'analyse et l'optimisation
du transport urbain**

Réalisé par: Ibtihel Abdellaoui

Encadrant ESPRIT: Zeineb Maatoug

Encadrant Entreprise: Mohamed Ben Hassine



Dédicace

À mes parents, pour leur amour inconditionnel, leur sacrifice et leur soutien sans faille tout au long de mon parcours.

À mes frères et sœurs, pour leur présence et leurs encouragements constants.

À tous mes amis, pour les moments partagés, le soutien mutuel et la bonne humeur qui ont rendu ce chemin plus léger.

*À **Ramzi Ben Nasr**, pour sa générosité, sa disponibilité et son aide précieuse qui ont été d'un grand apport pour la réalisation de ce travail.*

Je vous dédie ce travail en témoignage de ma profonde gratitude et de mon affection.

Remerciements

Au terme de ce travail, je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce projet de fin d'études.

Je remercie en premier lieu mon encadrante académique au sein d'ESPRIT, **Mme Zeineb Maatoug**, pour son suivi rigoureux, ses conseils avisés et sa disponibilité tout au long de ce projet.

Mes remerciements vont également à mon encadrant professionnel au sein de **SIMAC**, l'entreprise d'accueil, **M. Mohamed Ben Hassine**, pour la confiance qu'il m'a accordée, son accompagnement et son implication durant toute la durée du stage.

Je remercie aussi l'ensemble du corps enseignant d'ESPRIT qui a contribué à ma formation tout au long de mon parcours universitaire, ainsi que les membres du jury qui me font l'honneur d'évaluer ce travail.

Enfin, je remercie l'entreprise **SIMAC** pour l'environnement de travail mis à ma disposition et pour les ressources matérielles et humaines qui ont permis la concrétisation de ce projet.

Résumé

Le présent rapport décrit la conception et la mise en œuvre d’une solution décisionnelle (Business Intelligence) destinée à l’analyse et à l’optimisation du transport urbain de la ville de Dakar, réalisée pour le compte du CETUD (Conseil Exécutif des Transports Urbains de Dakar). Le projet s’appuie sur les données de l’Enquête Ménages-Déplacements (EMD) ainsi que sur des données de comptage de trafic, et couvre l’ensemble de la chaîne décisionnelle : compréhension métier, modélisation multidimensionnelle des données en schéma en constellation (3 faits, 7 dimensions), mise en œuvre d’un processus d’extraction-transformation-chargement (ETL) avec Talend, implémentation d’un entrepôt de données sous PostgreSQL, restitution à travers des tableaux de bord interactifs développés avec Knowage BI, et enrichissement de la solution par des modèles de Machine Learning (segmentation des usagers, système de recommandation, détection d’anomalies de trafic et prédiction des zones à risque d’inaccessibilité). L’ensemble de la solution est exposé à travers une application web (React / FastAPI) destinée à la fois aux usagers du réseau et aux décideurs du CETUD. Ce travail répond à la problématique de la valorisation d’un grand volume de données hétérogènes afin de fournir une vision globale, fiable et exploitable des flux de transport, en vue d’améliorer la prise de décision et l’optimisation du réseau de transport urbain.

Mots-clés : Business Intelligence, Data Warehouse, ETL, Talend, PostgreSQL, Knowage, schéma en constellation, Machine Learning, transport urbain, CETUD, Dakar.

Liste des abréviations

BI	Business Intelligence
CETUD	Conseil Exécutif des Transports Urbains de Dakar
DW	Data Warehouse (entrepôt de données)
EMD	Enquête Ménages-Déplacements
ETL	Extract, Transform, Load
API	Application Programming Interface
REST	Representational State Transfer
JWT	JSON Web Token
ML	Machine Learning (apprentissage automatique)
KPI	Key Performance Indicator (indicateur clé de performance)
GIMSI	Généralized Indicator for Management of Strategic Information
RBAC	Role-Based Access Control
SMOTE	Synthetic Minority Over-sampling Technique
LOF	Local Outlier Factor
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
SHAP	SHapley Additive exPlanations
ROC	Receiver Operating Characteristic
AUC	Area Under the Curve
KPI	Key Performance Indicator
SGBDR	Système de Gestion de Bases de Données Relationnelles
UML	Unified Modeling Language
PFE	Projet de Fin d'Études
UC	Cas d'utilisation (Use Case)
GPS	Global Positioning System
IoT	Internet of Things

Table des matières

Remerciements	ii
Résumé	iii
Liste des abréviations	iv
Introduction générale	1
1 Étude de l'existant et analyse des besoins	7
1.1 Introduction	7
1.2 Présentation de l'entreprise	7
1.2.1 Présentation du client : le CETUD	7
1.3 Contexte métier	8
1.4 Présentation du domaine du transport urbain	8
1.5 Analyse de l'existant	8
1.5.1 Processus actuel	9
1.5.2 Limites de l'existant	9
1.6 Analyse des besoins	9
1.6.1 Besoins fonctionnels	9
1.6.2 Besoins non fonctionnels	10
1.7 Identification des acteurs	10
1.8 Arbre de décision	11
1.9 Conclusion	12
2 Conception de la solution décisionnelle	13
2.1 Introduction	13
2.2 Architecture globale proposée	13
2.3 Choix technologiques	14
2.4 Architecture fonctionnelle	15
2.5 Architecture technique	16
2.6 Architecture logicielle	16
2.7 Modélisation UML	16
2.7.1 Diagramme de cas d'utilisation	16
2.8 Conclusion	17

3	Conception décisionnelle	19
3.1	Introduction	19
3.2	Description des sources de données	19
3.3	Dictionnaire de données et qualité des sources	20
3.3.1	Dictionnaire de données	20
3.3.2	Qualité des données sources	21
3.3.3	Choix du modèle décisionnel	22
3.4	Architecture ETL	23
3.5	Processus ETL avec Talend	23
3.5.1	Extraction	23
3.5.2	Nettoyage	24
3.5.3	Transformation	24
3.5.4	Chargement	25
3.6	Conception du Data Warehouse	26
3.6.1	Tables de faits	26
3.6.2	Dimensions	26
3.6.3	Hierarchies	27
3.6.4	Mesures et indicateurs	27
3.6.5	Implémentation physique	28
3.7	Conclusion	29
4	Intégration du Machine Learning	30
4.1	Motivation	30
4.2	Pourquoi un entraînement direct sur les sources	30
4.3	Pipeline de Machine Learning	31
4.3.1	Prétraitement	31
4.3.2	Feature engineering	31
4.3.3	Sélection des variables	31
4.3.4	Entraînement	31
4.3.5	Évaluation	31
4.3.6	Sauvegarde	31
4.4	Présentation des modèles	32
4.4.1	Segmentation des usagers (K-Means)	32
4.4.2	Recommandation de mode de transport (Random Forest)	33
4.4.3	Détection d'anomalies de trafic	34
4.4.4	Prédiction du risque d'inaccessibilité	36
4.5	Bilan des modèles de Machine Learning	39
4.6	Intégration dans FastAPI	40
4.7	Exploitation des prédictions	40
4.8	Valeur ajoutée de l'intelligence artificielle	40
4.9	Conclusion	41
5	Développement de la plateforme décisionnelle	42

5.1	Introduction	42
5.2	Architecture de l'application	42
5.2.1	Authentification des décideurs	44
5.2.2	Espace décisionnel	45
5.2.3	Audit des modèles de Machine Learning – accès restreint	50
5.2.4	Cockpit Knowage – rendu des six sheets	51
5.3	Sécurité de l'application	52
5.4	Conclusion	53
6	Résultats et évaluation	54
6.1	Introduction	54
6.2	Présentation des dashboards	54
6.3	Analyse des KPIs	54
6.4	Résultats des modèles ML	55
6.5	Comparaison BI vs ML	55
6.6	Apport global	56
6.7	Limites	56
6.8	Perspectives	57
6.9	Conclusion	57
	Conclusion générale	58
	Bibliographie	60
A	Annexes	62
A.1	Scripts SQL	62
A.2	Jobs Talend	62
A.3	Captures Knowage	63
A.4	Captures React	63
A.5	Documentation de l'API	63
A.6	Documentation des modèles de Machine Learning	64
A.7	Manuel utilisateur	64
A.7.1	Espace citoyen	64
A.7.2	Espace décideurs	64
A.8	Dictionnaire des codes de variables EMD utilisés	65
A.9	Glossaire	65
A.10	Liste des technologies utilisées	66

Liste des figures

1	Le processus Scrum : du Product Backlog à l'Incrément du produit via les sprints	4
2	Les quatre étapes de la méthodologie GIMSI	5
3	Intégration de la démarche GIMSI dans les sprints Scrum du projet	5
1.1	Logos des organismes partenaires – CETUD (client) et SIMAC (encadrant professionnel)	8
1.2	Arbre de décision – Conception de la solution décisionnelle pour le transport urbain à Dakar (CETUD)	11
2.1	Architecture complète de la solution – pipelines BI (décisionnel) et Machine Learning (prédictif)	14
2.2	Logos des technologies retenues dans la solution	15
2.3	Diagramme de cas d'utilisation de la solution décisionnelle TransportDakar . .	17
3.1	Capture d'écran – page de présentation du dictionnaire de données CETUD . .	20
3.2	Capture d'écran – onglet Mapping_DW du dictionnaire de données	21
3.3	Data discovery sous Google Colab – distribution des valeurs manquantes par variable	22
3.4	Schéma en constellation du modèle décisionnel (4 faits et 9 dimensions)	23
3.5	Job Talend de chargement de la Staging Area – déplacements	24
3.6	Composant tMap du job de construction de Fact_deplacement	25
3.7	Job Talend de construction de Fact_Comptage	25
3.8	Jobs de construction des dimensions de référence	26
3.9	Structure de la table Fact_Comptage (pgAdmin)	28
3.10	Extrait de la table Dim_Geographie (507 zones)	29
4.1	Exploration des données individus avant segmentation	32
4.2	Détermination du nombre optimal de clusters (méthode du coude + silhouette) .	32
4.3	Caractérisation des segments par variable (heatmap)	33
4.4	Matrice de confusion du modèle de recommandation de mode	34
4.5	Tableau de bord de synthèse des anomalies de trafic détectées	35
4.6	Cartographie des zones classées par niveau de risque d'inaccessibilité	37
4.7	Importance des variables du modèle de prédiction d'inaccessibilité	38
4.8	Analyse d'explicabilité SHAP du modèle de prédiction d'inaccessibilité	39
5.1	Page d'accueil citoyenne (WelcomePage)	43

5.2	Formulaire citoyen et recommandation de mode de transport (FormPage)	43
5.3	Cellule d'écoute publique – dépôt et restitution des avis citoyens (AvisCitoyen- Page)	44
5.4	Page de connexion de l'espace décideurs (LoginDecideurs)	44
5.5	Vue générale – tableau de bord de synthèse (VueGenerale)	45
5.6	Cockpit Knowage intégré, mode clair (CockpitDakar)	45
5.7	Cockpit Knowage intégré, mode sombre (CockpitDakar)	46
5.8	Zones à risque d'inaccessibilité – vue exploitation (ZonesRisquePage)	46
5.9	Zones à risque d'inaccessibilité – cartographie interactive	47
5.10	Simulateur interactif du score de risque (SimulateurRisque)	47
5.11	Détection d'anomalies de trafic (AnomalyDashboard)	48
5.12	Segmentation des usagers par profil de mobilité (SegmentationPage)	48
5.13	Évolution temporelle des indicateurs (EvolutionTemporelle)	49
5.14	Satisfaction et écoute citoyenne – vue décideur agrégée (SatisfactionPage) . . .	49
5.15	Transparence et audit des modèles de Machine Learning (MlInsights)	50
5.16	Sheet <i>Accueil</i> du cockpit Knowage – mode clair	51
5.17	Sheet <i>Trafic</i> (gauche) et sheet <i>Déplacements</i> (droite)	51
5.18	Sheet <i>Démographie</i> (gauche) et sheet <i>Accessibilité</i> (droite)	52
5.19	Sheet <i>IA</i> – restitution synthétique des résultats de Machine Learning dans le cockpit Knowage	52
6.1	Identité visuelle du cockpit décisionnel TransportDakar	54

Liste des tableaux

1	Comparaison des principales méthodologies de gestion de projet	3
1.1	Synthèse des acteurs et de leurs objectifs	11
2.1	Choix technologiques de la solution	15
3.1	Mapping entre les tables de faits, leurs dimensions et leurs tables sources EMD	20
3.2	Dictionnaire des dimensions du modèle décisionnel	27
4.1	Segments d'utilisateurs identifiés par K-Means	33
4.2	Algorithmes de détection d'anomalies et pondération du consensus	35
4.3	Performances du modèle de prédiction d'inaccessibilité (XGBoost)	36
4.4	Synthèse des modèles de Machine Learning	40
6.1	Synthèse des indicateurs clés produits par la solution	55
6.2	Synthèse des performances des modèles de Machine Learning	55
6.3	Comparaison des apports de la BI classique et du Machine Learning	56
A.1	Jobs Talend développés	62
A.2	Liste complète des endpoints REST exposés par l'API	63
A.3	Principaux codes de variables EMD exploités	65
A.4	Stack technique du projet	66

Introduction générale

Contexte

La ville de Dakar connaît, comme la plupart des grandes agglomérations africaines, une croissance urbaine rapide accompagnée d'une demande de mobilité de plus en plus forte. Le réseau de transport urbain, structuré autour de multiples modes (bus, cars rapides, Ndiaga Ndiaye, TATA, taxis, transport informel), génère un volume important de données issues des enquêtes ménages-déplacements et des dispositifs de comptage de trafic. Ces données, bien que riches, restent aujourd'hui largement sous-exploitées par manque d'outils permettant de les centraliser, de les croiser et de les restituer sous une forme directement utilisable par les décideurs.

C'est dans ce contexte que le CETUD (Conseil Exécutif des Transports Urbains de Dakar), autorité organisatrice des transports urbains de la région de Dakar, a souhaité disposer d'une solution décisionnelle complète permettant de transformer ces données brutes en informations stratégiques. L'enjeu n'est pas uniquement technique : il s'agit de fournir au directeur de planification et au chef d'exploitation du CETUD une vision fiable, actualisée et exploitable des flux de transport, afin d'orienter les décisions d'investissement, d'adaptation de l'offre et d'amélioration de l'accessibilité.

Problématique

La problématique générale ayant motivé ce projet peut être formulée ainsi :

Comment exploiter efficacement un grand volume de données hétérogènes issues du système de transport urbain afin de fournir une vision globale, pertinente et exploitable des flux de transport, et ainsi améliorer la prise de décision et l'optimisation du réseau de transport urbain ?

Cette problématique se décline en plusieurs questions opérationnelles :

- Comment garantir la qualité, la fiabilité et la cohérence de données collectées depuis des sources multiples et hétérogènes (enquêtes terrain, comptages automatiques) ?
- Comment structurer ces données pour qu'elles soient directement exploitables dans des indicateurs décisionnels ?
- Comment restituer ces indicateurs de façon claire et actionnable aux différents profils de décideurs du CETUD ?
- Comment aller au-delà du simple reporting descriptif, en exploitant les données pour anticiper (segmentation des usagers, détection d'anomalies, prédiction des zones à risque) ?

Objectifs du projet

Pour répondre à cette problématique, le projet poursuit les objectifs suivants :

1. **Compréhension métier et données** : analyser les sources de données disponibles (EMD, comptages de trafic) et identifier les besoins des décideurs du CETUD.
2. **Modélisation décisionnelle** : concevoir un modèle multidimensionnel capable de répondre aux besoins analytiques identifiés.
3. **Mise en œuvre de l'ETL** : industrialiser la collecte, le nettoyage et le chargement des données dans l'entrepôt de données à l'aide de Talend.
4. **Implémentation de l'entrepôt de données** : déployer un entrepôt de données sous PostgreSQL conforme au modèle décisionnel conçu.
5. **Visualisation et restitution** : développer des tableaux de bord interactifs avec Knowage BI permettant le suivi des indicateurs clés.
6. **Enrichissement par le Machine Learning** : développer des modèles prédictifs et de segmentation pour aller au-delà du reporting descriptif.
7. **Intégration applicative** : exposer l'ensemble de la solution à travers une application web destinée aux usagers et aux décideurs.

Méthodologie

Comparaison des méthodologies de gestion de projet

La conduite d'un projet décisionnel s'appuie sur une méthodologie de gestion de projet qui structure les étapes de développement, garantit la maîtrise du périmètre et assure la livraison d'une solution de qualité. Plusieurs méthodologies étaient envisageables pour ce projet ; elles ont été comparées avant de justifier le choix retenu (tableau 1).

Table 1: Comparaison des principales méthodologies de gestion de projet

Méthodologie	Principe	Avantages	Limites
Cycle en cascade	Phases séquentielles (besoins → conception → dev → tests → livraison)	Simple à planifier, documentation complète	Très peu adaptable aux changements en cours de projet ; retours tardifs du client
RUP (Rational Unified Process)	Processus itératif et piloté par les risques, organisé en quatre phases (Inception, Élaboration, Construction, Transition)	Bonne gestion des risques, orienté architecture	Lourd à mettre en œuvre, nécessite une équipe expérimentée ; trop formel pour un projet de taille académique
Kanban	Gestion visuelle du flux de travail en cours, sans itérations fixes	Souplesse maximale, l'encours	Absence de cadence temporelle ; peu adapté lorsque des délais formels doivent être respectés
Scrum	Cycles courts (sprints), revues régulières, adaptation continue aux priorités	Livraisons incrémentales, adaptation rapide, visibilité permanente	Requiert une implication régulière du product owner ; moins adapté aux projets à périmètre figé dès le départ
GIMSI	Démarche de construction de tableaux de bord partant des décideurs et de leurs objectifs, en quatre étapes (Identification, Conception, Mise en œuvre, Amélioration permanente)	Rigoureuse pour les projets BI, centrée sur la valeur décisionnelle	Ne couvre pas la gestion opérationnelle du projet (planification, suivi d'avancement) ; doit être combinée à une méthode de gestion de projet

Méthodologie retenue : Scrum intégrant GIMSI

À l'issue de cette comparaison, le choix s'est porté sur une combinaison de **Scrum** comme cadre de gestion opérationnelle du projet et de **GIMSI** comme démarche métier pour la construction du système décisionnel. Ce choix se justifie par plusieurs raisons :

- **Scrum** offre la souplesse nécessaire pour un projet de fin d'études dont le périmètre

fonctionnel s'affine progressivement : le découpage en sprints courts permet d'intégrer les retours des encadrants à chaque itération, de prioriser les briques à forte valeur ajoutée et de livrer des résultats intermédiaires démontrables ;

- **GIMSI** fournit le cadre métier structurant qui manque à Scrum pour un projet décisionnel : en s'appuyant sur l'Identification des décideurs et de leurs objectifs (étape 1), la Conception des indicateurs et de l'architecture (étape 2), la Mise en œuvre technique (étape 3) et l'Amélioration permanente (étape 4), GIMSI garantit que la solution est pilotée par la valeur décisionnelle plutôt que par la technologie.

Concrètement, la démarche GIMSI a été intégrée à *l'intérieur* des sprints Scrum (figure 1) : les étapes d'identification et de conception GIMSI ont structuré les premiers sprints (analyse des besoins, modélisation décisionnelle), tandis que les étapes de mise en œuvre et d'amélioration permanente ont piloté les sprints suivants (ETL, entrepôt, Machine Learning, application, restitution, tests). Ce couplage a permis de conserver la rigueur analytique propre aux projets BI tout en bénéficiant de la flexibilité et de la visibilité d'un cadre agile. L'intégration détaillée des étapes GIMSI dans chaque sprint est illustrée à la figure 3.




Figure 1: Le processus Scrum : du Product Backlog à l'Incrément du produit via les sprints




Figure 2: Les quatre étapes de la méthodologie GIMSI




Figure 3: Intégration de la démarche GIMSI dans les sprints Scrum du projet

Le projet s'est déroulé sur une période de six mois, avec des points d'avancement réguliers avec l'encadrant professionnel de SIMAC.

Organisation du mémoire

Ce rapport est organisé en six chapitres. Le premier chapitre présente l'étude de l'existant et l'analyse des besoins : l'organisme d'accueil, le domaine du transport urbain, les limites du processus actuel, l'arbre de décision et le cahier des charges fonctionnel et non fonctionnel. Le deuxième chapitre décrit la conception de la solution décisionnelle : l'architecture globale proposée, les choix technologiques et la modélisation UML retenue. Le troisième chapitre

détaille la conception décisionnelle proprement dite : sources de données, architecture ETL et conception de l'entrepôt de données. Le quatrième chapitre est consacré à l'intégration du Machine Learning, des choix méthodologiques jusqu'à l'exploitation des prédictions dans l'application. Le cinquième chapitre couvre le développement de la plateforme décisionnelle : backend FastAPI, frontend React, intégration de Knowage et sécurité. Le sixième chapitre présente les résultats obtenus et leur évaluation. Le rapport se termine par une conclusion générale, une bibliographie et un ensemble d'annexes techniques.

Chapitre 1

Étude de l'existant et analyse des besoins

1.1 Introduction

Conformément à la première étape de la méthodologie GIMSI (identification), ce chapitre pose le cadre métier du projet : présentation de l'entreprise d'accueil et du client du projet, du domaine du transport urbain à Dakar, analyse du processus décisionnel actuel et de ses limites, puis spécification des besoins fonctionnels et non fonctionnels qui ont guidé la conception de la solution.

1.2 Présentation de l'entreprise

Ce projet de fin d'études a été réalisé au sein de **SIMAC**, l'entreprise d'accueil. SIMAC est une société de services informatiques disposant de deux implantations : un site en **Tunisie (Tunis)** et un site au **Sénégal**, ce qui lui permet d'intervenir directement auprès de clients d'Afrique de l'Ouest tout en s'appuyant sur son pôle d'ingénierie tunisien. C'est dans le cadre de cette double implantation que SIMAC a été chargée de la conception et de la réalisation de la solution décisionnelle objet de ce rapport, pour le compte de son client le CETUD.



Figure 1.1: Logo de SIMAC, entreprise d'accueil

1.2.1 Présentation du client : le CETUD

Le **CETUD** (Conseil Exécutif des Transports Urbains de Dakar) est le **client** du projet. Basé à **Dakar, Sénégal**, il s'agit de l'autorité organisatrice des transports urbains pour la région de Dakar. Créé pour mettre en œuvre la politique de l'État en matière de transport urbain, il a pour mission de planifier, organiser et réguler l'offre de transport public sur le territoire de l'agglomération dakaroise, en coordonnant les différents opérateurs (bus Dakar Dem Dikk, cars rapides, Ndiaga Ndiaye, TATA, transport informel) et en veillant à l'amélioration continue de l'accessibilité et de la qualité de service offerte aux usagers.

Dans le cadre de ses missions de planification, le CETUD réalise et exploite des enquêtes de grande ampleur, notamment l'Enquête Ménages-Déplacements (EMD), ainsi que des campagnes de comptage de trafic sur les principaux axes et points névralgiques du réseau. Ces

données constituent un patrimoine informationnel considérable, mais dont l'exploitation reste aujourd'hui largement manuelle et ponctuelle – d'où la commande, auprès de SIMAC, de la solution décisionnelle présentée dans ce rapport.



Figure 1.2: Logo du CETUD, client du projet

1.3 Contexte métier

La mobilité urbaine à Dakar se caractérise par une forte hétérogénéité de l'offre (transport formel et informel coexistants), une demande en croissance continue liée à l'étalement urbain, et des contraintes d'accessibilité marquées dans certaines zones périphériques. Le CETUD doit, dans ce contexte, arbitrer en permanence entre plusieurs préoccupations : l'adaptation de l'offre de transport en commun à la demande réelle, la priorisation des investissements d'infrastructure, et le suivi de la qualité de service perçue par les usagers. Ces arbitrages reposent aujourd'hui largement sur l'expertise des agents du CETUD et sur des extractions ponctuelles de données, plutôt que sur un système d'information décisionnel structuré.

1.4 Présentation du domaine du transport urbain

Le réseau de transport urbain de Dakar repose sur plusieurs catégories de données qu'il convient de bien distinguer :

- l'**Enquête Ménages-Déplacements (EMD)**, une enquête déclarative menée auprès d'un échantillon de ménages, recensant les caractéristiques socio-démographiques des individus et le détail de leurs déplacements quotidiens (motif, mode, durée, coût, origine, destination) ;
- les **comptages de trafic**, des relevés automatiques ou manuels de flux de véhicules effectués sur des sites de comptage répartis sur le réseau, à une granularité horaire ;
- les **indicateurs d'accessibilité**, dérivés des deux sources précédentes, qui qualifient la qualité de la desserte en transport en commun par zone géographique.

Ce triptyque de données (déplacements déclarés, trafic observé, accessibilité dérivée) constitue le socle informationnel sur lequel s'appuie l'ensemble de la solution décisionnelle développée dans ce projet.

1.5 Analyse de l'existant

1.5.1 Processus actuel

Avant ce projet, l'exploitation des données EMD et de comptage de trafic au CETUD suivait un processus essentiellement manuel : les fichiers bruts (extraits Excel/CSV des enquêtes) étaient consultés au cas par cas, généralement à l'occasion d'une étude ponctuelle ou d'une demande spécifique d'un service. Les calculs d'indicateurs (volumes, taux, scores) étaient réalisés directement dans des feuilles de calcul, sans modèle de données partagé ni historique structuré. Il n'existait pas de tableau de bord consolidé permettant un suivi régulier des indicateurs clés, ni d'outil permettant de croiser facilement les données de déplacement avec les données de trafic ou les indicateurs d'accessibilité.

1.5.2 Limites de l'existant

Cette situation présentait plusieurs limites structurelles :

- **Absence de modèle de données partagé** : chaque analyse repartait des fichiers bruts, sans réutilisation d'un référentiel commun (dimensions, mesures), ce qui générait des incohérences entre analyses successives ;
- **Manque de centralisation** : les données EMD, les données de comptage et les indicateurs d'accessibilité étaient traités séparément, rendant difficile toute analyse croisée ;
- **Restitution non standardisée** : les résultats étaient produits sous forme de documents ponctuels (tableaux, graphiques isolés), sans interface de consultation interactive ni mise à jour automatisée ;
- **Aucune dimension prédictive** : l'analyse se limitait à du reporting descriptif (comptages, moyennes), sans capacité de segmentation des usagers, de détection d'anomalies ou de prédiction des zones à risque ;
- **Dépendance à l'expertise individuelle** : la connaissance des règles de calcul et des spécificités des données reposait sur quelques personnes, sans documentation centralisée.

Ces limites justifient la mise en place d'une chaîne décisionnelle structurée, allant de l'ETL jusqu'à la restitution interactive, enrichie par des modèles de Machine Learning permettant de dépasser le seul reporting descriptif.

1.6 Analyse des besoins

1.6.1 Besoins fonctionnels

L'analyse menée avec les décideurs du CETUD a permis d'identifier les besoins fonctionnels suivants :

- centraliser les données issues de l'EMD et des comptages de trafic dans un entrepôt de données unique et structuré ;
- produire automatiquement les indicateurs clés de performance (KPI) nécessaires au suivi de la mobilité urbaine (volumes de déplacement, heures de pointe, scores d'accessibilité, etc.) ;
- restituer ces indicateurs sous forme de tableaux de bord interactifs, navigables par thématique (trafic, déplacements, démographie, accessibilité) ;
- permettre la consultation de prédictions et d'analyses avancées (segmentation des usagers, détection d'anomalies de trafic, prédiction du risque d'inaccessibilité, recommandation de mode de transport) ;
- offrir un espace public permettant au citoyen d'obtenir une recommandation personnalisée de mode de transport ;
- distinguer les droits d'accès selon le profil de l'utilisateur (citoyen, chef d'exploitation, directeur de planification).

1.6.2 Besoins non fonctionnels

Au-delà des fonctionnalités, plusieurs exigences non fonctionnelles ont structuré les choix de conception :

- **Performance** : les temps de réponse des tableaux de bord et de l'API de recommandation doivent rester compatibles avec un usage interactif (chargement des modèles de Machine Learning en mémoire au démarrage du serveur plutôt qu'à chaque requête) ;
- **Sécurité** : l'accès à l'espace décideurs doit être protégé par authentification, avec un contrôle d'accès basé sur les rôles (RBAC) ;
- **Ergonomie** : les interfaces doivent être accessibles à des utilisateurs non techniques, avec une navigation claire et un mode sombre/clair ;
- **Maintenabilité** : l'architecture doit séparer clairement les couches (ETL, entrepôt, restitution BI, application web) afin de faciliter l'évolution indépendante de chaque composant ;
- **Traçabilité** : chaque indicateur restitué doit pouvoir être retracé jusqu'à sa source dans l'entrepôt de données, condition de la confiance des décideurs dans le système.

1.7 Identification des acteurs

Trois acteurs principaux interagissent avec la solution :

- **Citoyen / usager** : tout usager du réseau de transport, sans authentification requise, qui consulte l'application pour obtenir une recommandation de mode de transport adaptée à son profil de mobilité ;
- **Chef d'Exploitation** : décideur opérationnel du CETUD, authentifié, qui consulte les tableaux de bord de suivi (trafic, déplacements, zones à risque, anomalies, segmentation des usagers) afin d'ajuster l'offre de transport au quotidien ;
- **Directeur Planification** : décideur stratégique du CETUD, authentifié, qui dispose des mêmes accès que le chef d'exploitation, complétés par l'accès aux pages de transparence et d'audit des modèles de Machine Learning (métriques de performance, importance des variables), dans un objectif de gouvernance des décisions automatisées.

Table 1.1: Synthèse des acteurs et de leurs objectifs

Acteur	Authentification	Objectif principal
Citoyen / usager	Non	Obtenir une recommandation de mode de transport
Chef d'Exploitation	Oui (RBAC)	Ajuster l'offre au quotidien à partir des tableaux de bord
Directeur Planification	Oui (RBAC)	Piloter la stratégie et auditer les modèles de ML

1.8 Arbre de décision

L'arbre de décision ci-dessous (figure 1.2) illustre la démarche de prise de décision structurée adoptée pour la conception de la solution décisionnelle du CETUD. Il modélise les chemins décisionnels menant à la définition des indicateurs clés, à la sélection des modules analytiques (BI classique, Machine Learning) et à la priorisation des fonctionnalités selon les profils d'utilisateurs identifiés.




Figure 1.3: Arbre de décision – Conception de la solution décisionnelle pour le transport urbain à Dakar (CETUD)

1.9 Conclusion

Ce chapitre a permis de poser le cadre métier du projet : présentation du CETUD et du domaine du transport urbain à Dakar, analyse critique du processus décisionnel existant, spécification précise des besoins fonctionnels et non fonctionnels, identification des acteurs de la solution et formalisation de l'arbre de décision. Ces éléments constituent le cahier des charges à partir duquel la conception de la solution décisionnelle, objet du chapitre suivant, a été élaborée.

Chapitre 2

Conception de la solution décisionnelle

2.1 Introduction

Conformément à la deuxième étape de la méthodologie GIMSI (conception), ce chapitre présente la conception globale de la solution : l'architecture générale retenue, les choix technologiques opérés à chaque niveau de la chaîne, les architectures fonctionnelle, technique et logicielle, ainsi que la modélisation UML de la solution.

2.2 Architecture globale proposée

La solution repose sur une architecture en chaîne décisionnelle complète, allant des sources de données brutes jusqu'à leur restitution, doublée d'une couche applicative web exposant les résultats à deux publics distincts (citoyens et décideurs). Cette architecture s'articule autour de quatre grands blocs :

1. un bloc **Sources & ETL** : fichiers sources EMD et comptages de trafic, nettoyés en Python, puis intégrés dans l'entrepôt de données via des jobs Talend ;
2. un bloc **Entrepôt de données** : base PostgreSQL structurée selon un modèle décisionnel multidimensionnel (chapitre 3) ;
3. un bloc **Restitution et intelligence** : cockpit Knowage BI pour le reporting et la visualisation, complété par des modèles de Machine Learning entraînés directement sur les sources nettoyées ;
4. un bloc **Application web** : backend FastAPI exposant une API REST, consommée par un frontend React, qui intègre à la fois les pages applicatives et le cockpit Knowage.




Figure 2.1: Architecture complète de la solution – pipelines BI (décisionnel) et Machine Learning (prédicatif)

2.3 Choix technologiques

Le tableau 2.1 récapitule les choix technologiques retenus pour chaque maillon de la chaîne, ainsi que leur justification.

Table 2.1: Choix technologiques de la solution

Couche	Technologie	Justification
Préparation des données	Python / Pandas (Colab)	Écosystème mature pour le nettoyage et l'exploration de données tabulaires volumineuses
ETL	Talend Open Studio	Outil graphique gratuit, composants prêts à l'emploi (tMap, tDBOutput) adaptés à un projet académique
Entrepôt de données	PostgreSQL	SGBDR open source, robuste, bien documenté, compatible avec Knowage et Talend
Restitution BI	Knowage BI	Suite BI open source complète (datasets, cockpits, widgets) sans coût de licence
Machine Learning	Python / scikit-learn	Bibliothèque de référence pour les algorithmes de classification, clustering et détection d'anomalies, avec un bon compromis simplicité/performance
Backend applicatif	FastAPI	Framework Python moderne, performant, génération automatique de documentation interactive (Swagger), validation native via Pydantic
Frontend applicatif	React.js	Bibliothèque la plus répandue pour la construction d'interfaces utilisateur réactives et composables

Les bibliothèques de Machine Learning mobilisées incluent notamment `scikit-learn` (K-Means, Random Forest, Isolation Forest, Local Outlier Factor, DBSCAN, Gradient Boosting), `imbalanced-learn` (SMOTE) et `jolib` pour la sérialisation des modèles entraînés.



Python / Colab



Talend



PostgreSQL



Knowage BI



FastAPI



React.js

Figure 2.2: Technologies retenues dans la solution

2.4 Architecture fonctionnelle

D'un point de vue fonctionnel, la solution distingue trois grandes fonctions : la **fonction décisionnelle classique** (ETL, entrepôt, cockpit Knowage), qui répond aux besoins de reporting et de suivi des KPI ; la **fonction prédictive** (modèles de Machine Learning), qui enrichit l'analyse par des capacités de segmentation, de détection d'anomalies et de prédiction ; et la **fonction applicative**, qui expose ces deux fonctions à travers des interfaces adaptées à chaque type

d'utilisateur (citoyen, chef d'exploitation, directeur de planification). Ces trois fonctions communiquent entre elles : le cockpit Knowage lit l'entrepôt de données, tandis que les modèles de Machine Learning lisent directement les sources nettoyées (ce choix est justifié au chapitre 4), et l'application web orchestre l'accès à l'ensemble via son backend.

2.5 Architecture technique

Sur le plan technique, la solution est déployée selon une architecture en couches :

- une couche **stockage** (PostgreSQL, schéma DW) ;
- une couche **intégration** (Talend, exécuté en mode batch pour alimenter l'entrepôt) ;
- une couche **intelligence** (scripts Python entraînant et sérialisant les modèles de Machine Learning au format .pkl) ;
- une couche **services** (serveur FastAPI exposant l'API REST et chargeant les modèles en mémoire au démarrage) ;
- une couche **présentation** (application React consommant l'API REST et intégrant le cockpit Knowage par *embedding*) ;
- une couche **restitution BI** (serveur Knowage, consulté directement ou via le frontend React).

Cette séparation en couches permet à chaque composant d'évoluer indépendamment et facilite la maintenance de la solution dans son ensemble.

2.6 Architecture logicielle

L'architecture logicielle de l'application web suit un modèle client-serveur classique à trois couches : une couche de **présentation** (composants React organisés en pages publiques et pages décideurs protégées), une couche **métier/API** (endpoints FastAPI organisés par domaine fonctionnel : recommandation, zones à risque, anomalies, segmentation, authentification), et une couche **données** (modèles de Machine Learning sérialisés, accès à l'entrepôt PostgreSQL). La communication entre le frontend et le backend s'effectue exclusivement via des requêtes HTTP au format JSON, ce qui découple complètement les deux couches et permettrait, à terme, de remplacer l'une ou l'autre sans impact sur le reste du système.

2.7 Modélisation UML

2.7.1 Diagramme de cas d'utilisation

La modélisation UML de la solution s'appuie sur un diagramme de cas d'utilisation (figure 2.3), qui synthétise les interactions entre les trois acteurs identifiés au chapitre précédent (citoyen,

chef d'exploitation, directeur de planification) et les fonctionnalités du système. Ce diagramme met en évidence :

- les fonctionnalités publiques (sans authentification) : recommandation de mode de transport (UC1), consultation de l'application (UC2) et dépôt d'avis citoyens (UC3) ;
- les fonctionnalités décideurs : toutes dépendantes de l'authentification (UC4) : consultation des tableaux de bord trafic (UC5), déplacements (UC6), démographie (UC7), accessibilité (UC8), zones à risque (UC9), anomalies de trafic (UC10), segmentation des usagers (UC11), simulation de risque (UC12), évolution temporelle (UC13), satisfaction (UC14), et export PDF (UC16) ;
- la fonctionnalité d'audit des modèles de Machine Learning (UC15), réservée au seul directeur de planification, conformément à son rôle de gouvernance des décisions automatisées.




Figure 2.3: Diagramme de cas d'utilisation de la solution décisionnelle TransportDakar

Ce choix de se concentrer sur le diagramme de cas d'utilisation, plutôt que de multiplier les diagrammes UML (séquence, classes, composants, déploiement), répond à un objectif de clarté : le diagramme de cas d'utilisation est le plus pertinent pour exprimer le périmètre fonctionnel réel de l'application et les droits d'accès associés à chaque acteur, et constitue la base de référence pour le développement présenté au chapitre 5.

2.8 Conclusion

Ce chapitre a présenté la conception globale de la solution décisionnelle : son architecture, les technologies retenues à chaque niveau, et sa modélisation par cas d'utilisation. Les chapitres suivants détaillent successivement la mise en œuvre de chacun des blocs de cette architecture : la conception décisionnelle (chapitre 3), l'intégration du Machine Learning (chapitre 4) et le développement de la plateforme (chapitre 5).

Chapitre 3

Conception décisionnelle

3.1 Introduction

Ce chapitre détaille la conception décisionnelle de la solution : les sources de données exploitées, l'architecture du processus ETL, sa mise en œuvre avec Talend, et la conception de l'entrepôt de données qui constitue le socle de l'ensemble de la chaîne de restitution.

3.2 Description des sources de données

La principale source de données exploitée est l'**Enquête Ménages-Déplacements (EMD)** de Dakar, complétée par des données de **comptage de trafic** issues de capteurs et de relevés sur les principaux sites de comptage du réseau. L'EMD est structurée en plusieurs blocs de variables, identifiées par des codes (I2, I4, I9, M21, M26, M55, M66 à M91, etc.), couvrant :

- les caractéristiques géographiques du domicile (quartier, strate, district de recensement) ;
- les caractéristiques du ménage (taille, type de logement, équipement) ;
- les déplacements individuels (motif, mode, durée, coût) ;
- l'accessibilité aux transports en commun et aux services (école, daara) ;
- les problèmes et manquements perçus dans le quartier (manque de transport, inondations, enclavement, insécurité).

Ces données sources ont fait l'objet d'une priorisation en trois phases afin de structurer le développement de l'ETL de façon incrémentale :

1. **Phase 1 – MVP** : colonnes géographiques (I2, I4, I9), accessibilité de base (M66 à M70), problèmes majeurs (M73, M87) et taille du ménage (M21) ;
2. **Phase 2 – Extension services** : variables d'accès aux écoles et daaras (M90, M91) ;
3. **Phase 3 – Détails avancés** : variables de résilience en cas de pluie (M69), modes de transport vers les services, et autres problèmes de quartier (bruit, insécurité, accidents).

3.3 Dictionnaire de données et qualité des sources

3.3.1 Dictionnaire de données

Afin de documenter précisément le contenu des fichiers sources et leur correspondance avec le modèle décisionnel, un **dictionnaire de données** a été constitué (fichier `Dictionnaire_Donnees_CETUD.xls` dossier CETUD DATA). Il couvre les quatre tables sources exploitées : Menage (231 colonnes brutes), Individu (210 colonnes brutes), Deplacement (11 colonnes) et Trafic (19 colonnes), ainsi qu'un onglet Mapping_DW reliant explicitement chaque colonne source retenue à sa dimension ou son indicateur de destination dans l'entrepôt. Le tableau 3.1 reprend la synthèse de ce mapping.

Table 3.1: Mapping entre les tables de faits, leurs dimensions et leurs tables sources EMD

Table de faits	Dimensions liées	Source EMD	Mesures principales
Fait_Comptage	Dim_Site, Dim_Temps	Trafic	nb_vehicules, volume horaire, flux entrant/sortant, vitesse moyenne
Fait_Deplacement	Dim_Motif, Dim_Mode, Dim_Geographie	Deplacement	durée trajet, heure départ/arrivée, coût total
Fait_IndividuMenage	Dim_Individu, Dim_Menage, Dim_Geographie	Individu + Menage	nb déplacements/jour, taux équipement voiture, taux motorisation

Source	Enquête Ménages-Déplacements (EMD) du CETUD (Conseil Exécutif des Transports Urbains de Dakar, Sénégal) + comptages de trafic
Nature des données	Données réelles fournies par le CETUD - non simulées
Formats sources	Excel (.xls/.xlsx) pour les exports bruts ; CSV pour les versions transformées en entrée de l'ETL Talend
Tables couvertes	Menage, Individu, Deplacement, Trafic

Figure 3.1: Capture d'écran – page de présentation du dictionnaire de données CETUD

Colonne source	Description
Identifiant_source_collecte	Identifiant de la source de collecte du comptage
Description_source_collecte	Libellé de la source de collecte
Type_outil_comptage	Type d'outil utilisé pour le comptage (manuel, automatique...)
Type_comptage	Type de comptage réalisé
Identifiant_site_comptage	Identifiant du site de comptage (49 sites distincts)
Description_site_comptage	Libellé / localisation du site de comptage
GPS_Longitude_site	Longitude GPS du site de comptage
GPS_Latitude_site	Latitude GPS du site de comptage
Sens_circulation	Code du sens de circulation observé
Description_sens_circulation	Libellé du sens de circulation
Jour_comptage	Jour de la semaine du comptage
Date_comptage	Date du comptage
Heure_debut_comptage	Heure de début de la tranche de comptage
Minute_debut_comptage	Minute de début de la tranche de comptage
Amplitude_comptage	Amplitude horaire de la tranche de comptage (en minutes)
Categorie_vehicule	Catégorie de véhicule comptée (VL, PL, moto, etc.)
Nombre_vehicules_amplitude	Nombre de véhicules comptés sur l'amplitude
Vitesse_moyenne_amplitude	Vitesse moyenne observée sur l'amplitude (km/h)

Figure 3.2: Capture d'écran – onglet Mapping_DW du dictionnaire de données

3.3.2 Qualité des données sources

Les données exploitées sont des **données réelles, fournies par le CETUD** (et non des données simulées), issues de l'Enquête Ménages-Déplacements et des campagnes de comptage de trafic.

Une phase de *data discovery* a été menée sous **Google Colab** (notebook EDA_CETUD_DataDiscovery.ipynb, dossier CETUD DATA/02_eda_notebook) afin d'évaluer la qualité de ces sources avant leur intégration dans l'ETL. Cette analyse exploratoire a mis en évidence :

- un **volume de colonnes brutes très hétérogène** entre tables (jusqu'à 231 colonnes pour Menage), nécessitant une phase de sélection/priorisation des variables réellement exploitables (cf. priorisation en trois phases ci-dessus) ;
- une **proportion significative de valeurs manquantes** sur certaines variables déclaratives (notamment le taux de motorisation des ménages et la mobilité des seniors), illustrée à la figure 3.3 ;
- des **formats hétérogènes** entre les exports Excel bruts (.xls/.xlsx) et les fichiers CSV transformés en entrée de Talend, imposant une normalisation des types avant chargement ;
- des **codes de variables non auto-documentés** (codes EMD du type P1, M21, M66, etc.), justifiant la construction du dictionnaire de données comme référentiel central de traduction.




Figure 3.3: Data discovery sous Google Colab – distribution des valeurs manquantes par variable

Ce travail de qualification des sources, réalisé en amont de l'ETL, a directement conditionné la priorisation des variables intégrées (section 3 ci-dessus) et explique l'absence de fiabilité suffisante pour certains indicateurs (taux de motorisation, mobilité des seniors), signalée également au chapitre 6.

3.3.3 Choix du modèle décisionnel

La modélisation multidimensionnelle de l'entrepôt s'appuie sur un **schéma en constellation**, c'est-à-dire un modèle comportant plusieurs tables de faits partageant un ensemble commun de dimensions. Ce choix, plutôt qu'un schéma en étoile classique limité à une seule table de faits, est justifié par la nature même des données du projet : les données de comptage de trafic (issues de capteurs, granularité site/heure) et les données d'enquête ménages-déplacements (granularité individu/déplacement) correspondent à des processus métier distincts, avec des cycles de mise à jour différents, mais partagent des axes d'analyse communs (temps, géographie, site). Un schéma en étoile unique aurait nécessité de forcer ces deux processus métier dans une seule table de faits, au prix d'une perte de granularité ou de la création de mesures non applicables selon le contexte ; le schéma en constellation permet au contraire de conserver une table de faits dédiée à chaque processus, tout en mutualisant les dimensions partagées.




Figure 3.4: Schéma en constellation du modèle décisionnel (4 faits et 9 dimensions)

3.4 Architecture ETL

La chaîne ETL est organisée en deux niveaux successifs :

1. une **zone de préparation (Staging Area, SA)** : jobs chargeant les données brutes, préalablement nettoyées sous Python/Colab, dans des tables intermédiaires, sans transformation lourde ;
2. une **zone de chargement final** : jobs lisant les tables de la Staging Area, appliquant les transformations, jointures et calculs nécessaires (via le composant tMap), puis chargeant les dimensions et les faits dans l'entrepôt de données (DW).

Cette architecture à deux niveaux a été retenue afin de séparer clairement le chargement brut (rapide, peu de logique) de la transformation (jointures de référentiel, résolution de clés étrangères, calculs de mesures), ce qui facilite le débogage et la traçabilité de chaque étape.

3.5 Processus ETL avec Talend

3.5.1 Extraction

L'extraction est réalisée par les composants tFileInputExcel et tFileInputDelimited, qui lisent les fichiers sources (extraits EMD et comptages de trafic), déjà nettoyés en amont via des scripts Python (traitement des valeurs manquantes, normalisation des types, suppression des doublons).

3.5.2 Nettoyage

Au sein de Talend, un nettoyage complémentaire est appliqué via le composant `tFilterColumns`, qui sélectionne uniquement les colonnes utiles conformément à la priorisation définie en section 3 ci-dessus, réduisant ainsi la complexité des jobs et le volume de données transporté.

3.5.3 Transformation

La transformation constitue le cœur du processus ETL, portée par le composant `tMap`. Trois jobs principaux assurent d'abord l'alimentation de la zone de préparation : `SA_individu`, `SA_menage` et `SA_deplacement`, correspondant aux trois grandes entités sources de l'EMD.




Figure 3.5: Job Talend de chargement de la Staging Area – déplacements

Le job `Job_deplacement` illustre ensuite la logique de transformation appliquée pour construire la table de faits `Fact_deplacement`. Le composant `tMap` central réalise les opérations suivantes :

- récupération du flux principal contenant les attributs du déplacement (numéro de ménage, numéro d'individu, lieux et heures de départ/arrivée, durée, motif, fréquence de transport en commun, mode, coût total) ;
- trois jointures (*lookup*) sur les dimensions `Dim_Motif` (par motif), `Dim_Individu` (par clé composite `num_individu + num_menage`) et `Dim_Mode` (par mode) afin de résoudre les clés étrangères ;
- construction du flux de sortie combinant les clés étrangères résolues et les mesures (durée du trajet, lieux, coût total, heures de départ/arrivée, fréquence de transport en commun).




Figure 3.6: Composant tMap du job de construction de Fact_deplacement

Le job de construction de Fact_Comptage suit une logique similaire : une entrée principale portant les mesures de comptage est enrichie par deux jointures de référence via un composant tMap, avant chargement final. Les jobs fact_accessibilite et fact_indivmen suivent le même schéma général, en exploitant respectivement les variables d'accessibilité (durée de marche, modes disponibles, exposition aux inondations) et les variables croisées individu/ménage (taille du ménage, équipement, motorisation).




Figure 3.7: Job Talend de construction de Fact_Comptage

3.5.4 Chargement

Le chargement final dans l'entrepôt de données est réalisé par le composant tDBOutput, qui écrit successivement les dimensions de référence (Dim_Site, Dim_Geographie, Dim_Individu,

Dim_Menage) puis les tables de faits, afin de garantir l'intégrité référentielle au moment du chargement.




Figure 3.8: Jobs de construction des dimensions de référence

3.6 Conception du Data Warehouse

3.6.1 Tables de faits

Le modèle retenu comporte trois tables de faits.

Fait_Comptage. Enregistre les mesures issues des dispositifs de comptage automatique de trafic, à la granularité du site et de l'heure (clés étrangères : FK_id_Site, FK_id_temps ; mesures : nombre de véhicules, volume horaire matin/soir, flux entrant, flux sortant, désagrégation directionnelle).

Fait_Déplacement. Décrit chaque déplacement individuel déclaré, à la granularité du déplacement (clés étrangères : FK_id_motif, FK_id_mode, FK_id_zone_residence ; mesures : durée du trajet, heures de départ/arrivée, coût total, temps de parcours par motif).

Fait_IndividuMenage. Croise les informations individuelles et celles du ménage, à la granularité de l'individu enquêté (clés étrangères : FK_id_individu, FK_id_menage, FK_id_zone_residence ; mesures : nombre de déplacements journaliers, taux d'équipement en voiture, taux de motorisation, mobilité par zone).

3.6.2 Dimensions

Le modèle comporte neuf dimensions, dont le dictionnaire est présenté au tableau 3.2.

Table 3.2: Dictionnaire des dimensions du modèle décisionnel

Dimension	Attributs principaux	Granularité
Dim_Site	id_Site, code_site, Ouhl_Soc, catégorie_unité, DESC_Site, Sens	Site de comptage
Dim_Temps	id_temps, année, mois, jour, heure, heure début/fin déplacement	Heure / jour
Dim_Motif	id_motif, code_motif, motif_origine	Motif de déplacement
Dim_Individu	id_individu, num_individu, sexe, statut matrimonial, profession, permis	Individu
Dim_Mode	id_mode, code_mode, libellé, catégorie_mode	Mode de transport
Dim_Menage	id_menage, num_menage, statut occupation, type logement, équipements	Ménage
Dim_Geographie	id_zone_residence, code_zone, quartier, strate, département	Zone géographique (507 zones)
Dim_Service	id_service, code_service, libellé_service, type_service, opérateur	Service de transport
Dim_Difficulte	id_difficulte, code_difficulte, libellé_difficulte, catégorie_difficulte	Type de difficulté d'accès

3.6.3 Hiérarchies


Plusieurs hiérarchies d'agrégation sont exploitables sur ces dimensions : Dim_Temps (heure → jour → mois → année), Dim_Geographie (zone de résidence → quartier → strate → département), et Dim_Individu (individu → ménage). Ces hiérarchies permettent de restituer les indicateurs à différents niveaux de granularité dans le cockpit Knowage, sans nécessiter de retraitement de l'entrepôt.

3.6.4 Mesures et indicateurs

Au-delà des mesures directement issues des sources, plusieurs indicateurs calculés ont été intégrés au modèle : le **score d'accessibilité** (0 à 100), composite, intégrant une pénalité liée à la durée de marche jusqu'à l'arrêt le plus proche (jusqu'à -40 points), un bonus de diversité des modes disponibles (jusqu'à +20 points), une pénalité de zone inondable (-25 points, aggravée de -20 points supplémentaires en l'absence de mode disponible en cas de pluie) et une pénalité de tarification abusive en période de pluie (-15 points) ; la **vulnérabilité climatique**, combinant exposition aux inondations et absence de solution de repli ; et l'**impact sur l'éducation**, mesurant le lien entre accessibilité aux transports et accès aux structures scolaires. Le score d'accessibilité permet de classer chaque zone selon une typologie à quatre niveaux : *Bien desservie* (≥ 75), *Moyenne* (≥ 50), *Sous-desservie* (≥ 25) et *Critique* (< 25).

3.6.5 Implémentation physique

L'entrepôt de données a été déployé dans un schéma dédié (DW) au sein d'une base PostgreSQL. Chaque table de dimension est préfixée Dim_ et chaque table de faits Fact_, conformément aux conventions de nommage usuelles en modélisation décisionnelle. Les clés primaires des dimensions sont des entiers auto-incrémentés (PK_id...), repris en clé étrangère dans les tables de faits (FK_id...). La structure physique de chaque table a été vérifiée via pgAdmin, par interrogation du catalogue système `information_schema.columns`.



The screenshot shows the pgAdmin interface. At the top, a SQL query is entered in the editor:

```
1 SELECT column_name, data_type
2 FROM information_schema.columns
3 WHERE table_name = 'Fact_comptage';
```

Below the editor, the 'Data Output' tab is active, displaying the results of the query in a table format. The table has two columns: 'column_name' and 'data_type'. The results are as follows:

	column_name	data_type
1	PK_id_Comptage	integer
2	FK_id_site	integer
3	FK_id_temps	integer
4	GPS_X	double precision
5	GPS_Y	real
6	Amplitude	integer
7	VOLUME_SECT	integer

Figure 3.9: Structure de la table Fact_Comptage (pgAdmin)

La dimension géographique (Dim_Geographie) illustre la richesse du référentiel mis en place : elle recense 507 zones de résidence, chacune associée à une strate et un quartier de domicile. Une table `fact_access` a par ailleurs été ajoutée au modèle initial afin de porter spécifiquement les mesures liées à l'accessibilité (score d'accessibilité, durée de marche, nombre de modes disponibles, indicateur de zone inondable), en lien avec les dimensions Dim_Difficulte, Dim_Service et Dim_Transport.

Query Query History

```
1 SELECT * FROM "DW"."Dim_Geographie"
2 ORDER BY pk_id_zone_residence ASC
```

Data Output Messages Notifications

Showing rows: 1 to 507

	Strate character varying	Quartier_du_domicil character varying	pk_id_zone_residence [PK] integer
1	MALIKA/YEUMBEUL NORD	262	1
2	PLATEAU	58	2
3	MEDINA/GOUNASS	119	3
4	MALIKA/YEUMBEUL NORD	260	4
5	CAMBERENE	5	5
6	DJIDAH/THIARROYE/KAO/YEUMB SUD	230	6
7	GUINAW RAIL N - S/PIKINE OUEST	256	7
8	SAM NOTAIRES	122	8
9	OUAKAM	44	9
10	DALIFORD	208	10
11	FANN/POINT E/AMITIE	14	11
12	RUFISQUE EST	328	12
13	JAXAAY PARCELLE NIAKOUL RAP TIVADUANE PEULH-NIAGHA	311	13
14	MEDINA	35	14
15	MEDINA/GOUNASS	116	15
16	GRAND YOFF	7	16
17	PATTE D'OIE	54	17
18	HANN/BEL AIR	63	18

Total rows: 507 Query complete 00:00:00.330

Figure 3.10: Extrait de la table Dim_Geographie (507 zones)

L'outil pgAdmin a été utilisé tout au long du projet pour vérifier la structure des tables après chaque chargement Talend, contrôler les volumes chargés, détecter les valeurs manquantes ou aberrantes, et exécuter des requêtes SQL de contrôle qualité. Ce contrôle a notamment permis d'identifier l'absence de données fiables pour le taux de motorisation des ménages et la mobilité des seniors, indicateurs qui n'ont donc pu être que partiellement renseignés.

3.7 Conclusion

Ce chapitre a détaillé la conception décisionnelle de la solution : les sources de données, l'architecture et la mise en œuvre du processus ETL avec Talend, et la conception complète de l'entrepôt de données PostgreSQL. Ce socle décisionnel alimente directement le cockpit Knowage et l'ensemble des restitutions présentées au chapitre 6. Le chapitre suivant détaille le développement de la plateforme applicative qui expose cette chaîne décisionnelle aux utilisateurs finaux.

Chapitre 4

Intégration du Machine Learning

4.1 Motivation

Au-delà du reporting descriptif assuré par l'entrepôt de données et le cockpit Knowage, le projet intègre quatre familles de modèles de Machine Learning afin de répondre à des besoins analytiques plus avancés : segmenter les usagers selon leur profil de mobilité, recommander un mode de transport personnalisé, détecter les anomalies de trafic et prédire les zones à risque d'inaccessibilité. Cette dimension prédictive constitue l'apport distinctif du projet par rapport à une solution de Business Intelligence classique, en permettant aux décideurs du CETUD d'anticiper plutôt que de simplement constater.

4.2 Pourquoi un entraînement direct sur les sources

Contrairement au cockpit Knowage, qui interroge l'entrepôt de données PostgreSQL, les modèles de Machine Learning de ce projet sont entraînés et exploités directement à partir des fichiers sources nettoyés (extraits EMD et comptages de trafic), sans passer par l'entrepôt de données. Ce choix est motivé par trois raisons :

- le modèle décisionnel de l'entrepôt a été conçu pour répondre à des besoins de reporting agrégé (KPI, tableaux de bord), et certaines variables individuelles nécessaires aux modèles (par exemple l'ensemble des réponses détaillées de l'EMD utilisées en feature engineering) n'y sont pas toutes représentées à la granularité requise ;
- l'entraînement de modèles de Machine Learning nécessite des itérations rapides sur les données (sélection de variables, comparaison d'algorithmes), un cycle plus proche du travail exploratoire en Python/Colab que des cycles de chargement par lots de l'ETL ;
- découpler les deux chaînes (décisionnelle classique vers le DW, prédictive vers les sources nettoyées) permet de faire évoluer les modèles de Machine Learning indépendamment du calendrier de mise à jour de l'entrepôt de données, sans risque de régression sur le reporting existant.

Ce choix architectural ne remet pas en cause la cohérence de la solution : les sources utilisées par les modèles sont les mêmes données nettoyées qui alimentent par ailleurs l'ETL Talend, garantissant que les deux chaînes restent fondées sur un référentiel de données identique.

4.3 Pipeline de Machine Learning

Les quatre modèles partagent un pipeline méthodologique commun, décliné selon les spécificités de chaque tâche.

4.3.1 Prétraitement

Les valeurs manquantes sont traitées par imputation : médiane pour les variables numériques (robuste aux valeurs extrêmes), valeur la plus fréquente pour les variables catégorielles. Les variables catégorielles sont encodées, et les variables numériques normalisées (`StandardScaler`) lorsque l'algorithme utilisé est sensible à l'échelle des variables (K-Means notamment).

4.3.2 Feature engineering

Selon le modèle, des variables dérivées sont construites : agrégation de plusieurs indicateurs binaires en un score composite (modèle d'inaccessibilité), construction de statistiques par mode et par segment (durée, coût), ou encore calcul de scores de distance et de densité pour la détection d'anomalies spatiales.

4.3.3 Sélection des variables

La sélection des variables s'appuie sur une combinaison d'expertise métier (variables identifiées comme pertinentes lors de l'analyse des besoins, chapitre 1) et d'analyse statistique (importance des variables calculée a posteriori sur les modèles arborescents, permettant de valider ou d'écarter certaines variables candidates).

4.3.4 Entraînement

Chaque modèle est entraîné avec une validation croisée stratifiée à 5 plis (`StratifiedKFold`) lorsque la tâche est supervisée, garantissant une estimation robuste des performances et limitant le risque de surapprentissage.

4.3.5 Évaluation

Les modèles non supervisés sont évalués par des métriques internes (coefficient de silhouette, méthode du coude). Les modèles supervisés sont évalués par exactitude, F1-score, précision, rappel et aire sous la courbe ROC (ROC AUC), avec une attention particulière à l'équilibre précision/rappel sur les classes minoritaires.

4.3.6 Sauvegarde

Chaque modèle entraîné, ainsi que les objets de prétraitement associés (`scaler`, `encoder`) et les métadonnées (liste des variables, métriques de performance), sont sérialisés au format `.pkl` via `joblib`, afin d'être chargés tels quels par le backend FastAPI sans nouvel entraînement.

4.4 Présentation des modèles

4.4.1 Segmentation des usagers (K-Means)

Objectif. Regrouper les individus enquêtés en profils de mobilité homogènes, afin de permettre des analyses et des recommandations différenciées par segment.

Variables. Variables sociodémographiques et de mobilité de l'enquête individus : âge, sexe, statut d'activité, niveau d'instruction, possession du permis, fréquence d'utilisation des transports en commun, nombre de déplacements, nombre de véhicules, revenu.




Figure 4.1: Exploration des données individus avant segmentation

Algorithme. KMeans (scikit-learn), avec normalisation préalable des variables (StandardScaler) afin d'éviter qu'une variable à forte variance (le revenu, notamment) ne domine artificiellement le calcul de distance euclidienne. Le nombre optimal de clusters a été déterminé en combinant la méthode du coude (inertie intra-cluster en fonction de k) et le coefficient de silhouette, conduisant à retenir $k = 3$.




Figure 4.2: Détermination du nombre optimal de clusters (méthode du coude + silhouette)

Résultats. Coefficient de silhouette $\approx 0,240$ pour $k = 3$. Trois segments ont été identifiés et caractérisés (tableau 4.1) : Actifs motorisés, Étudiants mobilité douce, Travailleurs informels.

Table 4.1: Segments d'utilisateurs identifiés par K-Means

Segment	Profil type	Mode dominant
Actifs motorisés	~40 ans, actif, permis, revenu élevé	Voiture / Taxi
Étudiants	~20 ans, étudiant, budget faible	Marche / TC
Travailleurs formels	~30 ans, actif informel, mobilité mixte	TC / Moto




Figure 4.3: Caractérisation des segments par variable (heatmap)

Intégration. Le modèle est exposé via l'endpoint GET `/api/segmentation/profils` et restitué dans la page `SegmentationPage` de l'espace décideurs.

4.4.2 Recommandation de mode de transport (Random Forest)

Objectif. Recommander, pour un profil d'utilisateur donné, le ou les modes de transport les plus adaptés parmi l'ensemble des modes disponibles (transport en commun, voiture, taxi/clando, marche, moto).

Variables. Profil socio-démographique (âge, sexe, statut, niveau d'instruction, permis), habitudes de mobilité (fréquence d'usage des TC, nombre de déplacements, nombre de véhicules), et revenu.

Algorithme. `RandomForestClassifier` (scikit-learn), 200 arbres (`n_estimators=200`), profondeur maximale 10 (`max_depth=10`) pour limiter le surapprentissage, pondération des classes (`class_weight='balanced'`) pour compenser le déséquilibre entre modes, validé par validation croisée stratifiée à 5 plis.

Résultats. Exactitude $\approx 80,15\%$.




Figure 4.4: Matrice de confusion du modèle de recommandation de mode

Intégration. En production, le modèle retourne, via l'endpoint `POST /recommander`, non pas une seule prédiction mais le *top 3* des modes les plus probables avec leurs probabilités, enrichi par des statistiques de durée et de coût (quartiles Q1/médiane/Q3) calculées par mode et par segment, ce qui permet de fournir au citoyen une recommandation nuancée plutôt qu'une réponse binaire.

4.4.3 Détection d'anomalies de trafic

Objectif. Détecter, parmi les comptages de trafic, des comportements anormaux : pics de volume inattendus, schémas horaires incohérents, sites présentant un comportement différent de leurs voisins géographiques.

Variables. Volumes de comptage par site et par heure, position géographique (GPS) des sites de comptage.

Algorithme. Trois algorithmes complémentaires sont appliqués en parallèle puis combinés par un vote pondéré (tableau 4.2), une observation étant déclarée anormale lorsque le score combiné dépasse le seuil de 0,6. Un clustering spatial DBSCAN est ensuite appliqué sur les coordonnées GPS des sites détectés comme anormaux (rayon $\text{eps} \approx 500$ mètres, minimum 3 sites pour former un groupe), afin de distinguer les *hotspots* de congestion structurelle des incidents ponctuels isolés.

Table 4.2: Algorithmes de détection d'anomalies et pondération du consensus

Algorithme	Poids	Principe
Z-Score	0,25	Détection univariée des valeurs extrêmes par site
Isolation Forest	0,40	Détection multivariée par isolement aléatoire (arbres)
Local Outlier Factor (LOF)	0,35	Détection par densité locale (comparaison aux voisins)

Résultats. Cette approche par consensus réduit significativement les faux positifs par rapport à l'utilisation d'un seul algorithme, chaque méthode ayant des forces complémentaires : le Z-Score est rapide et interprétable mais univarié, l'Isolation Forest est robuste sur des données multivariées sans hypothèse de distribution, et le LOF détecte les anomalies de densité locale invisibles aux deux autres méthodes.




Figure 4.5: Tableau de bord de synthèse des anomalies de trafic détectées

Intégration. Les résultats sont exposés via les endpoints GET /api/anomalies/summary et GET /api/anomalies/sites, et restitués dans la page AnomalyDashboard avec drill-down par site de comptage.

4.4.4 Prédiction du risque d'inaccessibilité

Objectif. Prédire, pour une zone ou un ménage donné, le risque d'inaccessibilité aux transports en commun, afin d'orienter les décisions d'investissement en infrastructure.

Variables. Sept indicateurs terrain (distance TC, inondation, enclavement, acces sante...). Ces sept indicateurs sont combinés en un score composite, dont le seuil de classification (ménage à risque ou non) est fixé au 60^e percentile.

Algorithme. Le pipeline complet comprend l'imputation -> encodage -> normalisation -> SMOTE -> validation croisée stratifiée (4 algorithmes comparés). Le modèle **XGBoost** a été retenu comme modèle final, offrant les meilleures performances sur ce jeu de données déséquilibré.

Résultats. Le tableau 4.3 synthétise les performances obtenues.

Table 4.3: Performances du modèle de prédiction d'inaccessibilité (XGBoost)

Métrique	Valeur
ROC AUC	89 %
F1-score	72 %




Figure 4.6: Cartographie des zones classées par niveau de risque d'inaccessibilité

L'analyse de l'importance des variables (figure 4.7) confirme que les variables les plus déterminantes sont : Innodations, distance à pied jusqu'à l'arrêt TC, et durée d'accès aux soins de santé.




Figure 4.7: Importance des variables du modèle de prédiction d'inaccessibilité

Une analyse complémentaire par valeurs de Shapley (SHAP) a été menée afin de renforcer l'explicabilité du modèle auprès des décideurs (figure 4.8), en détaillant, pour chaque prédiction individuelle, la contribution positive ou négative de chaque variable au score de risque.




Figure 4.8: Analyse d'explicabilité SHAP du modèle de prédiction d'inaccessibilité

Intégration. Le modèle est exposé via l'endpoint POST /predict-inaccessibility, et restitué à la fois dans la page ZonesRisquePage (cartographie des zones) et dans la page SimulateurRisque, qui permet à un décideur de faire varier les sept indicateurs pour simuler le score de risque d'une zone hypothétique.

4.5 Bilan des modèles de Machine Learning

Le tableau 4.4 présente une synthèse comparative des quatre modèles intégrés dans la solution.

Table 4.4: Synthèse des modèles de Machine Learning

Modèle	Type	Objectif	Performance
K-Means ($k = 3$)	Non supervisé	Segmentation des us- agers	Silhouette $\approx 0,240$
Random Forest	Supervisé	Recommandation de mode	Accuracy $\approx 80,15\%$
Z-Score + Isolation Forest + LOF	Détection d'anomalies	Anomalies de trafic	Consensus pondéré $\geq 0,6$ – Accord inter-modèles 90,6%
XGBoost	Supervisé	Prédiction d'inaccessibilité	ROC AUC = 0,89

4.6 Intégration dans FastAPI

Les quatre modèles, ainsi que leurs objets de prétraitement et métadonnées, sont chargés en mémoire une seule fois au démarrage du serveur FastAPI, dans un bloc de chargement global qui interrompt volontairement le démarrage si un fichier de modèle venait à manquer (afin d'éviter de servir des prédictions incohérentes). Les endpoints orchestrent ensuite, à chaque requête, la construction des features à partir des données transmises, l'appel au modèle déjà chargé, puis le formatage de la réponse au format JSON attendu par le frontend.

4.7 Exploitation des prédictions

Du côté citoyen, les prédictions du modèle de recommandation alimentent directement le parcours de planification de trajet (FormPage). Du côté décideurs, les prédictions des trois autres modèles sont exploitées de façon complémentaire : la segmentation guide la priorisation des actions de communication et d'adaptation de l'offre par profil d'utilisateur ; la détection d'anomalies alerte sur les dysfonctionnements de trafic nécessitant une intervention opérationnelle ; et la prédiction du risque d'inaccessibilité oriente les décisions d'investissement en infrastructure, avec un outil de simulation permettant d'évaluer l'impact attendu d'un projet avant sa réalisation.

4.8 Valeur ajoutée de l'intelligence artificielle

L'intégration de ces quatre modèles transforme la solution d'un outil de reporting descriptif en un outil d'aide à la décision véritablement prédictif et prescriptif : au lieu de seulement constater des volumes de trafic ou des taux d'accessibilité passés, le système est désormais capable d'anticiper les comportements (segmentation, recommandation) et les risques (anomalies, inaccessibilité), avec un niveau de transparence (importance des variables, explicabilité SHAP) qui permet aux décideurs du CETUD d'auditer et de faire confiance aux résultats produits.

4.9 Conclusion

Ce chapitre a présenté l'intégration du Machine Learning au sein de la solution : la justification du choix d'un entraînement direct sur les sources, le pipeline méthodologique commun aux quatre modèles, leur présentation détaillée (segmentation, recommandation, détection d'anomalies, prédiction d'inaccessibilité), leur intégration technique dans le backend FastAPI, et la valeur ajoutée qu'ils apportent aux décideurs du CETUD. Le chapitre suivant présente le développement de la plateforme applicative qui expose ces résultats aux utilisateurs.

Chapitre 5

Développement de la plateforme décisionnelle

5.1 Introduction

Conformément à la troisième étape de la méthodologie GIMSI (mise en œuvre), ce chapitre détaille le développement de la plateforme applicative qui expose la chaîne décisionnelle conçue au chapitre précédent : son architecture, le backend FastAPI, le frontend React, l'intégration du cockpit Knowage, et les mesures de sécurité mises en place.

5.2 Architecture de l'application

L'application repose sur une architecture client-serveur classique en trois couches : un **backend** développé avec FastAPI (Python), exposant une dix-huitaine de points d'accès REST avec validation des entrées par schémas Pydantic et documentation interactive automatique (Swagger) ; un **frontend** développé avec React 18, organisé autour d'un routeur central (App.js) et d'un contexte de thème (ThemeProvider) gérant le mode clair/sombre ; et une couche de **contrôle d'accès** (RBAC) distinguant les rôles *citoyen*, *chef d'exploitation* et *directeur de planification*, chacun disposant d'un périmètre fonctionnel différent. Les deux couches communiquent exclusivement par requêtes HTTP au format JSON, le frontend interrogeant le backend via l'API native `fetch` (aucune bibliothèque tierce de type `axios` n'est utilisée).

La figure ?? présente la vue d'ensemble de la chaîne technique complète, couvrant les deux pipelines indépendants (décisionnel BI et prédictif ML) et leur point de jonction dans l'application React.




Figure 5.1: Page d'accueil citoyenne (WelcomePage)

La page d'accueil présente la démarche au grand public en langage simple et oriente vers le formulaire de recommandation. Son intérêt est d'abaisser la barrière d'entrée pour des usagers non avertis et de garantir l'adhésion au dispositif de collecte de données, condition nécessaire à l'alimentation de l'entrepôt et des modèles de Machine Learning.

Figure 5.2: Formulaire citoyen et recommandation de mode de transport (FormPage)

Le formulaire en quatre étapes (Profil, Situation, Trajet, Budget) collecte les variables nécessaires à la recommandation et adapte dynamiquement les champs affichés selon les réponses (par exemple, selon l'âge déclaré). Son intérêt est double : pour le citoyen, obtenir une recommandation personnalisée de mode de transport ; pour la plateforme, constituer progressivement un jeu de données réel et qualifié sur les habitudes de mobilité dakaroises, complémentaire à l'enquête EMD historique.




Figure 5.3: Cellule d'écoute publique – dépôt et restitution des avis citoyens (AvisCitoyenPage)

Cet écran permet à tout citoyen de noter son expérience de transport et de signaler un problème (attente, ponctualité, confort, etc.), avec une restitution en direct de la note moyenne et des derniers commentaires. Son intérêt est de fournir aux décideurs un canal de remontée qualitative continu, complémentaire aux indicateurs quantitatifs du cockpit, et de matérialiser concrètement la voix de l'utilisateur dans le dispositif décisionnel.

5.2.1 Authentification des décideurs




Figure 5.4: Page de connexion de l'espace décideurs (LoginDecideurs)

L'espace décideurs est protégé par une authentification dédiée (jeton JWT, voir section 5.3), distincte du parcours citoyen qui ne nécessite aucun compte. Cette page présente également les modules disponibles et les indicateurs clés du projet, afin de contextualiser l'outil avant même la connexion.

5.2.2 Espace décisionnel




Figure 5.5: Vue générale – tableau de bord de synthèse (VueGenerale)

La vue générale agrège, en un seul écran, les indicateurs clés (KPI) de trafic, de déplacements et les objectifs du projet. Elle constitue le point d'entrée du décideur après connexion et a vocation à offrir une vision d'ensemble immédiate, volontairement épurée, sans détailler les zones à risque – ce niveau de détail étant renvoyé vers les modules spécialisés afin de ne pas surcharger cette vue de synthèse.




Figure 5.6: Cockpit Knowledge intégré, mode clair (CockpitDakar)




Figure 5.7: Cockpit Knowage intégré, mode sombre (CockpitDakar)

Le cockpit Knowage est intégré directement dans l'application React via une *iframe* en *same-origin*, et hérite du thème clair/sombre choisi par l'utilisateur. Son intérêt est de donner accès, sans rupture de navigation, à l'ensemble des sheets BI détaillés (Trafic, Déplacements, Démographie, Accessibilité, IA) construits sur l'entrepôt de données, en conservant une cohérence visuelle complète avec le reste de la plateforme.




Figure 5.8: Zones à risque d'inaccessibilité – vue exploitation (ZonesRisquePage)




Figure 5.9: Zones à risque d'inaccessibilité – cartographie interactive

Ce module restitue le classement des zones selon leur score de risque d'inaccessibilité (modèle de classification, chapitre 4) à la fois sous forme de tableau classé et de carte interactive (Leaflet). Son intérêt opérationnel est de prioriser concrètement les zones d'intervention (renforcement de l'offre, nouvelles lignes) et de permettre l'export PDF du diagnostic pour partage avec les parties prenantes du CETUD.




Figure 5.10: Simulateur interactif du score de risque (SimulateurRisque)

Le simulateur permet de faire varier manuellement les paramètres d'une zone (distance aux axes, densité de population, fréquence du service, etc.) et d'observer en temps réel l'effet sur le score de risque prédit par le modèle. Son intérêt est de transformer le modèle de Machine Learning, habituellement perçu comme une boîte noire, en un outil d'aide à la décision exploratoire : le décideur peut tester des scénarios d'amélioration avant tout investissement réel.




Figure 5.11: Détection d'anomalies de trafic (AnomalyDashboard)

Ce tableau de bord restitue les anomalies de comptage de trafic détectées automatiquement (modèle non supervisé, chapitre 4), localisées sur une carte et filtrables selon le profil exploitation ou planification. Son intérêt est de signaler de façon proactive des situations atypiques (sur- ou sous-fréquentation inattendue) qui passeraient inaperçues dans une lecture purement tabulaire des données de trafic.




Figure 5.12: Segmentation des usagers par profil de mobilité (SegmentationPage)

La segmentation (K-Means) regroupe les usagers en profils homogènes de mobilité et restitue les caractéristiques type de chaque segment. Son intérêt est de permettre une communication et des politiques de transport ciblées par profil (par exemple, des actions différenciées pour les usagers captifs des transports informels et pour les usagers multimodaux), plutôt qu'une approche uniforme.



Figure 5.13: Évolution temporelle des indicateurs (EvolutionTemporelle)

Ce module retrace l'évolution des indicateurs clés sur la période 2010–2023 et permet de resituer les données EMD dans une perspective historique. Son intérêt est de donner au décideur le recul nécessaire pour distinguer une tendance structurelle d'une variation conjoncturelle avant toute décision d'investissement.




Figure 5.14: Satisfaction et écoute citoyenne – vue décideur agrégée (SatisfactionPage)

Cet écran restitue, côté décideur, l'agrégation des avis citoyens déposés via la cellule d'écoute publique (note moyenne, répartition des problèmes signalés, derniers commentaires). Son intérêt est de boucler le dispositif décisionnel : les remontées qualitatives des citoyens deviennent directement visibles et exploitables par les décideurs, au même titre que les indicateurs quantitatifs du cockpit.

5.2.3 Audit des modèles de Machine Learning – accès restreint




Figure 5.15: Transparence et audit des modèles de Machine Learning (MLInsights)

Ce module restitue les métriques de performance, l'importance des variables et les éléments de transparence des modèles de Machine Learning utilisés par la plateforme (classification du risque, détection d'anomalies, segmentation). Son intérêt est de permettre un audit critique des modèles avant qu'ils ne fondent des décisions opérationnelles, conformément à une exigence minimale d'explicabilité de l'IA dans un contexte de service public.

Ce module n'est volontairement pas accessible aux deux profils de décideurs de la même façon. Comme indiqué au tableau ?? et à la section 5.3, seul le rôle **Directeur de planification** dispose de la route `/ml-insights` dans son tableau `allowedRoutes` ; le rôle **Chef d'exploitation** ne l'a pas. Concrètement, pour ce dernier, l'entrée « Audit & Insights ML » reste visible dans le menu mais apparaît grisée, non cliquable, accompagnée d'un cadenas et d'une infobulle « Accès refusé – rôle Chef d'exploitation », le contrôle étant appliqué à la fois côté frontend (`canAccess`, `DecideursLayout.jsx`) et côté backend (dépendance `get_current_decideur` sur l'endpoint correspondant). Ce choix reflète une séparation des responsabilités : l'audit technique des modèles relève d'une décision stratégique (validation de la fiabilité des modèles avant qu'ils n'influencent les politiques de transport), tandis que le chef d'exploitation, orienté vers la gestion opérationnelle quotidienne (trafic, anomalies, zones à risque), n'a pas besoin de ce niveau de détail technique pour exercer ses missions. Toutes les autres pages décrites ci-dessus (vue générale, cockpit Knowage, zones à risque, simulateur, anomalies, segmentation, évolution temporelle, satisfaction) sont accessibles de façon identique aux deux profils.

5.2.4 Cockpit Knowage – rendu des six sheets




Figure 5.16: Sheet *Accueil* du cockpit Knowage – mode clair

Le sheet *Accueil* centralise les indicateurs de cadrage du projet et assure la navigation entre les sheets thématiques grâce à des boutons HTML.




Figure 5.17: Sheet *Trafic* (gauche) et sheet *Déplacements* (droite)

Le sheet *Trafic* détaille les comptages horaires, la répartition par site et les heures de pointe. Le sheet *Déplacements* analyse les durées, motifs et coûts des trajets déclarés dans l'enquête EMD.




Figure 5.18: Sheet *Démographie* (gauche) et sheet *Accessibilité* (droite)

Le sheet *Démographie* restitue le profil sociodémographique des individus enquêtés. Le sheet *Accessibilité* présente le score composite d'accessibilité par zone géographique.




Figure 5.19: Sheet *IA* – restitution synthétique des résultats de Machine Learning dans le cockpit Knowage

Le sheet *IA* est un feuillet statique qui synthétise, sous forme de fiches descriptives, les principaux résultats des modèles de Machine Learning (prédiction du risque, segmentation, anomalies), en renvoyant le décideur vers les modules interactifs de l'application pour l'exploration détaillée. Leur intérêt commun est de démontrer la capacité de l'outil BI choisi à être personnalisé visuellement (charte TransportDakar) au-delà de son habillage par défaut, et à rester exploitable de façon autonome par un analyste habitué à Knowage.

5.3 Sécurité de l'application

La sécurité de la plateforme repose sur trois piliers : l'**authentification** par jeton JWT signé (HS256), avec vérification systématique côté serveur pour les routes protégées ; le **contrôle d'accès basé sur les rôles** (RBAC), distinguant citoyen, chef d'exploitation et directeur de

planification, appliqué à la fois côté backend (dépendance `get_current_decideur`) et côté frontend (`allowedRoutes`, `ProtectedRoute`) ; et la **validation systématique des entrées** côté backend par les schémas Pydantic, qui rejettent automatiquement toute requête mal formée avant qu'elle n'atteigne la logique métier ou les modèles de Machine Learning.

5.4 Conclusion

Ce chapitre a détaillé le développement de la plateforme applicative : son architecture, le backend FastAPI et ses dix-huit endpoints, le frontend React et son organisation en pages publiques et protégées, l'intégration du cockpit Knowage, et les mécanismes de sécurité mis en place. Le chapitre suivant présente une évaluation transversale des résultats obtenus par la solution dans son ensemble.

Chapitre 6

Résultats et évaluation

6.1 Introduction

Conformément à la quatrième étape de la méthodologie GIMSI (amélioration permanente), ce chapitre présente une évaluation transversale des résultats obtenus : les tableaux de bord produits, l'analyse des indicateurs clés, les résultats des modèles de Machine Learning, une comparaison entre l'apport de la Business Intelligence classique et celui du Machine Learning, l'apport global de la solution, ainsi que ses limites et perspectives d'amélioration.

6.2 Présentation des dashboards

Le cockpit Knowage BI restitue l'ensemble des indicateurs descriptifs de l'entrepôt de données à travers cinq sheets thématiques : *Accueil* (vue de synthèse), *Trafic*, *Déplacements*, *Démographie* et *Accessibilité*, complétées par un sheet *IA* restituant de façon synthétique les résultats des modèles de Machine Learning. Côté application web, les décideurs disposent en complément de tableaux de bord dédiés (*VueGenerale*, *ZonesRisquePage*, *AnomalyDashboard*, *SegmentationPage*) permettant une navigation et un drill-down plus fins que dans le cockpit BI seul.



Figure 6.1: Identité visuelle du cockpit décisionnel TransportDakar

6.3 Analyse des KPIs

L'entrepôt de données alimente un ensemble cohérent d'indicateurs clés, synthétisés au tableau 6.1.

Table 6.1: Synthèse des indicateurs clés produits par la solution

Indicateur	Valeur
Individus enquêtés (EMD)	37 248
Ménages enquêtés (EMD)	4 521
Sites de comptage de trafic	49
Observations de trafic chargées	775 480
Zones géographiques référencées	507

L'analyse de ces indicateurs met en évidence des disparités marquées de mobilité et d'accessibilité selon les zones : certains quartiers périphériques cumulent un score d'accessibilité faible, une forte exposition aux inondations et une dépendance quasi exclusive à la marche, tandis que les zones centrales bénéficient d'une offre de transport diversifiée et d'un score d'accessibilité élevé.

6.4 Résultats des modèles ML

Le tableau 6.2 récapitule les performances des quatre modèles de Machine Learning présentés au chapitre 4.

Table 6.2: Synthèse des performances des modèles de Machine Learning

Modèle	Type	Objectif	Performance
K-Means ($k = 3$)	Non supervisé	Segmentation des usagers	Silhouette $\approx 0,240$
Random Forest	Supervisé	Recommandation de mode	Accuracy $\approx 80,15\%$
Z-Score + Isolation Forest + LOF + DBSCAN	Détection d'anomalies	Anomalies de trafic	Consensus pondéré $\geq 0,6$ – Accord inter-modèles $90,6\%$
XGBoost	Supervisé	Prédiction d'inaccessibilité	ROC AUC = $0,89$

Ces performances témoignent de la pertinence des variables sélectionnées et de la qualité du travail de prétraitement effectué en amont : le modèle de recommandation atteint une exactitude de $80,15\%$, le modèle de prédiction d'inaccessibilité un ROC AUC de $0,89$, et la segmentation produit un coefficient de silhouette de $0,240$ pour $k = 3$ clusters.

6.5 Comparaison BI vs ML

Le tableau 6.3 compare les apports respectifs du volet Business Intelligence classique (ETL, entrepôt, cockpit Knowage) et du volet Machine Learning de la solution.

Table 6.3: Comparaison des apports de la BI classique et du Machine Learning

Critère	Business Intelligence (Knowage)	Machine Learning
Nature de l'analyse	Descriptive (constat, agrégation)	Prédictive et exploratoire (anticipation, segmentation)
Horizon	Passé / présent	Présent / futur probable
Granularité	Agrégée (zone, période)	Individuelle (ménage, site, déplacement)
Explicabilité	Élevée (requêtes SQL directes)	Variable (nécessite des outils dédiés, ex. SHAP)
Mise à jour	Par lot ETL (cycle programmé)	Ré-entraînement périodique sur les sources
Valeur pour le décideur	Suivi, reporting régulier	Aide à la décision, simulation, alerte

Ces deux volets ne sont pas concurrents mais complémentaires : la Business Intelligence répond aux besoins de suivi régulier et de gouvernance des indicateurs, tandis que le Machine Learning apporte une capacité d'anticipation que le reporting descriptif ne peut pas offrir par construction.

6.6 Apport global

La solution développée transforme la gestion de la donnée du CETUD à trois niveaux : elle **centralise** des données auparavant dispersées et exploitées de façon ponctuelle dans un entrepôt de données structuré et documenté ; elle **automatise** la production des indicateurs clés, qui étaient auparavant recalculés manuellement à chaque besoin ; et elle **enrichit** l'analyse par des capacités prédictives (segmentation, détection d'anomalies, prédiction de risque) absentes du dispositif antérieur. L'intégration de l'ensemble dans une application web unique, accessible aussi bien au grand public qu'aux décideurs du CETUD, constitue enfin un apport en termes de diffusion et d'appropriation de la donnée, au-delà du seul cercle des experts techniques.

6.7 Limites

Le système, conçu dans le cadre d'un projet de fin d'études, repose sur des données historiques (EMD et comptages de trafic archivés) ; l'absence d'alimentation en temps réel constitue la principale limite au regard d'un déploiement opérationnel. Par ailleurs, certaines variables de l'EMD n'ont pu être pleinement exploitées en raison de la confidentialité partielle des données mises à disposition par le CETUD. Ces contraintes, propres au contexte académique du projet, sont pleinement identifiées et constituent des axes de travail prioritaires pour la suite.

6.8 Perspectives

Ces éléments ouvrent plusieurs axes d'extension naturels : l'intégration de données de trafic en temps réel pour permettre une actualisation continue de l'entrepôt et des tableaux de bord ; le développement d'une application mobile (iOS/Android) pour élargir l'accès aux citoyens en situation de mobilité ; l'extension géographique de la solution à d'autres agglomérations sénégalaises ; la mise en place de rapports mensuels automatisés à destination des décideurs du CETUD ; et, à plus long terme, l'exploration de modèles de Deep Learning (LSTM) pour la prédiction temporelle du trafic.

6.9 Conclusion

Ce chapitre a permis d'évaluer de façon transversale les résultats du projet : les dashboards produits, l'analyse des KPI, les performances des modèles de Machine Learning, leur complémentarité avec la Business Intelligence classique, ainsi que l'apport global de la solution et ses limites. Ces éléments alimentent directement le bilan dressé dans la conclusion générale.

Conclusion générale

Bilan

Ce projet de fin d'études a porté sur la conception et la mise en œuvre d'une solution décisionnelle complète au service du CETUD, visant à exploiter l'Enquête Ménages-Déplacements et les données de comptage de trafic de Dakar pour éclairer la prise de décision en matière de mobilité urbaine. La démarche suivie s'est appuyée sur la méthodologie GIMSI, qui a structuré le travail en quatre grandes étapes : l'identification des besoins et des acteurs (chapitre 1), la conception de la solution et du modèle décisionnel (chapitres 2 et 3), la mise en œuvre technique de la plateforme et des modèles prédictifs (chapitres 5 et 4), et l'évaluation des résultats obtenus (chapitre 6).

Contributions

Au-delà du volet décisionnel classique (ETL Talend, entrepôt de données en schéma constellation, cockpit Knowage BI), le projet a été enrichi par le développement de quatre modèles de Machine Learning : la segmentation des usagers par K-Means, la recommandation de mode de transport par Random Forest, la détection d'anomalies de trafic par un consensus de trois algorithmes (Z-Score, Isolation Forest, Local Outlier Factor) complété par un clustering spatial DBSCAN, et la prédiction du risque d'inaccessibilité par Gradient Boosting. Ces modèles ont été exposés au sein d'une application web complète, combinant un backend FastAPI sécurisé par authentification JWT et un frontend React, à destination à la fois des citoyens et des décideurs du CETUD (chef d'exploitation et directeur de planification). Sur le plan des compétences acquises, ce projet a permis une mise en pratique transversale couvrant l'ensemble de la chaîne de valeur de la donnée : de la modélisation décisionnelle classique jusqu'aux techniques avancées de Machine Learning, en passant par le développement complet d'une application web sécurisée. Cette double dimension, décisionnelle et prédictive, constitue l'apport principal du projet par rapport à une solution de reporting classique.

Difficultés rencontrées

La conduite de ce projet a confronté à plusieurs difficultés caractéristiques d'un projet décisionnel de cette ampleur : tout d'abord, la **confidentialité partielle des données du CETUD**, qui n'a pas pu mettre à disposition l'ensemble des sources souhaitées, contraignant certains indicateurs à être estimés ou partiellement renseignés ; ensuite, la **complexité structurelle et documentaire des données** issues de l'EMD (codes de variables non auto-documentés, hétérogénéité des formats, incomplétude de certaines variables), nécessitant un travail con-

séquent de nettoyage et de documentation avant toute exploitation ; l'arbitrage entre granularité fine des données individuelles et performance des agrégations dans l'entrepôt, qui a motivé le choix du schéma en constellation ; le déséquilibre des classes dans la tâche de prédiction d'inaccessibilité, traité par sur-échantillonnage SMOTE ; et la nécessité de concilier deux chaînes de traitement distinctes sans rompre la cohérence d'ensemble de la solution.

Perspectives d'amélioration

Plusieurs axes d'amélioration et d'extension sont envisageables pour la suite : le développement d'une **application mobile** (iOS / Android) permettant aux citoyens d'accéder aux recommandations de transport en situation de mobilité ; l'**extension géographique** de la solution à d'autres agglomérations sénégalaises ou sous-sahariennes, en réutilisant le pipeline ETL et le modèle décisionnel conçus ; l'**intégration de données de trafic en temps réel** (issues des opérateurs de transport ou de capteurs IoT) pour permettre une actualisation continue de l'entrepôt et des tableaux de bord, au lieu d'un chargement batch périodique ; la mise en place de **rapports mensuels automatisés** (génération PDF programmée, envoi par email aux décideurs du CETUD) ; et enfin, l'exploration de techniques de **Deep Learning**, notamment les réseaux de neurones récurrents de type LSTM pour la prédiction temporelle du trafic, en remplacement ou en complément du modèle d'anomalies actuel.

En définitive, ce projet démontre la faisabilité et l'intérêt d'une approche combinant Business Intelligence traditionnelle et Machine Learning pour répondre aux enjeux de mobilité urbaine d'une métropole comme Dakar, et pose les bases d'un système qui pourra être consolidé et étendu dans le cadre d'une collaboration future avec le CETUD.

Bibliographie

- [1] CETUD – Conseil Exécutif des Transports Urbains de Dakar. *Enquête Ménages-Déplacements de Dakar (EMD)*. Rapport technique, CETUD, Dakar (Sénégal), 2015.
- [2] Fernandez, A. *Les Nouveaux Tableaux de Bord des Managers : la méthode GIMSI*. 6^e éd., Éditions Eyrolles, Paris, 2013. ISBN : 978-2-212-13658-0.
- [3] Schwaber, K., Sutherland, J. *The Scrum Guide – The Definitive Guide to Scrum : The Rules of the Game*. Scrum.org, novembre 2020. Disponible en ligne : <https://scrumguides.org/scrum-guide.html> (consulté le 20 mai 2026).
- [4] Kimball, R., Ross, M. *The Data Warehouse Toolkit : The Definitive Guide to Dimensional Modeling*. 3^e éd., Wiley, Hoboken (NJ, États-Unis), 2013. ISBN : 978-1-118-53080-1.
- [5] Inmon, W. H. *Building the Data Warehouse*. 4^e éd., Wiley, Hoboken (NJ, États-Unis), 2005. ISBN : 978-0-764-59944-5.
- [6] Talend S.A.S. *Talend Open Studio for Data Integration – Documentation officielle (v8.0)*. Talend, 2023. Disponible en ligne : <https://www.talend.com/resources/documentation/> (consulté le 15 avril 2026).
- [7] PostgreSQL Global Development Group. *PostgreSQL 16 : Documentation*. PostgreSQL, 2023. Disponible en ligne : <https://www.postgresql.org/docs/16/> (consulté le 10 avril 2026).
- [8] Knowage Labs – Engineering Group. *Knowage Suite 8.1 – User Guide & Administrator Manual*. Knowage Labs, Rome (Italie), 2023. Disponible en ligne : <https://knowage-suite.readthedocs.io/> (consulté le 12 avril 2026).
- [9] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. *Scikit-learn : Machine Learning in Python*. Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011. Disponible en ligne : <https://jmlr.org/papers/v12/pedregosa11a.html> (consulté le 5 mai 2026).
- [10] Breiman, L. *Random Forests*. Machine Learning, vol. 45, no 1, pp. 5–32, Springer, 2001. DOI : <https://doi.org/10.1023/A:1010933404324>.
- [11] MacQueen, J. *Some Methods for Classification and Analysis of Multivariate Observations*. Dans : *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, pp. 281–297, University of California Press, Berkeley (CA, États-Unis), 1967.

- [12] Liu, F. T., Ting, K. M., Zhou, Z.-H. *Isolation Forest*. Dans : *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, pp. 413–422, IEEE, Pisa (Italie), 2008. DOI : <https://doi.org/10.1109/ICDM.2008.17>.
- [13] Breunig, M. M., Kriegel, H.-P., Ng, R. T., Sander, J. *LOF : Identifying Density-Based Local Outliers*. Dans : *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104, ACM, Dallas (TX, États-Unis), 2000. DOI : <https://doi.org/10.1145/342009.335388>.
- [14] Ester, M., Kriegel, H.-P., Sander, J., Xu, X. *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise*. Dans : *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 226–231, AAAI Press, Portland (OR, États-Unis), 1996.
- [15] Friedman, J. H. *Greedy Function Approximation : A Gradient Boosting Machine*. The Annals of Statistics, vol. 29, no 5, pp. 1189–1232, Institute of Mathematical Statistics, 2001. DOI : <https://doi.org/10.1214/aos/1013203451>.
- [16] Chawla, N. V., Bowyer, K. W., Hall, L. O., Kegelmeyer, W. P. *SMOTE : Synthetic Minority Over-sampling Technique*. Journal of Artificial Intelligence Research, vol. 16, pp. 321–357, AI Access Foundation, 2002. DOI : <https://doi.org/10.1613/jair.953>.
- [17] Lundberg, S. M., Lee, S.-I. *A Unified Approach to Interpreting Model Predictions*. Dans : Guyon, I. et al. (éd.), *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, pp. 4765–4774, Curran Associates, Long Beach (CA, États-Unis), 2017. Disponible en ligne : <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html> (consulté le 18 mai 2026).
- [18] Chen, T., Guestrin, C. *XGBoost : A Scalable Tree Boosting System*. Dans : *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794, ACM, San Francisco (CA, États-Unis), 2016. DOI : <https://doi.org/10.1145/2939672.2939785>.
- [19] Ramírez, S. *FastAPI – Modern, fast (high-performance) web framework for building APIs with Python*. GitHub / tiangolo, 2023. Disponible en ligne : <https://fastapi.tiangolo.com/> (consulté le 20 avril 2026).
- [20] Meta Open Source. *React – A JavaScript library for building user interfaces (v18)*. Meta Platforms Inc., 2023. Disponible en ligne : <https://react.dev/> (consulté le 20 avril 2026).
- [21] Colvin, S. et al. *Pydantic – Data validation using Python type hints (v2)*. Pydantic, 2023. Disponible en ligne : <https://docs.pydantic.dev/> (consulté le 22 avril 2026).
- [22] Jones, M., Bradley, J., Sakimura, N. *JSON Web Token (JWT)*. RFC 7519, Internet Engineering Task Force (IETF), mai 2015. Disponible en ligne : <https://datatracker.ietf.org/doc/html/rfc7519> (consulté le 8 avril 2026).

Annexe A

Annexes

A.1 Scripts SQL

Extrait de requête de contrôle qualité exécutée sous pgAdmin pour vérifier la structure d'une table de faits via le catalogue système :

```
SELECT column_name, data_type, is_nullable
FROM information_schema.columns
WHERE table_schema = 'DW' AND table_name = 'Fact_Comptage'
ORDER BY ordinal_position;
```

Extrait de requête de contrôle de cohérence référentielle (détection de clés étrangères orphelines) :

```
SELECT f.*
FROM "DW"."Fact_deplacement" f
LEFT JOIN "DW"."Dim_Individu" d ON f."FK_id_individu" = d."PK_id_individu"
WHERE d."PK_id_individu" IS NULL;
```

A.2 Jobs Talend

Le tableau A.1 récapitule l'ensemble des jobs Talend développés pour l'alimentation de l'entrepôt de données.

Table A.1: Jobs Talend développés

Job	Rôle
SA_individu, SA_menage, SA_deplacement	Chargement de la Staging Area
Job_dim_site, Job_dim_geo	Construction des dimensions de référence
Job_dim_individu, Job_dim_menage	Construction des dimensions individu / ménage
Job_deplacement	Construction de Fact_deplacement
Job_comptage	Construction de Fact_Comptage
Job_accessibilite	Construction de fact_access
Job_indivmen	Construction de Fait_IndividuMenage

A.3 Captures Knowage

Les sheets du cockpit Knowage BI (Accueil, Trafic, Déplacements, Démographie, Accessibilité, IA) sont illustrées par les figures du chapitre 6 ainsi que par les captures du dossier figures/kpis/ du présent rapport.

A.4 Captures React

Les pages de l'application web (espace citoyen et espace décideurs) sont illustrées par les figures du chapitre 5, présentant respectivement le parcours citoyen (recommandation de mode de transport) et les tableaux de bord décideurs (zones à risque, anomalies, segmentation, simulateur de risque).

A.5 Documentation de l'API

Le tableau A.2 liste l'ensemble des points d'accès REST exposés par le backend FastAPI, avec leur méthode HTTP et leur statut de protection.

Table A.2: Liste complète des endpoints REST exposés par l'API

Méthode	Endpoint	Protégé (JWT)
POST	/auth/login	–
GET	/	Non
GET	/health	Non
GET	/quartiers	Non
POST	/recommander	Non
GET	/segments	Oui
GET	/modes	Oui
GET	/zones-risque	Oui
GET	/zones-risque/resume	Oui
GET	/api/segmentation/profils	Oui
GET	/api/satisfaction	Oui
POST	/api/feedback	Non
GET	/api/feedback/stats	Oui
GET	/api/anomalies/summary	Oui
GET	/api/anomalies/sites	Oui
GET	/api/anomalies/sites/{site_id}/details	Oui
POST	/predict-inaccessibility	Oui
GET	/api/ml/features-importance	Oui
GET	/api/ml/metrics	Oui

La documentation interactive complète (Swagger UI) est générée automatiquement par FastAPI et accessible à l'adresse /docs du serveur.

A.6 Documentation des modèles de Machine Learning

Chaque modèle est sérialisé avec ses métadonnées (liste des variables, métriques de performance, date d'entraînement) au format `.pkl` via `joblib : kmeans_segmentation.pkl, rf_recommandation_inaccessibilite_model.pkl`, ainsi que les fichiers de métadonnées associés (`metadata.json`, `zones_risque.json`). Le détail méthodologique de chaque modèle (objectif, variables, algorithme, résultats, intégration) est présenté au chapitre 4.

A.7 Manuel utilisateur

A.7.1 Espace citoyen

1. Accéder à la page d'accueil de l'application (`WelcomePage`) ;
2. Cliquer sur « Planifier mon trajet » pour accéder au formulaire de recommandation ;
3. Renseigner son profil de mobilité (zone de résidence, âge, statut, disponibilité d'un véhicule, fréquence des déplacements) ;
4. Consulter le *top 3* des modes de transport recommandés, avec durée et coût estimés.

A.7.2 Espace décideurs

1. Accéder à la page de connexion (`LoginDecideurs`) et s'authentifier avec ses identifiants (chef d'exploitation ou directeur de planification) ;
2. Consulter la vue générale (`VueGenerale`) pour un aperçu synthétique des indicateurs clés ;
3. Naviguer vers les modules thématiques selon ses besoins : zones à risque, anomalies de trafic, segmentation des usagers, simulateur de risque, cockpit Knowage ;
4. Pour le directeur de planification uniquement : consulter la page de transparence des modèles (`MlInsights`) pour auditer les performances et l'importance des variables ;
5. Exporter un rapport PDF de synthèse depuis les pages *Zones à risque* ou *Anomalies* si nécessaire.

A.8 Dictionnaire des codes de variables EMD utilisés

Table A.3: Principaux codes de variables EMD exploités

Code	Signification
I2, I4, I9	Caractéristiques géographiques du domicile (quartier, strate, district)
M21	Taille du ménage
M55	Manque de transport en commun déclaré
M66 – M70	Accessibilité de base (distance, durée de marche, modes disponibles)
M68	Exposition aux inondations
M69	Résilience d'accès en cas de pluie
M73, M87	Problèmes majeurs déclarés dans le quartier
M90, M91	Accès aux écoles et daaras

A.9 Glossaire

BI Business Intelligence – informatique décisionnelle.

CETUD Conseil Exécutif des Transports Urbains de Dakar.

DBSCAN Density-Based Spatial Clustering of Applications with Noise – algorithme de clustering spatial.

EMD Enquête Ménages-Déplacements.

ETL Extract-Transform-Load – processus d'extraction, transformation et chargement des données.

GIMSI Méthodologie de conception de tableaux de bord décisionnels.

JWT JSON Web Token – jeton signé utilisé pour l'authentification.

KPI Key Performance Indicator – indicateur clé de performance.

LOF Local Outlier Factor – algorithme de détection d'anomalies par densité locale.

RBAC Role-Based Access Control – contrôle d'accès basé sur les rôles.

SHAP SHapley Additive exPlanations – méthode d'explicabilité des modèles de Machine Learning.

SMOTE Synthetic Minority Over-sampling Technique – technique de rééquilibrage de classes.

A.10 Liste des technologies utilisées

Table A.4: Stack technique du projet

Couche	Technologie
Préparation des données	Python, Pandas, Google Colab
ETL	Talend Open Studio
Entrepôt de données	PostgreSQL
Restitution décisionnelle	Knowage BI
Machine Learning	scikit-learn, imbalanced-learn, SHAP, joblib
Backend applicatif	FastAPI, Pydantic, PyJWT, uvicorn
Frontend applicatif	React.js, Recharts, Leaflet, Framer Motion, jsPDF
Gestion de projet	Scrum