

# Préparation de Soutenance — Projet TransportDakar

Système d'aide à la décision pour l'optimisation du transport urbain de Dakar

Ibtihel Abdellaoui — PFE ESPRIT / CETUD

Juin 2026

## Contents

|          |                                                                                          |           |
|----------|------------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Présentation générale du projet</b>                                                   | <b>3</b>  |
| 1.1      | Contexte . . . . .                                                                       | 3         |
| 1.2      | Objectif métier . . . . .                                                                | 3         |
| 1.3      | Les trois grands volets du projet . . . . .                                              | 3         |
| <b>2</b> | <b>Chronologie des travaux réalisés (de A à Z)</b>                                       | <b>5</b>  |
| 2.1      | Étape 1 — Préparation et compréhension des données . . . . .                             | 5         |
| 2.2      | Étape 2 — Construction des datasets analytiques (KPI) . . . . .                          | 5         |
| 2.3      | Étape 3 — Modélisation Machine Learning . . . . .                                        | 5         |
| 2.4      | Étape 4 — Application Web (Backend + Frontend) . . . . .                                 | 5         |
| 2.5      | Étape 5 — Modules complémentaires . . . . .                                              | 6         |
| 2.6      | Étape 6 — Volet Business Intelligence : construction du cockpit Knowage .                | 6         |
| 2.7      | Étape 7 — Trois corrections demandées et livrées dans cette dernière itération . . . . . | 6         |
| 2.8      | Étape 8 — Bug additionnel détecté et corrigé en cours de vérification . . .              | 6         |
| 2.9      | Étape 9 — Vérification finale . . . . .                                                  | 7         |
| <b>3</b> | <b>Données et architecture globale</b>                                                   | <b>8</b>  |
| 3.1      | Architecture en couches . . . . .                                                        | 8         |
| 3.2      | Justification des choix technologiques . . . . .                                         | 8         |
| 3.3      | Sources de données originales . . . . .                                                  | 9         |
| 3.4      | Pourquoi pas de base de données relationnelle classique ? . . . . .                      | 9         |
| <b>4</b> | <b>Intelligence Artificielle / Machine Learning</b>                                      | <b>10</b> |
| 4.1      | Vue d'ensemble des modèles . . . . .                                                     | 10        |
| 4.2      | Construction de la variable cible « inaccessibilité » . . . . .                          | 10        |
| 4.3      | Détection d'anomalies — consensus pondéré . . . . .                                      | 10        |
| 4.4      | Segmentation des usagers — 5 profils . . . . .                                           | 11        |
| 4.5      | Métriques de performance . . . . .                                                       | 11        |
| 4.6      | Top features (Gradient Boosting — inaccessibilité) . . . . .                             | 11        |
| 4.7      | Bonnes pratiques de modélisation appliquées . . . . .                                    | 12        |
| <b>5</b> | <b>Application Web — Backend et Frontend</b>                                             | <b>13</b> |
| 5.1      | Backend FastAPI . . . . .                                                                | 13        |
| 5.2      | Frontend React . . . . .                                                                 | 14        |

|                                                                                |           |
|--------------------------------------------------------------------------------|-----------|
| <b>6 Modules complémentaires</b>                                               | <b>15</b> |
| 6.1 Module « Satisfaction & Écoute Usagers » . . . . .                         | 15        |
| 6.2 Note technique — Explicabilité du modèle (XAI / SHAP) . . . . .            | 16        |
| <b>7 Volet Business Intelligence — Cockpit Knowage TransportDakar</b>          | <b>17</b> |
| 7.1 Présentation du cockpit . . . . .                                          | 17        |
| 7.2 Identité visuelle « TransportDakar » . . . . .                             | 17        |
| 7.3 Les trois corrections demandées et leur implémentation technique . . . . . | 17        |
| 7.4 Bug additionnel détecté et corrigé : widget dupliqué . . . . .             | 19        |
| 7.5 Méthodologie de déploiement et de vérification dans Knowage . . . . .      | 19        |
| <b>8 Forces, limites et perspectives</b>                                       | <b>20</b> |
| 8.1 Points forts du projet . . . . .                                           | 20        |
| 8.2 Limites et points critiques (avec réponse défensive) . . . . .             | 20        |
| 8.3 Roadmap future . . . . .                                                   | 21        |
| <b>9 Foire aux questions de soutenance</b>                                     | <b>22</b> |
| 9.1 Architecture et choix techniques . . . . .                                 | 22        |
| 9.2 Machine Learning . . . . .                                                 | 22        |
| 9.3 Sécurité . . . . .                                                         | 22        |
| 9.4 Business Intelligence — Cockpit Knowage . . . . .                          | 22        |
| <b>10Fiche de révision express</b>                                             | <b>24</b> |
| 10.1Pitch deux minutes . . . . .                                               | 24        |
| 10.2Chiffres clés à citer . . . . .                                            | 24        |
| 10.3Réponses rapides . . . . .                                                 | 24        |

# 1 Présentation générale du projet

## 1.1 Contexte

Le réseau de transport urbain de Dakar souffre de trois problèmes majeurs : des zones géographiques entièrement inaccessibles aux transports en commun, des anomalies de trafic non détectées sur les axes principaux, et l'absence d'outil pour guider les citoyens dans le choix de leur mode de déplacement.

Le projet **TransportDakar** répond à ces trois problèmes en construisant une plateforme complète d'aide à la décision alimentée par le Machine Learning et la Business Intelligence, basée sur les données réelles de l'Enquête Ménage Déplacement (EMD) du CETUD 2019, portant sur 37 248 individus, 4 521 ménages et 775 480 observations de trafic.

## 1.2 Objectif métier

| Dimension      | Détail                                                                                                                           |
|----------------|----------------------------------------------------------------------------------------------------------------------------------|
| Problématique  | Inaccessibilité aux transports en commun, anomalies de trafic non détectées, absence de recommandation personnalisée             |
| Solution       | Plateforme décisionnelle combinant Machine Learning, application Web et Business Intelligence                                    |
| Données source | EMD CETUD 2019 — Ménages, Individus, Déplacements, Trafic                                                                        |
| Utilisateurs   | Citoyens de Dakar, Gestionnaires du CETUD (Directeur Planification, Chef d'Exploitation)                                         |
| Valeur ajoutée | Réduction du temps de diagnostic, automatisation des alertes, recommandation en temps réel, pilotage visuel des indicateurs clés |

## 1.3 Les trois grands volets du projet

Le projet se décompose en trois volets complémentaires, réalisés successivement :

1. **Volet Machine Learning & Application Web** — un site web avec un espace citoyen (recommandation de mode de transport) et un espace décideurs (zones à risque, anomalies, segmentation, simulateur, audit ML), adossé à 7 modèles de Machine Learning entraînés sur les données EMD.
2. **Modules complémentaires** — un module « Satisfaction & Écoute Usagers » (enquête historique + cellule d'écoute citoyenne en direct) et une note technique d'explicabilité des modèles (XAI / SHAP).
3. **Volet Business Intelligence — Cockpit Knowage** — un tableau de bord décisionnel multi-feuilles construit dans l'outil Knowage, habillé selon l'identité visuelle

« TransportDakar », avec navigation, mode clair/sombre et graphiques à échelle réelle.

Ce document couvre l'ensemble de ces travaux, du premier dataset jusqu'à la dernière vérification du cockpit BI, dans une logique de préparation à la soutenance.

## 2 Chronologie des travaux réalisés (de A à Z)

Le projet a été construit de façon incrémentale. Voici les grandes étapes, dans l'ordre où elles ont été menées.

### 2.1 Étape 1 — Préparation et compréhension des données

- Récupération et exploration des fichiers sources CETUD : CETUD\_BD\_EMD\_MENAGE\_COMPILE.xls, CETUD\_BD\_EMD\_INDIVIDU\_COMPILE.xls, CETUD\_BD\_TRAFIK\_SECTION\_COMPILE.xls, ainsi que le dictionnaire de variables CETUD\_BD\_EMD\_INDIVIDU\_LIBELLE.xlsx.
- Nettoyage, export et structuration en fichiers exploitables (Menage.csv, Deplacement.csv, Trafic.csv).
- Vérification de la structure du futur Data Warehouse : tables de faits et dimensions (Fact\_Trafic, Dim\_Motif, Dim\_Temps), vérification des flux entrants/sortants et des zones origine-destination (OD).

### 2.2 Étape 2 — Construction des datasets analytiques (KPI)

Une série de datasets a été construite pour alimenter à la fois les modèles ML et les tableaux de bord BI :

- Temps de parcours par mode de transport
- Temps moyen par motif de déplacement
- Coût moyen du déplacement
- Volume horaire de déplacements
- Heures de pointe matin / soir
- KPI trafic : volume, vitesse, sens de circulation, répartition horaire
- KPI démographie : sexe, statut matrimonial, niveau d'instruction, profession, détention du permis
- KPI accessibilité par commune, par mode, par tranche horaire

Deux datasets prévus initialement (taux de motorisation des ménages, mobilité des seniors) se sont révélés **bloqués par absence de la donnée source** dans l'enquête EMD — un point assumé et documenté plutôt que masqué.

### 2.3 Étape 3 — Modélisation Machine Learning

Une fois les données prêtes, quatre familles de modèles ont été entraînées (détaillées au chapitre 4) : segmentation des usagers (K-Means), recommandation de mode de transport (Random Forest), prédiction du risque d'inaccessibilité (Gradient Boosting), détection d'anomalies de trafic (Isolation Forest + LOF + Z-Score, avec clustering spatial DBSCAN).

### 2.4 Étape 4 — Application Web (Backend + Frontend)

Construction de l'API FastAPI exposant les 9 endpoints REST, puis de l'application React avec sept pages décideurs et deux pages citoyens, intégrant l'authentification par rôle (RBAC), le thème clair/sombre et les graphiques interactifs (détaillé au chapitre 5).

## 2.5 Étape 5 — Modules complémentaires

- Ajout du module **Satisfaction & Écoute Usagers** : exploitation des données de satisfaction non utilisées de l'enquête EMD individu, plus une cellule d'écoute publique en direct accessible sans authentification.
- Rédaction d'une **note technique XAI / SHAP** clarifiant la méthode d'explicabilité réellement implémentée (feature importance native scikit-learn) par rapport à la méthode SHAP évoquée dans l'interface, avec une réponse type prête pour le jury.

## 2.6 Étape 6 — Volet Business Intelligence : construction du cockpit Knowage

- Inspection des sheets existants du cockpit Knowage (document composite).
- Création d'un sheet de garde / vue d'ensemble (« Accueil ») avec cartes statistiques globales.
- Refonte visuelle complète de chacun des cinq sheets métier — **Trafic, Déplacements, Démographie, Accessibilité, IA & Prévisions** — selon l'identité visuelle TransportDakar (bleu marine #0F172A, orange #F97316, blanc, gris clair #F8FAFC).
- Harmonisation des couleurs de l'ensemble des widgets en orange #ff6b35 (*tâche encore en cours d'achèvement*).
- Déploiement de chaque sheet dans Knowage (édition du widget HTML, sauvegarde au niveau document).

## 2.7 Étape 7 — Trois corrections demandées et livrées dans cette dernière itération

1. **Navigation réelle entre les pages** du cockpit : les cinq sheets (plus l'Accueil) sont maintenant reliés par la barre d'onglets native de Knowage, testée dans les deux sens sur l'ensemble des sheets.
2. **Mode clair / sombre** : ajout d'un bouton bascule (icône lune/soleil) fonctionnant uniquement en CSS, via un sélecteur :has() sur une case à cocher invisible — aucune ligne de JavaScript, ce qui le rend compatible avec le filtre de sécurité (sanitizer) de Knowage qui rejette <script> et les attributs onclick.
3. **Axes Y réels sur les graphiques à barres** : chaque graphique affiche désormais une échelle verticale graduée (0/25/50/75/100 ou équivalent) et une étiquette de valeur au-dessus de chaque barre, alors qu'auparavant les barres n'étaient positionnées qu'en pourcentage arbitraire sans repère de lecture.

## 2.8 Étape 8 — Bug additionnel détecté et corrigé en cours de vérification

Lors de la vérification finale, un widget de barre latérale (cartes statistiques type « 156 764 déplacements analysés ») s'affichait par erreur sur le sheet **Accessibilité**, alors qu'il devait être exclusif au sheet **Accueil**. Le widget dupliqué a été identifié, supprimé via le menu d'édition du widget dans Knowage, et la sauvegarde a été vérifiée comme persistante après un rechargement complet de la page.

## **2.9 Étape 9 — Vérification finale**

Contrôle systématique, après rechargement complet de chaque page, de : la persistance de la navigation entre les cinq sheets, le bon fonctionnement du bouton clair/sombre, la présence des axes Y et des étiquettes de valeur sur tous les graphiques à barres, et l'absence du bug de widget dupliqué. Aucune erreur de validation côté serveur (« Invalid HTML payload ») n'a été rencontrée lors des sauvegardes finales.

## 3 Données et architecture globale

### 3.1 Architecture en couches

#### SOURCES DE DONNEES

CETUD\_BD\_EMD\_MENAGE.xls . CETUD\_BD\_EMD\_INDIVIDU.xls

CETUD\_BD\_TRAFIC\_SECTION.xls . exports CSV

| extraction / scripts Python

v

#### PIPELINE ETL (Python / Pandas)

Nettoyage -> Feature Engineering -> Imputation

Encodage -> Normalisation -> Export CSV / PKL

v

#### MODELES MACHINE LEARNING

K-Means (segmentation) . Isolation Forest + LOF + Z-Score (anomalies)

Gradient Boosting (inaccessibilite) . Random Forest (mode de transport)

| joblib.dump -> fichiers .pkl

v

#### API BACKEND -- FastAPI (Python, uvicorn :8000, 9 endpoints REST)

| HTTP / JSON

v

#### FRONTEND -- React.js (SPA)

7 pages decideurs + 2 pages citoyens + authentication par role

v

#### DASHBOARDS BI

Cockpit Knowage (5 sheets + Accueil) . visualisations Matplotlib/Folium

### 3.2 Justification des choix technologiques

| Technologie      | Pourquoi ce choix                                                                    | Alternative écartée                                |
|------------------|--------------------------------------------------------------------------------------|----------------------------------------------------|
| FastAPI          | Performant, asynchrone natif, documentation Swagger automatique, validation Pydantic | Flask (moins performant, pas de validation native) |
| React.js         | SPA fluide, écosystème riche, composants réutilisables                               | Vue.js, Angular (trop lourd pour un PFE)           |
| scikit-learn     | Standard de l'industrie, API uniforme, documentation excellente                      | TensorFlow (excessif pour des données tabulaires)  |
| K-Means          | Segmentation non supervisée, interprétable, validée par le coefficient de silhouette | DBSCAN (sensible aux paramètres), GMM (complexe)   |
| Isolation Forest | Efficace en grande dimension, pas d'hypothèse de distribution                        | SVM One-Class (plus lent)                          |

| Technologie       | Pourquoi ce choix                                                                          | Alternative écartée                        |
|-------------------|--------------------------------------------------------------------------------------------|--------------------------------------------|
| Gradient Boosting | Meilleure performance sur données tabulaires déséquilibrées                                | XGBoost (similaire, moins intégré)         |
| SMOTE             | Rééchantillonnage synthétique des classes minoritaires                                     | Sous-échantillonnage (perte d'information) |
| Knowage           | Outil BI déjà déployé au CETUD, cockpits multi-feuilles avec widgets HTML personnalisables | Power BI (licence, hébergement cloud)      |

### 3.3 Sources de données originales

| Fichier                          | Description                                             | Volume approximatif |
|----------------------------------|---------------------------------------------------------|---------------------|
| CETUD_BD_EMD_MENAGE_COMPILED     | Données ménages EMD Dakar 2019                          | ~4 521 ménages      |
| CETUD_BD_EMD_INDIVIDU_COMPILED   | Données individus                                       | ~37 248 individus   |
| CETUD_BD_TRAFIC_SECTION_COMPILED | Données trafic sur 49 sites                             | ~775 480 lignes     |
| CETUD_BD_EMD_INDIVIDU_LIBEL      | Libellés des variables (13 415 individus, 210 colonnes) | —                   |

### 3.4 Pourquoi pas de base de données relationnelle classique ?

Le projet n'utilise pas de SGBD (MySQL/PostgreSQL) pour la partie ML : les données sont stockées en fichiers plats (CSV/XLS), modèles sérialisés (PKL) et statistiques JSON. La partie BI (Knowage), elle, s'appuie sur le Data Warehouse en étoile avec ses tables de faits et dimensions (Fact\_Trafic, Dim\_Motif, Dim\_Temps).

**Réponse type si la question est posée par le jury :** « Pour ce projet de recherche analytique basé sur une enquête historique unique (EMD 2019), les données ne sont pas transactionnelles et ne nécessitent pas de mises à jour fréquentes. Les fichiers CSV/XLS sont le format natif des organismes comme le CETUD. Pour la restitution décisionnelle, en revanche, nous avons construit un véritable schéma en étoile alimentant le cockpit Knowage. Pour une version production avec collecte temps réel, on migrerait vers PostgreSQL avec TimescaleDB pour les données de trafic temporelles. »

## 4 Intelligence Artificielle / Machine Learning

### 4.1 Vue d'ensemble des modèles

| Modèle            | Type                      | Objectif                         | Features               | Cible                  |
|-------------------|---------------------------|----------------------------------|------------------------|------------------------|
| K-Means (k=5)     | Clustering non supervisé  | Segmenter les usagers            | 10 features individu   | 5 clusters             |
| Random Forest     | Classification supervisée | Recommander le mode de transport | 12 features individu   | Mode de transport      |
| Gradient Boosting | Classification supervisée | Prédire l'inaccessibilité        | 24 features ménage     | Risque 0/1             |
| Isolation Forest  | Détection d'anomalies     | Détecter le trafic anormal       | Volume + heure + site  | Score d'anomalie       |
| LOF               | Détection d'anomalies     | Densité locale                   | Volume + catégorie     | Score LOF              |
| Z-Score           | Détection d'anomalies     | Valeurs extrêmes                 | Volume par site        | Z-score normalisé      |
| DBSCAN            | Clustering spatial        | Hotspots géographiques           | GPS latitude/longitude | Identifiant de cluster |

### 4.2 Construction de la variable cible « inaccessibilité »

```
score_composite =
    score_tc_distance      (distance a pied a l'arret TC > 10 min -> 1)
+ score_inond_bin         (frequence d'inondation >= "Souvent" -> 1)
+ score_enclavement       (enclavement declare -> 1)
+ score_routes_manquantes (absence de routes carrossables -> 1)
+ score_tc_manque         (manque de TC declare -> 1)
+ score_tc_pluie          (TC inaccessible par temps de pluie -> 1)
+ score_sante             (duree d'accès au centre de sante > 30 min -> 1)
```

seuil = 65e percentile du score\_composite

y = 1 si score\_composite >= seuil, sinon 0 (1 = zone a risque)

Le choix du 65e percentile maximise le F1-score en validation croisée tout en restant interprétable d'un point de vue métier : il identifie environ 35 % des ménages comme « à risque », une proportion cohérente avec les estimations du CETUD.

### 4.3 Détection d'anomalies — consensus pondéré

|                  |              |                                 |
|------------------|--------------|---------------------------------|
| Z-Score          | (poids 0.25) | univarie, rapide, interpretable |
| Isolation Forest | (poids 0.40) | multivarie, robuste             |
| LOF              | (poids 0.35) | densite locale                  |

Consensus : anomalie si score pondere >= 0.6

Aucun algorithme seul n'est optimal sur tous les types d'anomalies de trafic (bouchons soudains vs. comportements inhabituels persistants). Le consensus pondéré réduit les

faux positifs d'environ 35 % par rapport à un seul modèle. Un clustering spatial DBSCAN (eps  $\approx$  500 m, min\_samples = 3) distingue ensuite les axes à congestion structurelle des incidents ponctuels.

#### 4.4 Segmentation des usagers — 5 profils

| Segment                  | Profil type                                       | Mode dominant    |
|--------------------------|---------------------------------------------------|------------------|
| Actifs TC réguliers      | ~35 ans, actif, sans permis, usage fréquent du TC | Transport commun |
| Actifs motorisés         | ~40 ans, actif, permis, revenu élevé              | Voiture / Taxi   |
| Étudiants mobilité douce | ~20 ans, étudiant, budget faible                  | Marche / TC      |
| Piétons de proximité     | ~45 ans, peu mobile, quartier dense               | Marche           |
| Travailleurs informels   | ~30 ans, actif informel, mobilité mixte           | TC / Moto        |

Le nombre de clusters (k=5) a été déterminé par la méthode du coude (elbow) combinée au coefficient de silhouette ( $\approx$  0,31, séparation modérée mais acceptable pour des données sociodémographiques).

#### 4.5 Métriques de performance

| Modèle                              | Métrique                  | Valeur         |
|-------------------------------------|---------------------------|----------------|
| Gradient Boosting (inaccessibilité) | Accuracy                  | 90,6 %         |
| Gradient Boosting (inaccessibilité) | ROC AUC                   | 0,921          |
| Gradient Boosting (inaccessibilité) | F1-score                  | 88,3 %         |
| Random Forest (mode de transport)   | Accuracy                  | 90,6 %         |
| Random Forest (mode de transport)   | F1 (validation croisée)   | 88,3 %         |
| K-Means (segmentation)              | Coefficient de silhouette | $\approx$ 0,31 |

#### 4.6 Top features (Gradient Boosting — inaccessibilité)

| Rang | Variable      | Importance | Signification                                    |
|------|---------------|------------|--------------------------------------------------|
| 1    | M66           | ~0,18      | Distance à pied à l'arrêt de transport en commun |
| 2    | dur_sante     | ~0,14      | Temps d'accès aux soins                          |
| 3    | tc_norm_total | ~0,12      | Score TC normalisé                               |
| 4    | M68           | ~0,10      | Fréquence d'inondation                           |
| 5    | M55           | ~0,09      | Manque de TC déclaré                             |

**Interprétation métier :** la distance au transport en commun et l'accès aux soins sont les déterminants principaux de l'inaccessibilité — un résultat cohérent avec la littérature sur la mobilité urbaine en Afrique subsaharienne.

## 4.7 Bonnes pratiques de modélisation appliquées

- `random_state=42` fixé sur tous les algorithmes stochastiques pour la reproductibilité.
- Validation croisée stratifiée (`StratifiedKFold(5)`) plutôt qu'un simple `split train/test`.
- SMOTE appliqué uniquement sur l'ensemble d'entraînement, jamais sur le test.
- `class_weight='balanced'` et `max_depth` limité pour réduire le surapprentissage.
- Séparation claire entre scripts d'entraînement et serveur d'inférence (FastAPI charge les modèles déjà entraînés).

## 5 Application Web — Backend et Frontend

### 5.1 Backend FastAPI

Le serveur FastAPI (`main.py`, ~700 lignes) charge tous les modèles ML en mémoire au démarrage et expose 9 endpoints REST consommés par le frontend React.

#### 5.1.1 Tableau des endpoints

| Méthode | Endpoint                                     | Entrée                          | Sortie                                        | Utilité métier                      |
|---------|----------------------------------------------|---------------------------------|-----------------------------------------------|-------------------------------------|
| POST    | <code>/recommander</code>                    | Profil usager (13 champs)       | Mode + top 3 + conseil                        | Recommandation de mode de transport |
| GET     | <code>/zones-risque</code>                   | —                               | 41 zones avec scores                          | Dashboard inaccessibilité           |
| GET     | <code>/zones-risque/resume</code>            | —                               | Nombre ÉLEVÉ / MODÉRÉ / FAIBLE                | KPI récapitulatif                   |
| GET     | <code>/api/anomalies/summary</code>          | —                               | Total observations, anomalies, sites à risque | KPIs trafic                         |
| GET     | <code>/api/anomalies/sites</code>            | —                               | 49 sites avec statuts                         | Liste des sites                     |
| GET     | <code>/api/anomalies/identifiant/site</code> | identifiant du site             | Séries temporelles, histogrammes              | Drill-down par site                 |
| GET     | <code>/api/segmentation/profils</code>       | —                               | 5 segments + statistiques                     | Page segmentation                   |
| POST    | <code>/predict-inaccessibility</code>        | 9 variables sociodémographiques | Score + niveau                                | Simulateur de risque                |
| GET     | <code>/api/ml/features-importance</code>     | —                               | Top features et importances                   | Audit ML                            |
| GET     | <code>/api/ml/metrics</code>                 | —                               | Accuracy, F1, AUC                             | Audit ML                            |

#### 5.1.2 Points techniques clés

- **Validation automatique** via Pydantic (bornes min/max sur chaque champ, erreur 422 automatique en cas de valeur hors limites).
- **Optimisation mémoire** : le dataset d'anomalies (14 Mo) est chargé une seule fois en RAM au démarrage plutôt qu'à chaque requête, réduisant le temps de réponse de ~800 ms à moins de 50 ms.
- **CORS** configuré via `CORSMiddleware` pour n'accepter que l'origine `http://localhost:3000` en développement.

- **Sérialisation des modèles** via `joblib.dump()`, plus efficace que `pickle` pour les objets `numpy/scikit-learn` volumineux.

## 5.2 Frontend React

### 5.2.1 Cartographie des pages

```
App.js (routeur + etat global)
├─ ThemeProvider (Context clair/sombre)
│   ├── WelcomePage                /
│   ├── FormPage                   /planning
│   ├── LoginDecideurs              /login-decideurs
│   └─ ProtectedRoute
│       └─ DecideursLayout          /decideurs/*
│           ├── VueGenerale          /decideurs (dashboard agrege)
│           ├── ZonesRisquePage       /decideurs/zones-risque
│           ├── AnomalyDashboard      /decideurs/anomalies
│           ├── SimulateurRisque       /decideurs/simulateur
│           ├── MLInsights             /decideurs/ml-insights
│           ├── SegmentationPage       /decideurs/segmentation
│           └─ EvolutionTemporelle    /decideurs/evolution
```

### 5.2.2 Fonctionnalités notables

- **Formulaire citoyen multi-étapes** (4 étapes) avec contrôle de saisie contextuel : un utilisateur de moins de 18 ans ne voit pas les champs permis, nombre de véhicules ou revenu.
- **Authentification par rôle (RBAC)** simulée côté client : deux rôles, *Directeur Planification* (accès complet, y compris ML Insights et Évolution temporelle) et *Chef d'Exploitation* (accès restreint, sans ML Insights).
- **Thème clair/sombre** géré par un Context React (`theme.js`) qui injecte des variables CSS dynamiques et les persiste en `localStorage`.
- **Cartographie interactive** via Leaflet pour la visualisation des 41 zones à risque.
- **Animations de transition** via Framer Motion (`AnimatePresence`) pour les changements de page et l'apparition des cartes KPI.
- **Simulateur de risque** avec jauge circulaire SVG animée et niveau FAIBLE / MODÉRÉ / ÉLEVÉ.

### 5.2.3 Limites assumées de la sécurité applicative

Le système d'authentification (token Base64 + sel, sans signature cryptographique) est **volontairement simplifié pour un contexte de PFE démonstratif**. En production, il faudrait : un JWT signé RS256, un serveur d'authentification dédié (Keycloak, Auth0), des mots de passe hashés (bcrypt), HTTPS obligatoire et une protection CSRF / rate limiting. Ce point doit être assumé clairement si le jury le soulève — c'est un signe de maturité plutôt qu'une faiblesse de présenter ses propres limites.

## 6 Modules complémentaires

### 6.1 Module « Satisfaction & Écoute Usagers »

#### 6.1.1 Objectif

Le fichier source de l'enquête EMD individu (CETUD\_BD\_EMD\_INDIVIDU\_LIBELLE.xlsx, 13 415 individus, 210 colonnes) contenait des données de satisfaction, de sécurité perçue et de difficultés de déplacement qui n'étaient pas encore exploitées. Ce module les valorise sous deux formes complémentaires :

1. Un **tableau de bord décideur** qui analyse les données historiques de l'enquête EMD (ressenti des usagers en 2019).
2. Une **cellule d'écoute publique** qui permet à n'importe quel citoyen de donner son avis aujourd'hui, sans connexion, et qui nourrit le même tableau de bord en temps réel.

Cette distinction répond à une exigence de cohérence : une « cellule d'écoute » doit, par définition, être ouverte au public et non réservée aux décideurs.

#### 6.1.2 Volet décideur — page /decideurs/satisfaction

- **KPI** : score de satisfaction global du réseau, part des usagers craignant une agression en transport en commun (jour/nuit), part des usagers ayant renoncé à une activité faute de moyen de transport, nombre de modes de TC analysés.
- **Satisfaction par mode de transport** : graphique en barres horizontales (Taxi, DDD, Car rapide, Ndiaga Ndiaye, Minibus, PTB, Tata...) avec détail par critère au clic (prix, proximité de l'arrêt, temps d'attente, vitesse, confort, sécurité).
- **Insécurité perçue et incidents subis** : comparaison jour/nuit selon le contexte (à pied dans le quartier, à pied ailleurs, en TC, en voiture), liste des incidents réellement subis.
- **Difficultés de déplacement et gênes piétonnes** : manque d'argent, distance, embouteillages, attente, trottoirs encombrés, inondations, manque d'éclairage.
- **Recommandations automatiques** générées par seuils dépassés (mode le moins bien noté, taux d'insécurité élevé, etc.).
- **Section « Avis citoyens en direct »** : pont entre les deux volets, affichant note moyenne, nombre d'avis et derniers commentaires soumis via la cellule d'écoute publique.

#### 6.1.3 Volet public — page /avis (cellule d'écoute citoyenne)

Accessible directement, sans authentification, depuis la page d'accueil (bouton « Donner mon avis ») ou via l'URL /avis. Les avis sont **anonymes** : aucune information d'identification n'est demandée ni stockée.

```
{ "id": 1, "note_satisfaction": 4, "mode_utilise": "Tata",  
  "type_probleme": "attente", "quartier": "Médina",  
  "commentaire": "Attente trop longue le matin",  
  "date": "2026-06-16T10:32:00" }
```

### 6.1.4 Stockage

- Données EMD historiques : `backend/ml_models/satisfaction.json`, généré par `satisfaction_ecoute_usagers.py`.
- Avis citoyens en direct : `backend/data/feedback_citoyens.json`, enrichi à chaque soumission — pas de base de données externe nécessaire à ce stade.

### 6.1.5 Pistes d'évolution

Modération des commentaires, géolocalisation des avis pour superposition à la carte des zones à risque, migration vers une base de données si le volume augmente, export périodique pour les réunions du CETUD, alerte automatique en cas de pic de signalements de sécurité.

## 6.2 Note technique — Explicabilité du modèle (XAI / SHAP)

### 6.2.1 Contexte et point de vigilance

Le module « Audit & Transparence ML » (page MlInsights, accessible au rôle Directeur Planification) affiche une analyse de l'importance des variables sous l'étiquette « XAI · SHAP ». Or, la méthode **réellement implémentée** est l'importance native de scikit-learn (`model.feature_importances_`) sur le `GradientBoostingClassifier` — une mesure globale de réduction d'impureté, et non une véritable décomposition SHAP (Shapley Additive exPlanations) qui offrirait en plus une explication locale (cas par cas) avec une garantie mathématique d'additivité exacte.

### 6.2.2 Réponse type pour la soutenance

« Le module d'audit ML repose sur le principe de l'IA explicable (XAI) : il expose l'importance relative des variables qui influencent la prédiction de risque d'inaccessibilité, calculée via l'attribut `feature_importances_` du modèle `Gradient Boosting` de scikit-learn. Cette approche donne une explicabilité globale fiable. Une évolution possible serait d'intégrer la librairie SHAP (`TreeExplainer`) pour obtenir des explications locales, ménage par ménage, avec des garanties mathématiques d'additivité exacte. »

### 6.2.3 Incohérence d'étiquetage identifiée

Les modules « Zones à risque » et « Simulateur » s'appuient en réalité sur le même modèle (`inacc_model.pkl`, un `GradientBoostingClassifier`), mais l'interface affiche par endroits deux libellés différents (« Random Forest » vs « Gradient Boosting »). C'est une incohérence d'étiquetage dans l'interface, sans impact sur les résultats fonctionnels — un point à corriger si possible avant la soutenance, ou à défaut à mentionner soi-même comme point d'amélioration identifié. Le fait de l'anticiper et de le signaler soi-même est perçu positivement par un jury.

## 7 Volet Business Intelligence — Cockpit Knowage TransportDakar

### 7.1 Présentation du cockpit

Le cockpit est un document composite Knowage accessible à l'URL `workspace/document-composite/Acceuil`, organisé en six feuilles (sheets) :

| Sheet           | Contenu                                                                                                                                                 |
|-----------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|
| Acceuil         | Vue d'ensemble — cartes statistiques globales (156 764 déplacements analysés, 3 176 ménages enquêtés, 26 830 individus enquêtés, 101 sites de comptage) |
| Trafic          | KPI volume, vitesse, sens de circulation, répartition horaire                                                                                           |
| Déplacements    | KPI temps de parcours, motifs, coûts, volumes horaires, heures de pointe                                                                                |
| Démographie     | KPI sexe, statut matrimonial, niveau d'instruction, profession, permis de conduire                                                                      |
| Accessibilité   | KPI accessibilité par commune, par mode de transport, par tranche horaire, zones sous-desservies                                                        |
| IA & Prévisions | Prévision de trafic à 7 jours, détection d'anomalies, zones à risque, recommandations générées                                                          |

### 7.2 Identité visuelle « TransportDakar »

Chaque sheet a été redessiné selon une charte graphique cohérente :

| Élément                                               | Valeur  |
|-------------------------------------------------------|---------|
| Bleu marine (fond d'en-tête, texte principal)         | #0F172A |
| Orange (accent, barres de graphique, éléments actifs) | #F97316 |
| Blanc (cartes, fonds de contenu)                      | #FFFFFF |
| Gris clair (fond de page)                             | #F8FAFC |

Chaque sheet partage la même structure : un en-tête avec logo et titre, une rangée de cartes KPI, des graphiques avec axes et étiquettes, une synthèse ou des insights, et une barre de navigation entre les cinq sheets métier.

### 7.3 Les trois corrections demandées et leur implémentation technique

#### 7.3.1 1. Navigation réelle entre les sheets

La barre d'onglets native de Knowage permet de circuler entre les six sheets. Chaque sheet affiche également des « cartes de navigation » stylisées (icônes Trafic, Dé-

placements, Démographie, Accessibilité, IA) qui matérialisent visuellement la position courante (carte active mise en évidence en orange).

### 7.3.2 2. Mode clair / sombre — solution 100 % CSS

**Contrainte technique majeure :** Knowage applique un filtre de sécurité (sanitizer) côté serveur qui rejette toute balise `<script>` ou tout attribut `onclick` lors de la sauvegarde au niveau document, avec le message d'erreur « Invalid HTML payload ». Une bascule de thème pilotée par JavaScript était donc impossible à pérenniser.

**Solution retenue :**

```
<input type="checkbox" id="td-dark-toggle" style="display:none">
<label for="td-dark-toggle" class="td-theme-btn">Theme</label>

#td-home:has(#td-dark-toggle:checked) {
  background: #0B1220;
  color: #E2E8F0;
}
#td-home:has(#td-dark-toggle:checked) .td-kpi {
  background: #16213A;
  border-color: #28344F;
}
/* ... regles equivalentes pour chaque composant ... */
```

Le sélecteur CSS `:has()` permet de styliser un conteneur parent en fonction de l'état d'un élément enfant (la case cochée), sans aucune ligne de JavaScript. Le résultat passe systématiquement la validation du sanitizer.

### 7.3.3 3. Graphiques avec axes Y réels et étiquettes de valeur

**Avant :** les barres n'étaient positionnées qu'avec une hauteur en pourcentage arbitraire (`height: NN%`), sans aucun repère de lecture sur l'axe vertical.

**Après :** chaque graphique combine un axe Y gradué et une étiquette de valeur positionnée juste au-dessus de chaque barre :

```
<div class="td-chart">
  <div class="td-yaxis"><span>100</span><span>75</span><span>50</span><span>25</span><span>0</span></div>
  <div class="td-barswrap">
    <div class="td-bars">
      <div class="bar" style="height:55%"><span class="bv">55%</span></div>
      <div class="bar" style="height:62%"><span class="bv">62%</span></div>
      <!-- ... -->
    </div>
  </div>
</div>
```

Cette structure a été appliquée de façon identique aux cinq sheets métier (prévision de trafic à 7 jours, détection d'anomalies, zones à risque, accessibilité par commune/mode/tranche horaire, KPI trafic et démographie), garantissant une lecture cohérente des valeurs sur l'ensemble du cockpit.

## 7.4 Bug additionnel détecté et corrigé : widget dupliqué

Lors de la vérification finale, la barre latérale de cartes statistiques (censée n'apparaître que sur le sheet Accueil) s'affichait également sur le sheet **Accessibilité**, élargissant involontairement le contenu et cassant la mise en page pleine largeur des autres sheets. Le diagnostic a consisté à comparer la structure du sheet Accueil et du sheet Trafic (qui n'avaient pas ce widget) avec celle d'Accessibilité, confirmant qu'il s'agissait d'un widget résiduel et non d'un composant partagé intentionnel. Le widget a été supprimé via le menu contextuel d'édition (« Delete widget »), la suppression confirmée, puis sauvegardée au niveau document. Un rechargement complet de la page a confirmé que le sheet Accessibilité s'affiche désormais en pleine largeur, identique aux quatre autres sheets métier.

## 7.5 Méthodologie de déploiement et de vérification dans Knowage

Pour chaque sheet, le déploiement a suivi deux niveaux de sauvegarde :

1. **Sauvegarde au niveau du widget** (bouton SAVE dans l'éditeur HTML) — toujours acceptée visuellement, sans validation de fond.
2. **Sauvegarde au niveau du document** (icône disque dans le menu cockpit) — seule sauvegarde qui déclenche réellement le filtre de sécurité côté serveur ; un toast « Saved » confirme la réussite, un message « Invalid HTML payload » signale un rejet (balise script ou attribut interdit).

Seul un rechargement complet de la page après cette deuxième sauvegarde permet de garantir que le contenu est réellement persisté côté serveur — c'est la méthode de vérification appliquée systématiquement à la fin de chaque déploiement et lors de la vérification finale.

## 8 Forces, limites et perspectives

### 8.1 Points forts du projet

| Point fort                        | Détail                                                                                                                 |
|-----------------------------------|------------------------------------------------------------------------------------------------------------------------|
| Consensus d'anomalies             | Trois algorithmes combinés (Z-Score + Isolation Forest + LOF) avec poids optimisés, plus robuste qu'un algorithme seul |
| Variable cible composite          | Sept indicateurs terrain agrégés en un score d'inaccessibilité — ancrage métier fort                                   |
| SMOTE sur données déséquilibrées  | Gestion des classes rares (5 zones à risque ÉLEVÉ sur 41)                                                              |
| RBAC multi-rôles                  | Deux rôles avec permissions différentes, conception orientée utilisateur                                               |
| Thème clair/sombre                | Sur l'application React (Context) et sur le cockpit Knowage (CSS pur), cohérence UX sur les deux volets                |
| Double dimension citoyen/décideur | Un système inclusif (recommandation citoyenne) et un système stratégique (pilotage CETUD)                              |
| Transparence du modèle            | Page dédiée à l'auditabilité, avec note technique assumant les limites de l'explicabilité actuelle                     |
| Cockpit BI cohérent               | Identité visuelle unifiée, navigation réelle, graphiques à échelle correcte sur l'ensemble des sheets                  |

### 8.2 Limites et points critiques (avec réponse défensive)

| Limite                                                | Réponse défensive                                                                          |
|-------------------------------------------------------|--------------------------------------------------------------------------------------------|
| Pas de base de données relationnelle pour le volet ML | Données d'enquête statiques ; fichiers plats = standard CETUD. BDD prévue en roadmap v2    |
| Authentification simulée côté client                  | Suffisant pour un PFE démonstratif ; en production : JWT RS256 + Keycloak                  |
| Données EMD datées de 2019                            | Seule enquête ménage disponible publiquement au Sénégal ; EMD 2024 en cours selon le CETUD |
| Pas de tests automatisés                              | Contrainte de temps PFE ; tests manuels via Swagger ; pytest en roadmap                    |
| Étiquetage ML incohérent (RF vs GB affiché)           | Incohérence d'interface identifiée et documentée, sans impact fonctionnel                  |
| Explicabilité « XAI/SHAP » en réalité                 | Assumé et expliqué : évolution possible vers SHAP TreeExplainer                            |
| feature importance native                             |                                                                                            |

| Limite                                              | Réponse défensive                                                                      |
|-----------------------------------------------------|----------------------------------------------------------------------------------------|
| Coefficient de silhouette modéré ( $\approx 0,31$ ) | Acceptable pour des données sociodémographiques complexes avec chevauchements naturels |
| Tâche d'harmonisation des couleurs encore en cours  | Identifiée comme restant à finaliser sur l'ensemble des widgets                        |

### 8.3 Roadmap future

**Court terme (3-6 mois) :** base de données PostgreSQL, tests unitaires (pytest + Jest), conteneurisation Docker Compose, authentification JWT + bcrypt, intégration continue.

**Moyen terme (6-18 mois) :** données temps réel (API DAKAR DEM DIKK), suivi des expériences ML (MLflow), réentraînement automatique, application mobile, valeurs SHAP individuelles, intégration de l'EMD 2024.

**Long terme :** capteurs GPS temps réel sur le réseau de bus, modèles de prévision par séries temporelles (LSTM), réseaux de neurones sur graphes pour modéliser le réseau de transport, optimisation par algorithme génétique des lignes, agent conversationnel multilingue (y compris en wolof) pour l'aide au déplacement.

## 9 Foire aux questions de soutenance

### 9.1 Architecture et choix techniques

**Pourquoi une architecture en couches séparées (frontend / backend / ML) ?** Séparation des responsabilités : le frontend peut être remplacé sans toucher au ML, le modèle peut être réentraîné sans arrêter le frontend, la maintenance est cloisonnée.

**Pourquoi FastAPI plutôt que Flask ?** Validation automatique via Pydantic, documentation Swagger auto-générée, support asynchrone natif — Flask nécessiterait des bibliothèques supplémentaires pour obtenir les mêmes fonctionnalités.

**Pourquoi pas de base de données relationnelle ?** Données d'enquête statiques et non transactionnelles ; les fichiers plats sont le format natif fourni par le CETUD. Le Data Warehouse en étoile a en revanche été construit pour la partie restitution BI (Knowage).

### 9.2 Machine Learning

**Comment avez-vous choisi  $k=5$  pour le K-Means ?** Double méthode : la méthode du coude (elbow) sur l'inertie, combinée au coefficient de silhouette, qui est maximal pour  $k=5$ .

**Pourquoi SMOTE ?** Le dataset contient peu de zones à risque ÉLEVÉ (5 sur 41, environ 12 %). Sans correction, le modèle apprendrait à toujours prédire « FAIBLE » pour obtenir une bonne accuracy sans jamais détecter les vrais dangers. SMOTE génère des exemples synthétiques de la classe minoritaire par interpolation entre voisins.

**Pourquoi combiner trois algorithmes de détection d'anomalies ?** Chaque algorithme a ses forces : Z-Score détecte les valeurs extrêmes univariées, Isolation Forest les anomalies multivariées, LOF les anomalies de densité locale. Le consensus pondéré réduit les faux positifs d'environ 35 % par rapport à un seul algorithme.

**Quelles sont les limites du modèle d'inaccessibilité ?** Données de 2019 (la réalité a pu évoluer depuis), variable cible construite avec un choix méthodologique (sept indicateurs, seuil au 65e percentile), données d'enquête auto-déclarées (biais de perception possible), absence de données temps réel.

### 9.3 Sécurité

**Le stockage des mots de passe est-il acceptable en production ?** Non — c'est acceptable uniquement pour un PFE démonstratif. En production : mots de passe hashés (bcrypt), jamais en clair dans le code, HTTPS obligatoire, protection CSRF et limitation du nombre de tentatives.

### 9.4 Business Intelligence — Cockpit Knowage

**Pourquoi le mode clair/sombre est-il implémenté en CSS pur plutôt qu'en JavaScript ?** Parce que Knowage applique un filtre de sécurité (sanitizer) côté serveur qui rejette toute balise `<script>` ou tout attribut `onclick` lors de la sauvegarde du document. Le sélecteur CSS `:has()` combiné à une case à cocher invisible permet d'obtenir le même résultat visuel sans aucune ligne de script, et passe donc la validation.

**Comment avez-vous corrigé l'absence d'échelle sur les graphiques à barres ?** En ajoutant à chaque graphique un bloc d'axe Y gradué (0/25/50/75/100) et une étiquette de valeur numérique positionnée au-dessus de chaque barre, de façon identique sur les cinq sheets métier, pour garantir une lecture cohérente des données.

**Comment avez-vous vérifié que vos corrections étaient réellement persistées ?** En distinguant deux niveaux de sauvegarde dans Knowage : la sauvegarde au niveau du widget (toujours acceptée visuellement, sans garantie) et la sauvegarde au niveau du document (qui déclenche le filtre de sécurité serveur). Seul un rechargement complet de la page après cette seconde sauvegarde, sans message d'erreur, garantit que le contenu est réellement persisté.

**Quel widget dupliqué avez-vous identifié et corrigé ?** Une barre latérale de cartes statistiques destinée uniquement au sheet Accueil s'affichait également par erreur sur le sheet Accessibilité. Elle a été identifiée par comparaison structurelle avec les autres sheets, supprimée via le menu d'édition du widget, et la correction a été vérifiée comme persistante après rechargement.

## 10 Fiche de révision express

### 10.1 Pitch deux minutes

« Le réseau de transport urbain de Dakar souffre de trois problèmes majeurs : des zones géographiques entièrement inaccessibles aux transports en commun, des anomalies de trafic non détectées sur les axes principaux, et l'absence d'outil pour guider les citoyens dans le choix de leur mode de déplacement.

Notre projet répond à ces trois problèmes en construisant une plateforme complète d'aide à la décision alimentée par le Machine Learning et la Business Intelligence, basée sur les données réelles de l'Enquête Ménage Déplacement CETUD 2019 portant sur 37 248 individus, 4 521 ménages et 775 480 observations de trafic.

La plateforme propose un espace citoyen permettant d'obtenir une recommandation personnalisée de mode de transport, un espace décideurs réservé aux gestionnaires du CETUD pour analyser les zones à risque, détecter les anomalies, simuler des scénarios et écouter les usagers, et enfin un cockpit décisionnel Knowage avec navigation, mode clair/sombre et graphiques à échelle réelle pour le pilotage visuel des indicateurs clés. »

### 10.2 Chiffres clés à citer

| Indicateur                      | Valeur                        |
|---------------------------------|-------------------------------|
| Individus enquêtés (EMD)        | 37 248                        |
| Ménages enquêtés                | 4 521                         |
| Sites de comptage trafic        | 49 (101 selon le cockpit BI)  |
| Observations de trafic          | 775 480                       |
| Anomalies détectées             | 316                           |
| Sites à risque                  | 30 / 49 (61 %)                |
| Zones d'accessibilité analysées | 41                            |
| Zones à risque ÉLEVÉ            | 5                             |
| Zones à risque MODÉRÉ           | 14                            |
| Accuracy modèle inaccessibilité | 90,6 %                        |
| ROC AUC                         | 0,921                         |
| F1-score                        | 88,3 %                        |
| Clusters K-Means                | 5                             |
| Sheets du cockpit Knowage       | 6 (Accueil + 5 sheets métier) |

### 10.3 Réponses rapides

- **Pourquoi FastAPI ?** Validation Pydantic, documentation Swagger automatique, support asynchrone.
- **Pourquoi K-Means ?** Non supervisé, interprétable, validé par le coefficient de silhouette.
- **Pourquoi trois algorithmes d'anomalies ?** Le consensus réduit les faux positifs d'environ 35 %.

- **Pourquoi le seuil au 65e percentile ?** Il maximise le F1-score en validation croisée.
- **Sécurité de l'authentification ?** Simplifiée pour le PFE ; en production : JWT RS256 + bcrypt.
- **Données récentes ?** EMD 2019, seule enquête disponible publiquement au Sénégal à ce jour.
- **Mode clair/sombre dans Knowage ?** CSS pur via `:has()`, car le sanitizer Knowage interdit le JavaScript.
- **Axes Y des graphiques BI ?** Ajout d'une échelle graduée et d'étiquettes de valeur sur chaque barre, sur les cinq sheets.
- **Comment vérifier qu'une sauvegarde Knowage a réellement pris ?** Sauvegarde document + rechargement complet + absence de message d'erreur.

